



UNIVERSIDADE DO ESTADO DO
RIO DE JANEIRO



INSTITUTO POLITÉCNICO
GRADUAÇÃO EM ENGENHARIA
DE COMPUTAÇÃO

Pedro Felipe Pena Barata

Aplicações práticas em técnicas de reconstrução 3D utilizando
fotogrametria

Nova Friburgo

2017



UNIVERSIDADE DO ESTADO DO
RIO DE JANEIRO



INSTITUTO POLITÉCNICO
GRADUAÇÃO EM ENGENHARIA
DE COMPUTAÇÃO

Pedro Felipe Pena Barata

Aplicações práticas em técnicas de reconstrução 3D utilizando fotogrametria

Trabalho de Conclusão de Curso apresentado, como requisito parcial para obtenção do título de Graduado em Engenharia de Computação, ao Departamento de Modelagem Computacional do Instituto Politécnico, da Universidade do Estado do Rio de Janeiro.

Orientador: Prof. Dr. Ricardo Fabbri

Nova Friburgo

2017

Pedro Felipe Pena Barata

Aplicações práticas em técnicas de reconstrução 3D utilizando fotogrametria

Trabalho de Conclusão de Curso apresentado, como requisito parcial para obtenção do título de Graduado em Engenharia de Computação, ao Departamento de Modelagem Computacional do Instituto Politécnico, da Universidade do Estado do Rio de Janeiro.

Aprovada em 30 de 09 de 2017.

Banca Examinadora:

Prof. Dr. Ricardo Fabbri (Orientador)
Departamento de Modelagem Computacional – UERJ

Prof. Dr. Edirlei Soares
Departamento de Modelagem Computacional – UERJ

Prof. Dr. Roberto Pinheiro
Departamento de Modelagem Computacional – UERJ

Nova Friburgo
2017

AGRADECIMENTOS

RESUMO

BARATA, Pedro Felipe Pena. *Aplicações práticas em técnicas de reconstrução 3D utilizando fotogrametria*. 2017. 58 f. Trabalho de Conclusão de Curso (Graduação em Engenharia de Computação) – Departamento de Modelagem Computacional, Instituto Politécnico, Universidade do Estado do Rio de Janeiro, Nova Friburgo, 2017.

A partir dos anos 2000, a área de reconstrução 3D vem sido amplamente explorada. No início, sensores de alcance, tanto aéreos quanto terrestres, eram empregados em diferentes aplicações. Porém, constantes melhorias na tecnologia, sobretudo, nos *hardwares* e *softwares* no âmbito da reconstrução, fizeram com que hoje, quase duas décadas depois, novas técnicas surgissem.

Muitos cientistas que utilizavam a fotogrametria converteram seus esforços na área dos sensores à laser. Pois além de executarem uma reconstrução mais rápida, possuem uma altíssima acurácia, compensando seu alto custo inicial. Isto dificultou e desacelerou o processo de descoberta de novos algoritmos e métodos na área da fotogrametria.

Hoje em dia, graças à esse avanço, a fotogrametria, aliada a novos algoritmos, como o *Structure from Motion* (SfM), pontos em comum e de combinação de imagens, por exemplo, consegue competir com scanners à laser e sensores de alcance.

Neste trabalho, abordaremos o uso de técnicas combinando SfM e MVS (*Multi-View Stereo*), utilizando *softwares* como o MVE (CITAR GOESELE) e o VisualSfM (CITAR CHANGCHANGWU), é possível gerar uma reconstrução satisfatória apenas utilizando uma câmera de um *smartphone*. Além disso exploraremos um pouco sobre outros tipos de técnicas empregadas em grandes projetos, como o Kinect, da Microsoft e sua aplicação em SfM e o projeto de reconstrução das esculturas de Michelangelo, feito por um grupo da Universidade de Stanford.

O trabalho foi estruturado da seguinte maneira: previamente apresentam-se os objetivos do projeto, destacando suas funcionalidades e metas, a seguir divide-se em capítulos; O Capítulo 1, que introduz o funcionamento de cada algoritmo e técnica empregada, apresentando e debatendo, comparativamente pontos à favor e contra; O Capítulo 2 é dedicado à ferramenta gráfica utilizada para a obtenção dos resultados (VisualSfM). Finalmente, apresentamos os resultados e conclusões do trabalho, bem como sugestões para implementações e trabalhos futuros.

Palavras-chave: Reconstrução densa. Nuvem de pontos. SfM. Triangulação.

ABSTRACT

BARATA, Pedro Felipe Pena. . 2017. **58** f. Trabalho de Conclusão de Curso (Graduação em Engenharia de Computação) – Departamento de Modelagem Computacional, Instituto Politécnico, Universidade do Estado do Rio de Janeiro, Nova Friburgo, 2017.

Keywords:

LISTA DE FIGURAS

Figura 1 - Kinects de primeira geração (a) consistindo de câmeras e projetores infra-vermelho (b) e de segunda geração, consistindo de tecnologia ToF (c). Ambos os kinects são largamente utilizados para escaneamento em tempo real, formando a base de scanners manuais (d), porém nem sempre são úteis para preservação detalhada de patrimônio. Um dos objetivos deste projeto é explorar os limites desta tecnologia.	13
Figura 2 - A reconstrução usando-se Kinect (de primeira ou segunda geração) usando software atual de super-resolução (c) fornece precisão similar a um sistema estéreo de média resolução, inferior um sistema a laser de alta qualidade (d) porém de baixo custo e muito mais versátil devido ao sistema de aquisição manual e a software amplamente utilizado e desenvolvido(????).	14
Figura 3 - Protótipo do scanner a laser de triangulação. O objeto a ser escaneado é uma réplica em tamanho real de um sarcófago egípcio (a). O scanner foi reconfigurado para escanear objetos maiores, pois a escultura possui 517 centímetros (b), o da cabeça também sofreu uma reconfiguração, este scanner gira em 90 graus, que faz o laser rotacionar, da posição horizontal para a vertical e também roda em torno da cabeça como um todo (c). Para a reconstrução, o primeiro passo foi alinhar cerca de 100 scans em diversas posicoes, após isso, utilizado um alinhamento automatico em pares dos scans, utilizando um algoritmo modificado de iteracoes de pontos próximos (ICP - <i>iterated-closest-points</i>). Após isso, faz-se um processo de relaxação global a fim de minimizar erros de alinhamento por toda a estátua. Depois de alinhados, usa-se o algoritmo de profundidade volumétrica de processamento de imagens (VRIP - <i>volumetric range image processing</i> - do Brian Curless) (d).	14
Figura 4 - Algumas esculturas do Jardim do Nêgo	15
Figura 5 - A reconstrução usando-se apenas imagens, sem controle de aquisição, como em um vídeo de um smartphone filmado em torno do objeto, fornece uma nuvem de pontos, que pode ser densificada (??????????), ou atribuída de curvas (?????????), de forma a preservar a resolução em áreas de alto conteúdo informativo. Tais representações estão sendo atualmente unificadas na pesquisa da área. Este projeto propõe explorar os limites da reconstrução 3D usando-se apenas imagens, no contexto de preservação de patrimônio.	15

Figura 6 - Exemplo de reconstrução à laser utilizando o método baseado em volume.	18
Figura 7 - Imagem de um kinect V1 aberto, constituído de uma câmera infravermelho (IR), uma câmera RGB e um projetor IR.	22
Figura 8 - Exemplo de como é a saída de uma imagem interpretada pelo Kinect, onde cada cor disposta na imagem, corresponde à profundidade ou distância da cena para o Kinect.	23
Figura 9 - Representação visual do acerto do deslocamento. A parte em preto é a imagem IR e o contorno em branco é a imagem de profundidade do alvo.	25
Figura 10 - Posição e orientação do Kinect (com as câmeras IR e RGB) e o par estéreo SLR (<i>Left</i> , <i>Right</i>) em conjunto com pontos de calibração 3D reconstruídos em alvos de calibração planar.	25
Figura 11 - É aplicado um filtro gaussiano na imagem original (a), com $\sigma = 1$, tendo como resultado a imagem (b). Um outro filtro gaussiano é usado, porém, neste caso, o $\sigma = 2$ (c). Após isso, subtrai-se (b) de (c), obtendo o filtro DoG (d).	28
Figura 12 - Exemplo de funcionamento de detecção de espaço-escala extrema	29
Figura 13 - Exemplo do resultado obtido do histograma orientado	31
Figura 14 - Exemplo de um descritor de pontos-chaves, com uma matriz 2x2 e uma região 8x8	31
Figura 15 - Uma triangulação utilizando um ponto qualquer, X_j . Onde cada câmera C_1, C_2, C_3 possui um <i>feature</i> correspondente a cada uma delas, respectivamente, X_{1j}, X_{2j}, X_{3j} .	32
Figura 16 - Erro proveniente da reprojeção, onde os pontos x e x' estão mais próximos das medidas reais da imagem.	33
Figura 17 - Funcionamento do MVE. Começando com múltiplas imagens, técnicas SfM são empregadas para reconstruir os parâmetros das câmeras e os conjuntos de pontos esparsos. Mapas de profundidade são computados para cada imagem usando o MVS. Finalmente, uma malha colorida é extraída da união de todos os mapas de profundidade usando um algoritmo de aproximações de reconstruções de superfícies (FSSR).	35

Figura 18 - Caso o espaçamento entre as câmeras seja grande, a informação extraída das imagens em comum será menor (a). Se a angulação do efeito de paralaxe seja baixa, terá a mesma informação sobre um ponto em questão (c). Ou seja utilizando ou (a), ou (c). Pode ser que a reconstrução fique incerta. Para que o efeito paralaxe tenha maior proveito das imagens das câmeras, é necessário que as câmeras estejam dispostas como (b), conseguindo extrair uma boa quantidade e qualidade de informações do ponto.	36
Figura 19 - Interface gráfica (UMVE)	37
Figura 20 - Reconstrução baseada em nuvem de pontos gerada a partir da reconstrução SfM.	37
Figura 21 - Uma imagem de entrada (à esquerda) e sua correspondência em mapas de profundidade (à direita), onde a parte roxa significa que não foi encontrada nenhum mapa naquela região.	38
Figura 22 - A figura (a) é um exemplo onde a imagem possui dados na extensão EXIF (destacado em azul). Ao passo que a figura (b) é um frame de um vídeo, que não possui os dados das câmeras (destacado em azul).	39
Figura 23 - Final da reconstrução via UMVE, percebe-se que alguns pontos não foram considerados, tendo como resultado uma ”nuvem de pontos” mais densa, basicamente.	39
Figura 24 - Processos dentro do comando <i>sfmrecon</i> , onde (a) estão sendo detectadas as <i>features</i> do conjunto de imagens. Em (b) está computado o <i>pairwise matching</i> e em (c) está no processo do <i>Bundle Adjustment</i> , usando condições-padrão para as câmeras.	40
Figura 25 - Término do comando <i>sfmrecon</i> , onde demorou cerca de 1 minuto e meio (75509 milisegundos).	41
Figura 26 - Término do comando <i>dmrecon</i> , onde demorou cerca de 4 horas (14502576 milisegundos).	41
Figura 27 - Execução dos comandos <i>scene2pet</i> , nos níveis -F0, -F1, -F2 e -F3.	42
Figura 28 - Progressão do comando <i>fssrecon</i> , onde possui o ETA – <i>Estimated Time of Arrival</i>	42
Figura 29 - Malha com ruídos proveniente do comando <i>fssrecon</i>	43
Figura 30 - Resultado final, após a remoção dos ruídos da malha.	43
Figura 31 - Botões na parte superior da interface gráfica, este seria o <i>pipeline</i> software.	44
Figura 32 - Exemplo de como foi realizada a varredura da escultura	51
Figura 33 - Reconstrução esparsa do objeto no VisualSfM	52
Figura 34 - Reconstrução densa do objeto no VisualSfM	53
Figura 35 - Reconstrução esparsa do objeto com 224 imagens no VisualSfM	53

Figura 36 - Foi gerado dois modelos esparsos do objeto a partir do conjunto inicial de 224 imagens, provavelmente, proveniente da falta de parâmetros da câmera	54
Figura 37 - Reconstrução do primeiro modelo do objeto no VisualSfM com 224 imagens	54
Figura 38 - Reconstrução do segundo modelo do objeto no VisualSfM com 224 imagens	54
Figura 39 - Tempo gasto da etapa <i>sfmrecon</i> do MVE	54
Figura 40 - Tempo da etapa <i>dmrecon</i> do MVE	55
Figura 41 - Tempo da etapa <i>fssrecon</i> do MVE	55
Figura 42 - Resultado da etapa <i>fssrecon</i> do MVE	55
Figura 43 - Resultado da etapa <i>meshclean</i> , da etapa anterior 42	56
Figura 44 - Resultado da etapa <i>sfmrecon</i> , com todas as imagens	56
Figura 45 - Resultado da etapa <i>dmrecon</i> , com todas as imagens	57

SUMÁRIO

	INTRODUÇÃO	12
0.1	Introdução e Justificativa	12
0.1.1	<u>O Jardim do Nêgo, Nova Friburgo</u>	15
0.2	Objetivos	16
0.3	Organização deste manuscrito	17
0.4	Laser	17
1	KINECT	22
2	PONTOS DE INTERESSE	27
2.1	SIFT – <i>Scale Invariant Feature Transform</i>	27
2.1.1	<u>Detecção de espaço-escala extremos</u>	27
2.1.2	<u>Localização de pontos-chaves</u>	29
2.1.3	<u>Atribuição de orientação</u>	30
2.1.4	<u>Descriptor de pontos-chaves</u>	31
2.1.5	<u>Combinação de pontos-chaves</u>	32
2.2	Triangulação – <i>Full pairwise image matching</i>	32
3	RECONSTRUÇÃO DENSA	34
3.1	Introdução	34
3.2	MVE	34
3.2.1	<u>Guia de reconstrução com o MVE</u>	35
4	VISUALSFM	44
4.0.2	<u>Filtro SFM</u>	46
4.0.3	<u>Seleção de imagens</u>	47
4.0.4	<u>Divisão de <i>cluster</i></u>	47
4.0.5	<u>Adição de imagens</u>	47
4.0.6	<u>PMVS-2</u>	48
4.0.7	<u>Detecção de <i>features</i></u>	49
4.0.8	<u>Expansão</u>	49
4.0.9	<u>Filtragem</u>	50
4.0.9.1	<u>Filtro de Qualidade</u>	50
4.0.9.2	<u>Filtro de Visibilidade</u>	50
5	EXPERIMENTOS	51
5.1	Procedimento	51
5.1.1	<u>Resultados da reconstrução do objeto com o VisualSfM</u>	52
5.1.2	<u>Resultados da reconstrução do objeto com o MVE</u>	53
	CONCLUSÃO	58

INTRODUÇÃO

0.1 Introdução e Justificativa

A reconstrução 3D de cenas gerais a partir de múltiplos pontos de vista usando-se câmeras convencionais, sem aquisição controlada, é um dos grandes objetivos de pesquisa em visão computacional, ambicioso até mesmo para os dias de hoje. Aplicações incluem a reconstrução de modelos 3D para uso em videogames (??), filmes (??), arqueologia, arquitetura, modelagem 3D urbana (*e.g.*, Google Streetview); técnicas de *match-moving* em cinematografia para fusão de conteúdo virtual e filmagem real (??), a organização de uma coleção de fotografias com relação a uma cena (*e.g.*, o sistema *Phototourism* (??) e a funcionalidade *Look Around* do Google Panoramio e Street View), manipulação robótica, e a metrologia a partir de câmeras na indústria automobilística e metal-mecânica.

Os desafios estão ligados às escolhas de grande escala de representações adequadas e de técnicas que possam modelar simultaneamente com materiais drásticamente diferentes (*e.g.*, não-Lambertianos), modelos geométricos (*e.g.*, variedades curvilíneas gerais, descontinuidades, texturas, deformações, em escalas diferentes), tipos de regiões (com ou sem textura), condições de iluminação variadas, sombras, fortes diferenças de perspectivas, desbalanceamento devido a excesso de detalhes em partes menos importantes, número arbitrário de objetos e câmeras não-calibradas.

Mesmo que um sistema completo esteja fora do alcance da tecnologia atual, um progresso significativo tem sido atingido nos últimos anos. Por um lado, uma tecnologia operacional tem evoluído, mais recentemente para sistemas de grande escala (????), a partir do desenvolvimento da detecção robusta de *features* (??), o *fitting* robusto e seleção de correspondências baseados em RANSAC, e o desenvolvimento de métodos de geometria projetiva para calibrar duas ou três imagens e progressivamente adicionar imagens e extrair estrutura 3D dessas *features* na forma de nuvens de pontos. Com o código fonte do sistema Bundler (????) liberado por Noah Snavely, e sua subsequente incorporação ao sistema VisualSfM (??), é possível utilizar este sistema para a reconstrução de patrimônio.

No paradigma usando-se apenas imagens convencionais – denominado **reconstrução estéreo multiocular passiva** – a posição das câmeras são estimadas a partir apenas de imagens, usando pontos de interesse, em seguida uma nuvem de pontos é reconstruída ?. As câmeras podem então ser utilizadas para obter modelos mais detalhados de reconstrução, como algoritmos de densificação (??) e interpolação (??) da nuvem de pontos, bem como demais algoritmos densos de visão estéreo multi-perspectiva/multiocular, como os do grupo de Michel Goesele (??), também com código disponível. Tais algoritmos, no entanto, têm problemas, em particular a reconstrução suaviza partes bem-

delineadas do objeto, e pode conter buracos em áreas homogêneas. Pode-se, portanto, utilizar a reconstrução 3D de curvas do pesquisador proponente (?????????) para auxiliar na reconstrução mais bem-delinada nesses casos problemáticos, bem como para ajudar no problema de escalabilidade quando a reconstrução 3D se torna muito grande. Um segundo paradigma, denominado **reconstrução estéreo multiocular ativa**, tem se tornado viável devido à indústria de videogames, e consiste na utilização de sistemas que alteram o funcionamento de câmeras convencionais, típicamente usando-se projetores infra-vermelho, laser ou câmeras ToF (time of flight), como no caso dos dispositivos Kinect, figura 7.

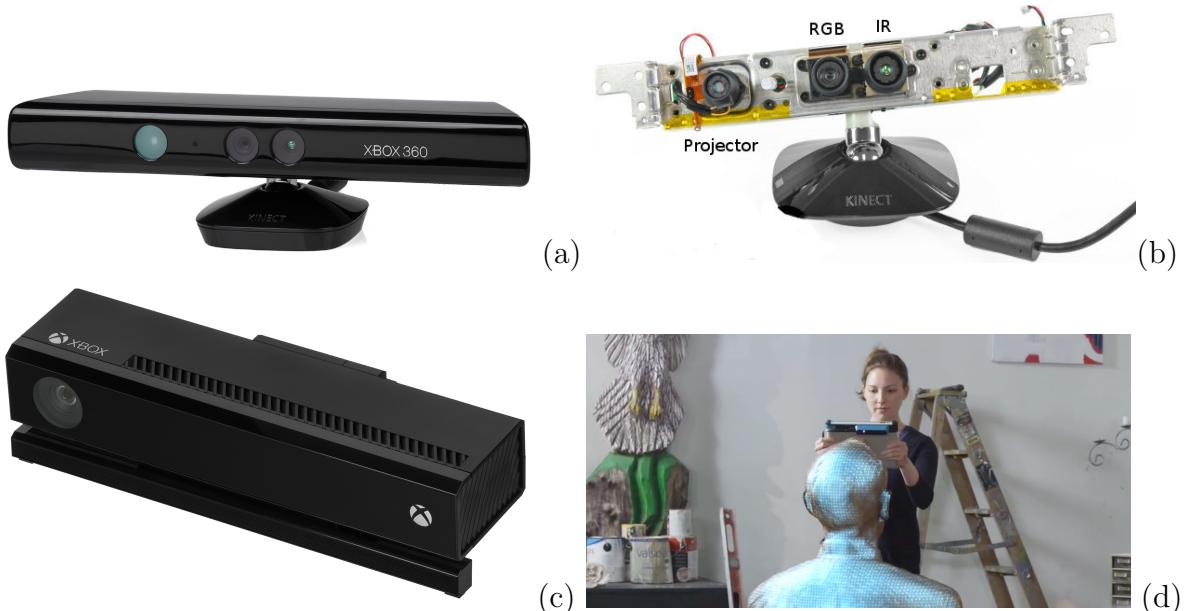


Figura 1 - Kinects de primeira geração (a) consistindo de câmeras e projetores infra-vermelho (b) e de segunda geração, consistindo de tecnologia ToF (c). Ambos os kinects são largamente utilizados para escaneamento em tempo real, formando a base de scanners manuais (d), porém nem sempre são úteis para preservação detalhada de patrimônio. Um dos objetivos deste projeto é explorar os limites desta tecnologia.

A preservação de patrimônio tem sido realizada tradicionalmente com scanners dedicados de alto custo, como no projeto David 3. O projeto teve início em 1992 e tem como objetivo a utilização de scanners a laser de profundidade (*rangefinder scanners*), aliado com algoritmos que combinam diferentes profundidades e cores da imagem, para realizar uma digitalização da parte externa e da superfície de forma acurada da estátua de David (porém, esse método pode ser utilizado em diferentes objetos no mundo real, como partes de máquinas, artefatos culturais e na indústria de video games, por exemplo). Para as partes mais detalhadas, foi utilizado um scanner de menor escala que faz uma pequena triangulação com laser de profundidade.

Seria de grande interesse explorar os dois paradigmas supracitados para avaliar as possibilidades disponíveis no estado da arte de reconstrução 3D para o escaneamento de

baixo custo para a preservação de Patrimônio. O que se pode atingir com apenas uma filmagem de esculturas realizada por um smartphone, sem calibração prévia e *in situ*, ou seja, sem ambiente controlado? Como esta reconstrução se compara nos dias de hoje com a reconstrução realizada por um scanner padrão baseado em Kinect?

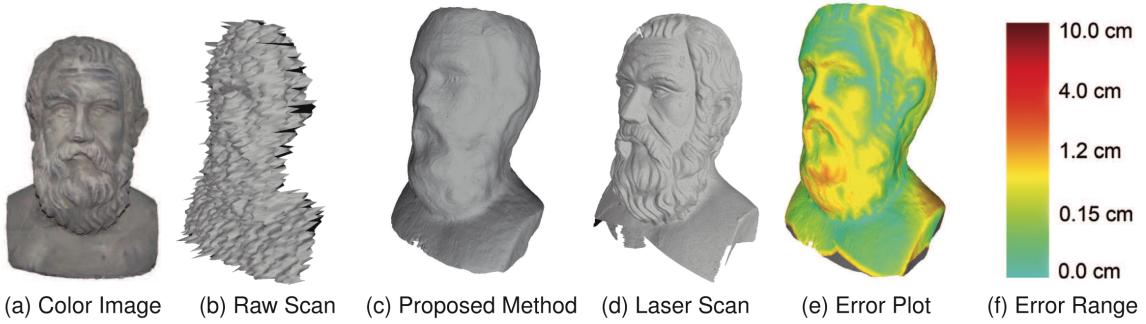


Figura 2 - A reconstrução usando-se Kinect (de primeira ou segunda geração) usando software atual de super-resolução (c) fornece precisão similar a um sistema estéreo de média resolução, inferior um sistema a laser de alta qualidade (d) porém de baixo custo e muito mais versátil devido ao sistema de aquisição manual e a software amplamente utilizado(????).

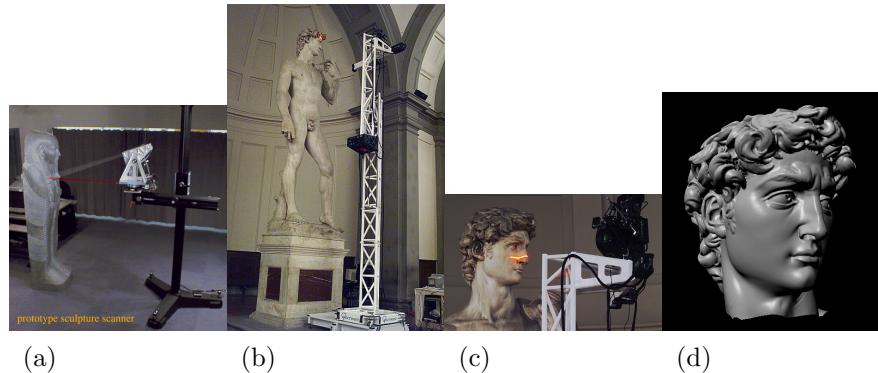


Figura 3 - Protótipo do scanner a laser de triangulação. O objeto a ser escaneado é uma réplica em tamanho real de um sarcófago egípcio (a). O scanner foi reconfigurado para escanear objetos maiores, pois a escultura possui 517 centímetros (b), o da cabeça também sofreu uma reconfiguração, este scanner gira em 90 graus, que faz o laser rotacionar, da posição horizontal para a vertical e também roda em torno da cabeça como um todo (c). Para a reconstrução, o primeiro passo foi alinhar cerca de 100 scans em diversas posicoes, após isso, utilizado um alinhamento automatico em pares dos scans, utilizando um algoritmo modificado de iteracoes de pontos próximos (ICP - *iterated-closest-points*). Após isso, faz-se um processo de relaxação global a fim de minimizar erros de alinhamento por toda a estátua. Depois de alinhados, usa-se o algoritmo de profundidade volumétrica de processamento de imagens (VRIP - *volumetric range image processing* - do Brian Curless) (d).

0.1.1 O Jardim do Nêgo, Nova Friburgo

No caso de Nova Friburgo, há a necessidade redobrada de preservação do patrimônio, em especial devido às chuvas e deslizamentos inerentes à região. O Jardim do Nêgo consiste em grandes esculturas em encostas, cobertas por um tapete de vegetação, as quais desfrutam de grande reconhecimento regional e internacional (??), figura 4.



Figura 4 - Algumas esculturas do Jardim do Nêgo

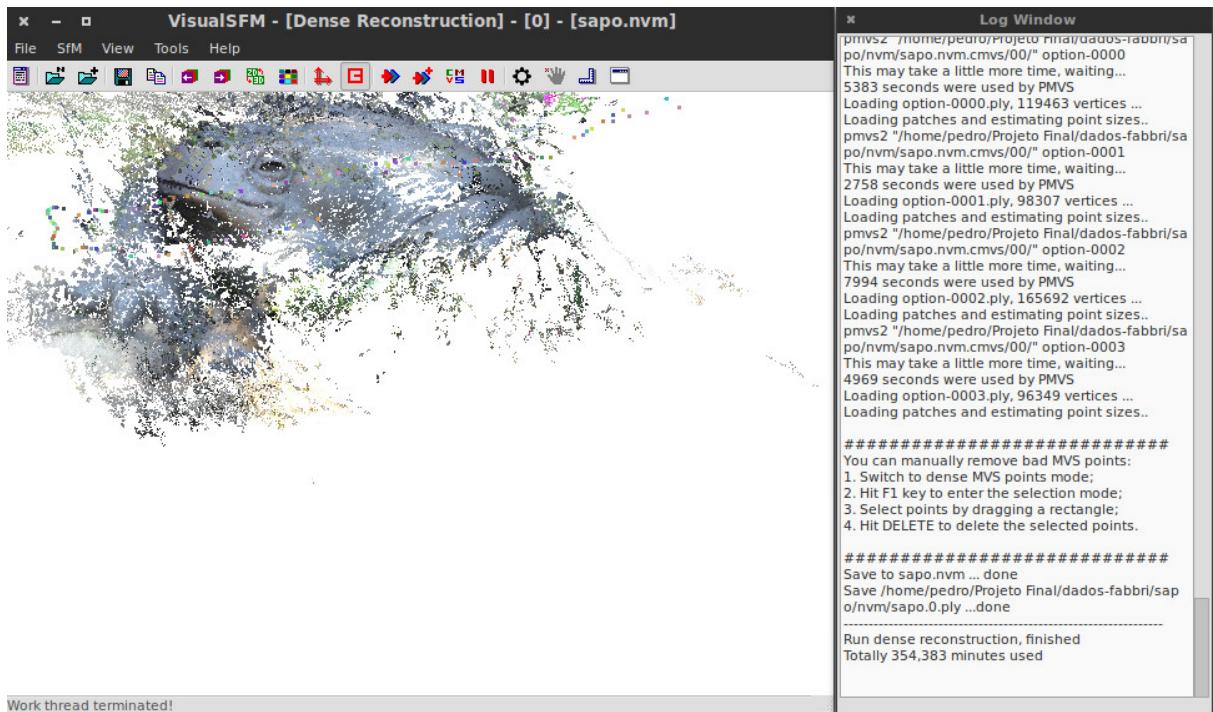


Figura 5 - A reconstrução usando-se apenas imagens, sem controle de aquisição, como em um vídeo de um smartphone filmado em torno do objeto, fornece uma nuvem de pontos, que pode ser densificada (??????????), ou atribuída de curvas (??????????), de forma a preservar a resolução em áreas de alto conteúdo informativo. Tais representações estão sendo atualmente unificadas na pesquisa da área. Este projeto propõe explorar os limites da reconstrução 3D usando-se apenas imagens, no contexto de preservação de patrimônio.

Idealizado e criado por Geraldo Simplicio (Nêgo), artista cearense que mora no

local a mais de 30 anos, ganhou notoriedade por suas esculturas de barro, com traços singulares e técnicas únicas. Hoje, trabalha para reconstruir o Jardim da tragédia de 2011 na região serrana, onde algumas estruturas foram destruídas. Portanto, com o consentimento do Nêgo, surgiu a motivação desta pesquisa: além de explorar métodos de reconstrução, também tem o objetivo de eternizar um patrimônio que é reconhecido no mundo todo.

A preservação das esculturas do Jardim do Nego se torna um desafio à pesquisa em reconstrução 3D, pois apresentam curvas bem delineadas, que são representadas de maneira suavizada e empobrecida por métodos convencionais. Algumas esculturas apresentam pouca textura, quase sem nenhum padrão de textura/musgo. Seria de grande interesse avaliar o potencial de técnicas atuais de reconstrução 3D geral sem controle de aquisição, as quais têm seu código fonte disponível na internet.

0.2 Objetivos

O presente projeto pretende fazer com que o aluno ganhe experiência com técnicas modernas de reconstrução 3D fotogramétrica, no contexto de uma aplicação bem-definida de preservação de patrimônio. A entrada do sistema deverá ser um conjunto de vídeos realizados por câmeras de baixo custo, ou um conjunto de escaneamentos realizados por scanners à mão de baixo custo baseados em Kinect.

O objetivo concreto do aluno será explorar as tecnologias supracitadas para desenvolver um esquema de escaneamento usando software aberto, câmeras e scanners de baixo custo, representando o estado da arte em reconstrução 3D sem restrições de aquisição. Perguntas fundamentais a serem respondidas são: que nível de detalhe, facilidade e precisão se pode obter usando-se apenas imagens e software aberto? É possível utilizar scanners de baixo custo baseados em Kinect com melhorias significativas em termos de qualidade, conveniência ou tempo de processamento? Quais são as restrições desses sistemas? Seria útil na prática uma reconstrução de curvas para auxiliar na reconstrução de nuvem de pontos e de superfícies densas? Onde o estado da arte deve ser avançado de forma a permitir uma solução mais conveniente e completa para a preservação de patrimônio?

O principal objetivo em termos de pesquisa científica será comparar as diferentes abordagens do estado da arte disponíveis para reconstrução 3D e explicitar suas limitações práticas. O aluno deverá, com o entendimento das abordagens, desenvolver um esquema de aquisição de esculturas que permita ampliar os detalhes ou ajudar a resolver os problemas dos métodos. Com a experiência obtida, o aluno estará pronto para desenvolver pesquisa futura na área de reconstrução 3D, com conhecimento de causa para avaliar direções de pesquisa de efetivo e alto impacto na prática.

0.3 Organização deste manuscrito

O trabalho foi estruturado da seguinte maneira: previamente introduzimos os métodos baseados em pontos de interesse no Capítulo 2, destacando suas funcionalidades. No Capítulo 3 discutimos e aprofundamos o funcionamento de cada algoritmo de reconstrução densa empregados, apresentando e debatendo, comparativamente, pontos à favor e contra; O Capítulo 1 é apresentada a técnica de reconstrução utilizada nos *Kinects*, da Microsoft; Com isso, temos o Capítulo 4, que é dedicado à ferramenta gráfica utilizada para a obtenção dos resultados (VisualSfM) dos algoritmos de reconstrução densa utilizados. Finalmente, apresentamos os resultados e conclusões do trabalho, bem como sugestões para implementações e trabalhos futuros.

0.4 Laser

A técnica de reconstrução baseada em laser é conhecida desde o século passado, pois oferecem uma alta qualidade geométrica de dados, os resultados são em tempo real e requer pouco tempo de captura de dados.

Existem alguns tipos de reconstruções empregando lasers, baseados em volume (ressonância, tomografia, por exemplo 6 ou em superfície (estereoscopia, *time of flight*, luz estruturada) . Neste caso, abordaremos o projeto de escaneamento da escultura de Michelangelo, David, que utiliza escaners baseados em superfícies, mais especificamente, utilizando luz estruturada.

Este projeto tem como motivação avançar a tecnologia de digitalização 3D e criar um acervo digital sobre alguns dos principais artefatos culturais. Foi utilizada uma tecnologia chamada de *rangefinder*, com uma equipe de mais de 30 professores, funcionários e estudantes da Universidade de Stanford desenvolveram algoritmos para combinar imagens de múltiplas gamas e cores, passaram os anos de 1998 e 1999 na Itália escaneando esclturas de Michelangelo.

Pipeline:

O principal componente de *hardware* do sistema é um escaner de triangulação à laser, que é composto por 4 eixos motorizados, utiliza um laser, uma câmera de alcance, uma câmera de cores e uma luz branca, isso tudo acrescido de estruturas para estátuas grandes. O objetivo de um escaner deste porte era capturar marcas menores que um milímetro, das ferramentas utilizadas por Michelangelo em suas esculturas. Para isso foram testadas diversas resoluções, na qual foi decidido um espaçamento Y (ao longo da faixa do laser) de 1/4 mm e uma resolução Z (profundidade) de pelo menos duas vezes este valor. O que resultou em uma visualização de 14 cm de largura (ao longo da faixa do laser) por 14 cm de profundidade. Caso esta resolução fosse menor, as marcas de



Figura 6 - Exemplo de reconstrução à laser utilizando o método baseado em volume.

cinzelão ficariam borradadas e se fosse maior, o conjunto de dados produzido seria gigantesco. Felizmente, a maioria das estátuas feitas por Michelangelo foram esculpidas com um mármore encontrado em Carrara Statuario, uma pedra altamente uniforme, não direcional e constituída de grãos finos. Além disso, com exceção da "Noite", as esculturas não são polidas e cobertas por terra, o que aumenta a dispersão superficial e reduz a abaixo da superfície. Neste contexto, a dispersão abaixo da superfície causa alguns problemas: não se pode assumir que a superfície é Lambertiana ideal (), mudou a forma com que a renderização dos modelos seriam feitos e diminuiu a qualidade de disposição de dados. Calibração: O objetivo de calibrar o aparato era encontrar um mapeamento de coordenadas 2D no seu alcance e cores para coordenadas 3D em um quadro de referência global. Idealmente, este quadro deve ser a estátua (estacionária). Porém não foi rastreado o aparato, ele tornou-se a própria referência. O mapeamento final foi realizado alinhando novas varreduras, com varreduras previamente existentes. Para calibrar qualquer sistema, primeiramente escolhe-se um modelo matemático que se aproxime do comportamento do sistema, então estima-se parâmetros desse modelo medindo o comportamento do sistema. No caso do projeto de David, o modelo matemático natural era um modelo geométrico 3D parametrizado da cabeça digitalizada e do aparato. Se os componentes do sistema forem suficientemente independentes, a calibração pode ser dividida em estágios, correspondente a cada componente do sistema. Por isso o aparato foi construído pensando na

rigidez (independência), pois particionar a calibração em etapas reduz o grau de liberdade em cada etapa, e com isso, o número de medidas necessárias para calibrar este estágio. Em um sistema mecânico, também é reduzido o volume físico total na qual essas medidas de calibração devem ser tomadas. Além disso, uma calibração em etapas é menos suscetível a propagação de erros, pois caso uma calibração falhasse, seria apenas uma parte da calibração e não o sistema como um todo. No projeto de David, a calibração foi dividida em seis etapas distintas:

1. Um mapeamento 2D a partir de coordenadas de *pixels* das imagens da câmera para locais físicos na camada de laser
2. Transformação rígida 2D/3D do sistema de coordenadas da camada do laser para esferas de aço anexadas ao escaner da cabeça
3. Transformação rígida 3D para acomodar o rolamento do escaner da cabeça em 90 *circ* (ao remontá-lo) em relação ao conjunto de inclinação
4. A localização do eixo de rotação de inclinação e o mapeamento não-linear de movimento comandos para ângulos de rotação físicas
5. A localização do eixo de rotação panorâmico e o mapeamento de seus comandos de movimento para ângulos de rotação física
6. A localização do eixo de translação, que também depende de como o conjunto inclinação-panorâmico está montado no braço horizontal

O resultado da calibração pode ser descrito como uma concatenação de seis matrizes 4x4:

$$\begin{bmatrix} \text{translação} \\ \text{horizontal} \end{bmatrix} \begin{bmatrix} \text{rotação} \\ \text{panorâmica} \end{bmatrix} \begin{bmatrix} \text{rotação} \\ \text{de} \\ \text{inclinação} \end{bmatrix} \begin{bmatrix} \text{rotação} \\ \text{de} \\ \text{rolamento} \end{bmatrix} \begin{bmatrix} \text{laser para o} \\ \text{escaner da cabeça} \end{bmatrix} \begin{bmatrix} \text{imagem} \\ \text{para o} \\ \text{laser} \end{bmatrix}$$

Calibração do sistema de cores: Para corrigir a distorção geométrica na câmera de cores, foi fotografado um alvo de calibração planar que possui um certo número de *features* que, por sua vez, foram usados para calcular os parâmetros intrínsecos da câmera. Estão inclusos no modelo dois termos de distorção radial e dois termos de distorção tangencial que tem uma projeção de perspectiva fora do centro e uma escala possivelmente não uniforme (em X e Y)

Para obter um mapeamento da câmera colorida para o escaner da cabeça, o alvo foi escaneado usando o laser e a câmera de alcance. Uma vez que o escaner retornou a intensidade refletida pelo laser, bem como a profundidade, pode-se calcular as coordenadas 3D de cada ponto da *feature*.

Para corrigir os efeitos radiométricos espaciais, incluindo o aspecto de vinheta das lentes, a não uniformidade angular, o declínio da lei quadrada inversa dos holofotes e a não uniformidade espacial na resposta do sensor, foi fotografado um cartão branco sob o holofote e construída uma tabela de correção de intensidade por pixel.

Procedimento de digitalização: Passos para digitalização: Um operador move, interativamente o escaner da cabeça através de uma sequencia de movimentos, definindo os limites de volume a ser escaneado. O volume que pode ser coberto em uma única varredura, foi delimitado por conta de quatro fatores:

- O campo de visão e os limites de movimento do escaner
- A queda na qualidade da varredura com o aumento da obliquidade do laser
- Oclusões, tanto do laser quanto da linha de visão da câmera
- Obstruções físicas, como paredes, estátuas ou o próprio equipamento

Uma vez planejada a varredura, um script de digitalização é executado automaticamente, levando desde alguns minutos, até horas para terminar, dependendo da largura da área a ser coberta.

Alcance da varredura

Primeiramente faz-se o escaneamento da geometria da escultura:

- Alinhamento manual
- ICP – *Iterative Closest Point* para uma câmera existente
- ICP automático para todos os pares sobrepostos
- Relaxação global para espalhar o erro
- Reunir utilizando métodos volumétricos

Após isso, ocorre o escaneamento e processamento das cores da escultura:

- Compensação da iluminação do ambiente
- Descarte de pixels com sombra ou especulares
- Mapeia-se os vértices (uma cor por vértice)
- Correção da irradiação e reflectância difusa

Limitações:

- Inter-reflexões são ignoradas

Tabela 1 - Métricas do projeto de reconstrução da escultura David

Números de objetos escaneados	10 estátuas + 2 edificações + 1,163 fragmentos de mapa
Menor e maior objetos escaneados	1 polegada (fragmentos de mapa) e 23 pés (David)
Resolução espacial dos dados	0.29mm para geometria, 0.125mm para cor
Complexidade do maior conjunto de dados	2 bilhões de polígonos + 7,000 imagens (David)
Tamanho do maior conjunto de dados	32 <i>gigabytes</i> (David)
Quantia total de dados capturados	250 <i>gigabytes</i>
Tamanho do maior escaner	24 pés de altura, 1800 libras de peso
Peso total do equipamento levado para a Itália	4 toneladas
Número de pessoas envolvidas	32 (sem incluir subcontratantes e colaboradores)
Tempo médio para escaneamento	1 semana (exceto o David, que levou 1 mês)
Tempo total de escaneamento	5,000 horas de trabalho
Total de tempo para processamento de dados	4,000 horas de trabalho (até agora)
Custo do projeto	\$2,000,000

- Dispersões subterrâneas são ignoradas
- Tratamento difuso com Lambertiano
- Usa superfícies normais agregadas

O projeto não teve mais nenhum avanço desde o verão de 2004, por falta de financiamento. Como resultado, modelos de alta qualidade só existem do David na resolução de 1,0 mm (56 milhões de triângulos) e São Mateus a 0,25 mm (372 milhões de triângulos). Um modelo também existe para o Atlas em 0,25 mm (aproximadamente 500 milhões de triângulos), mas contém erros de alinhamento. Após 6 anos de trabalho estudantil remunerado e voluntário, existem modelos para cada um dos 1.186 fragmentos. Esses modelos, que totalizam quase 8 bilhões de polígonos, se encontram no próprio site da Universidade de Stanford.

Também foram disponibilizadas algumas métricas sobre este projeto [1](#).

Porém, devido ao seu alto custo com equipamentos, com *softwares* e sem falar na necessidade de estações robustas para armazenamento dos dados e para escaneamento de patrimônios, outras técnicas foram emergindo com o passar dos anos, como a fotogrametria, que será abordada mais tarde neste documento.

1 KINECT

Um componente criado pela Microsoft para fins recreativos (como no XBox, por exemplo), virou uma das mais conhecidas ferramentas de reconstrução 3D no cenário atual. Sua primeira versão (Kinect V1) utiliza uma técnica similar à empregada no projeto da Universidade de Stanford, com luz estruturada, porém, diferentemente dos escaners à laser, o Kinect tem um custo monetário baixo e é acessível a todo público em geral (desde entusiastas, amadores até profissionais da área).

O Kinect V2 é composto de uma câmera RGB-D (Red, Green, Blue e Depth) e utiliza uma projeção de fôtons, é mais robusto que seu antecessor, porém para ambientes fechados e para fins de escaneamento de formas humanas (como esqueleto, músculos, batimento cardíaco, por exemplo). Devido à técnica empregada para reconhecimento 3D (*Time Of Flight*), ele é muito sensível às texturas presentes no objeto. Ou seja, para esculturas com diferentes superfícies com diferentes refletâncias, lambertianos ou especulares, por exemplo, essas diferenças entre superfícies geram problemas nas reconstruções. Além disso, existem outros obstáculos, como a dificuldade onde o fóton emitido pelo emissor rebate em várias superfícies antes de ser detectado pelo sensor de infra-vermelho. E, em comparação ao V1, para fotogrametria de áreas externas, o custo benefício da primeira versão é mais utilizado.

O V1 é composto por 2 câmeras: uma RGB e outra de profundidade e por um projetor IR (*infra-red*) de padrões. Ele funciona da seguinte maneira: o projetor IR de padrões lança uma matriz que é conhecida pelo Kinect, a partir disso, qualquer deformação deste padrão é captada pelas câmeras, o que identifica se um objeto está no alcance dos sensores ou não. A resposta, é composta por 3 *outputs*: uma imagem IR, uma RGB e a profundidade (inversa) da imagem.



Figura 7 - Imagem de um kinect V1 aberto, constituído de uma câmera infra-vermelho (IR), uma câmera RGB e um projetor IR.

Sua principal saída da imagem do Kinect é correspondente à profundidade da cena. Em vez de providenciar uma profundidade Z , ele retorna uma profundidade inversa, D . A profundidade da imagem é construída a partir da triangulação da imagem IR com o projetor e, consequentemente, "carregada" pela imagem IR.



Figura 8 - Exemplo de como é a saída de uma imagem interpretada pelo Kinect, onde cada cor disposta na imagem, corresponde à profundidade ou distância da cena para o Kinect.

Foram realizados alguns experimentos associando fotogrametria com o Kinect V1. Primeiramente, foi executado uma calibração do Kinect para este tipo de reconstrução, onde a partir de experimentos, o sistema foi modelado como 1.

$$q(z) = 2.73z^2 + 0.74z - 0.58 \quad (1)$$

Onde "z" é a profundidade em metros, e "q" a quantização.

O modelo geométrico do Kinect foi criado com um sistema multi-view considerando o RGB, IR e a profundidade.

$$\begin{bmatrix} u \\ v \\ 1 \end{bmatrix} = K \begin{bmatrix} s \\ t \\ 1 \end{bmatrix} \quad (2)$$

$$\begin{bmatrix} s \\ t \\ 1 \end{bmatrix} = \underbrace{(1 + k_1 r^2 + k_2 r^4 + k_5 r^6)}_{\text{distorção radial}} \begin{bmatrix} p \\ q \\ 0 \end{bmatrix} + \underbrace{\begin{bmatrix} 2k_3 pq + k_4(r^2 + 2p^2) \\ 2k_4 pq + k_3(r^2 + 2q^2) \\ 1 \end{bmatrix}}_{\text{distorção tangencial}} \quad (3)$$

$$r^2 = p^2 + q^2, \begin{bmatrix} pz \\ qz \\ z \end{bmatrix} = R(X - C) \quad (4)$$

Onde k_n é o parâmetro de distorção, calibração K , rotação R e centro C .

A profundidade é associada à geometria da câmera IR. que retorna a profundidade inversa ao longo do eixo z.

Os valores de u e de v são dados pela equação 3

$$X_{IR} = \frac{1}{c_1 d + c_0} dis^{-1} \left(K_{IR}^{-1} \begin{bmatrix} x + u_0 \\ y + v_0 \\ 1 \end{bmatrix}, k_{IR} \right) \quad (5)$$

$$u_{RGB} = K_{RGB} dis(R_{RGB}(X_{IR} - C_{RGB}), k_{RGB}) \quad (6)$$

Associamos o sistema de coordenadas do Kinect com a câmera IR e consequentemente, $R_{IR} = I$ (identidade) e $C_{IR} = 0$. O ponto 3D X_{IR} é construído a partir da medição de [x,y,d] de 5 e produz uma imagem RGB de 6.

Em 5, dis é a distorção de 3, k_{IR} e k_{RGB} são, respectivamente, distorção relacionada à IR e à RGB. K_{IR} é a calibração de IR, K_{RGB} é a matriz de calibração. R_{RGB} e C_{RGB} são, a matriz de rotação e de centro da câmera RGB, respectivamente.

A calibração ocorreu usando o mesmo alvo nas câmeras IR e RGB, mesmos pontos 3D, e consequentemente, a posição relativa das câmeras. O sistema de coordenadas global do Kinect faz a posição relativa da câmera igual a R_{RGB} , C_{RGB} . Foi observado que existe um deslocamento entre imagem IR e a imagem da profundidade criada pelo Kinect. Para contornar este problema, uma série de experimentos foram executados, gerando 2.

Tabela 2 - Valores de deslocamentos e sua média

Imagen	1	2	3	4	Média
u_0	2,8	2,9	3,0	3,4	3,0
v_0	3,0	2,7	2,8	3,1	2,9

Foi observado que após a calibração, o Kinect gerava erros residuais complexos, que para compensar esse erro residual, foi criada uma correção em z , onde é subtraído da coordenada Z_{IR} de 5. Para validar essa correção, a correção-z das imagens foram construídas a partir dos resíduos das imagens ímpares e aplicadas nas pares, e o vice-versa. Depois da aplicação da correção-z, a media dos erros diminuiu aproximadamente 0,25mm. Como parâmetro de comparação, foram dispostas 2 câmeras diferentes, no mesmo ambiente do Kinect.

Kinect com SfM:

A figura a seguir compara a superfície 3D de nuvem de pontos com uma com kinect. O resultado é tão bom quanto ao mais acurado multi-view stereo.

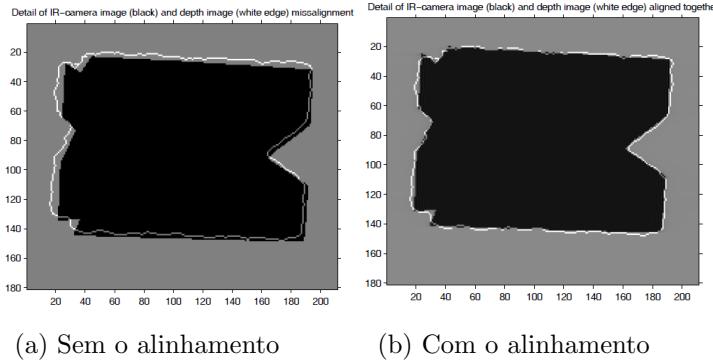


Figura 9 - Representação visual do acerto do deslocamento. A parte em preto é a imagem IR e o contorno em branco é a imagem de profundidade do alvo.

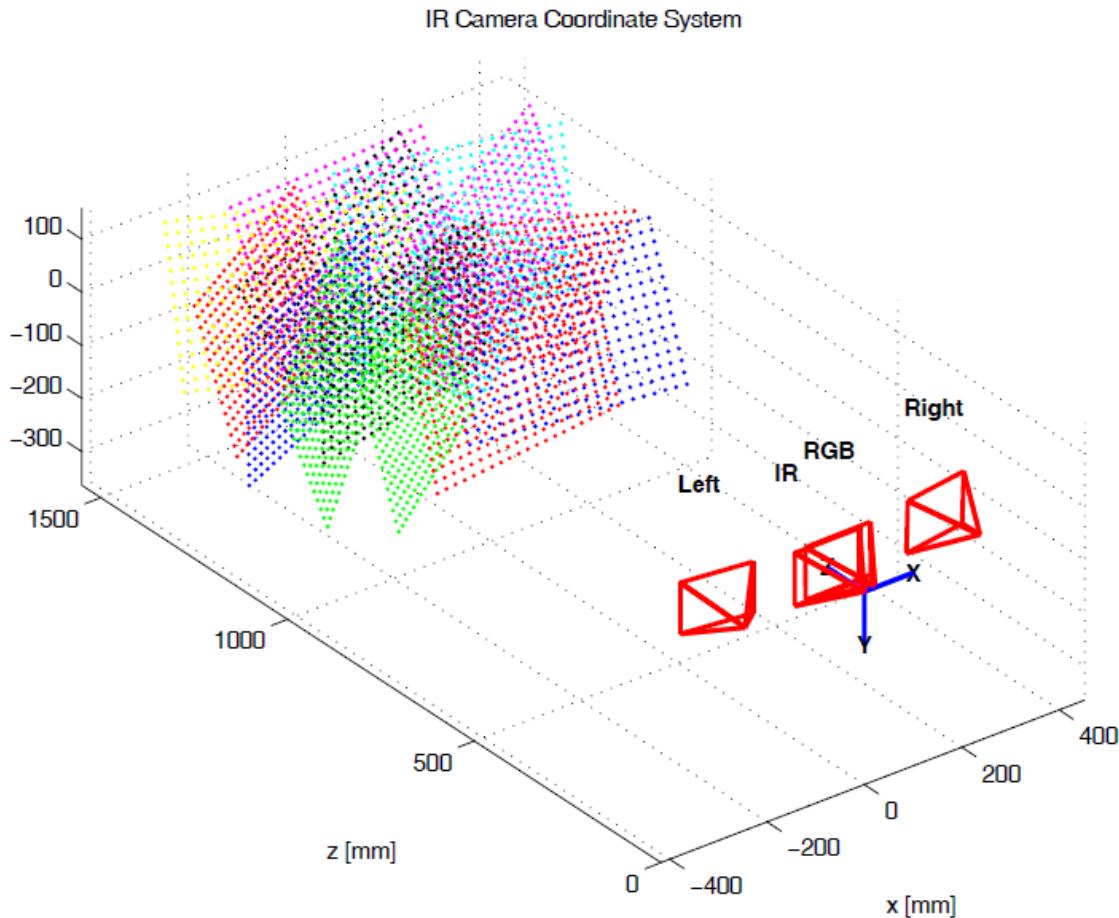


Figura 10 - Posição e orientação do Kinect (com as câmeras IR e RGB) e o par estéreo SLR (*Left*, *Right*) em conjunto com pontos de calibração 3D reconstruídos em alvos de calibração planar.

O kinect tem a capacidade e, com o procedimento de calibração, é possível combiná-lo com SfM e multi-view stereo, o que abre uma nova área de aplicação.

Quanto a qualidade da reconstrução de multi-view, o kinect ficou melhor que o SR-4000 e perto do 3.5M SLR Stereo 3.

Tabela 3 - Resultados dos testes executados no ambiente descrito anteriormente

Método	Erro geométrico e [mm]		
	$\mu(e)$	$\sigma(e)$	$\max(e)$
SLR Stereo	1,57	1,15	7,38
Kinect	2,39	1,67	8,64
SR-4000	27,62	18,20	133,85

Existem alguns *softwares* para utilizar o Kinect como uma ferramenta de reconstrução 3D e a maioria deles são bem acessíveis. Uma delas é o *Skanect* que tem a versão gratuita onde é possível fazer escaneamentos básicos e a versão paga, que possibilita uma configuração maior, como por exemplo, a delimitação do objeto que será reconstruído, exportar o arquivo em diferentes formatos (*.PLY*; *.OBJ*: formato para exportação para programas que melhoram o modelo gerado (blender ou sculptris, por exemplo). E escolher o numero de faces a ser exportado; *STL*: próprio para a impressora 3D (software cura); *VRML*: salva também as cores do modelo.)

Entretanto, uma desvantagem que diminui a aplicabilidade do Kinect é que ele foi projetado para funcionar bem em espaços fechados, com detecção de formas humanas e movimentações. Ou seja, numa aplicação *in situ* ele já não funcionaria muito bem, pois além de não conseguir projetar os detalhes em alta definição de uma escultura, ele necessita de uma fonte de energia externa, o que dificulta a acessibilidade do mesmo e como gera uma reconstrução em tempo real (não tem uma forma de salvar em *cache* ou internamente), ele precisa estar ligado a um computador para fazer o escaneamento.

2 PONTOS DE INTERESSE

A reconstrução 3D pelo método da estrutura do movimento, ou *Structure from Motion (SfM)*. Tem como base a utilização de pontos de interesse (*features*), que são pontos ou áreas em comum entre as imagens usadas na reconstrução. Para encontrar estes pontos, diferentes algoritmos são empregados.

2.1 SIFT – *Scale Invariant Feature Transform*

Primeiramente, utiliza-se o SIFT (algoritmo de detecção de pontos de interesse, invariante à escala e à transformações, como rotação, translação e iluminação da imagem, por exemplo). O algoritmo pode ser dividido em cinco etapas, das quais:

- Detecção de espaço-escala extremos – *Scale-space Extrema Detection*
- Localização de pontos-chaves – *Keypoint Localization*
- Atribuição de orientação – *Orientation Assignment*
- Descritor de pontos-chaves – *Keypoint Descriptor*
- Combinação de pontos-chaves – *Keypoint Matching*

2.1.1 Detecção de espaço-escala extremos

Em casos com cantos pequenos, a detecção funciona bem. Porém, raramente utilizaremos a mesma janela para detectar pontos-chaves em imagens com diferentes escalas, pois utilizamos imagens grandes e, consequentemente, cantos grandes. Para isso, precisamos de janelas grandes também.

Para resolver este problema, o filtro de escala-espacó é usado: o Laplaciano de Gaussiano (*Laplacian of Gaussian* – LoG). O LoG atua como um detector de partículas em diferentes tamanhos σ . (Onde σ é o parâmetro de escala). Por exemplo, o núcleo gaussiano com σ baixo, tem como resposta um alto valor para um canto pequeno. Enquanto um núcleo gaussiano com alto σ , se encaixa bem para um canto maior. Com esta lógica, podemos encontrar um máximo local através da escala e o espaço, o que nos fornece uma lista de $(x, y\sigma)$, o que significa que existe um ponto-chave em potencial, com o par (x, y) na escala σ .

Porém, como o LoG é um pouco custoso, computacionalmente. O SIFT utiliza um algoritmo aproximado do LoG, o DoG (Diferença de Gaussianos – *Difference of Gaussians*). O DoG é a diferença de um filtro Gaussiano de uma imagem, com dois valores diferentes de escala σ .

Uma aplicação prática do filtro DoG é a sequência de imagens a seguir:

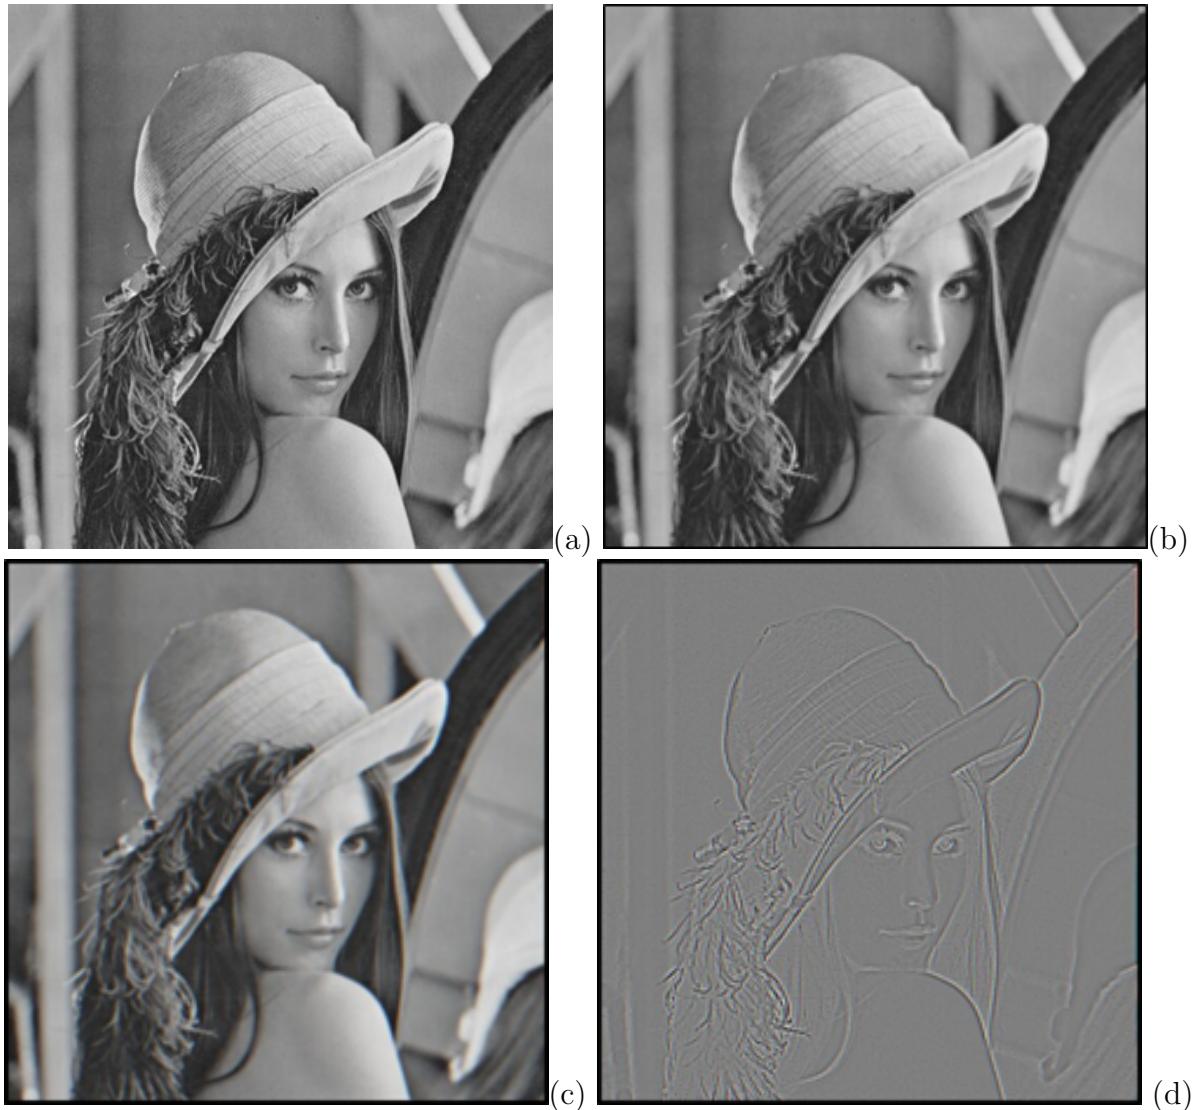


Figura 11 - É aplicado um filtro gaussiano na imagem original (a), com $\sigma = 1$, tendo como resultado a imagem (b). Um outro filtro gaussiano é usado, porém, neste caso, o $\sigma = 2$ (c). Após isso, subtrai-se (b) de (c), obtendo o filtro DoG (d).

Uma vez que o DoG é aplicado, as imagens são utilizadas com o espaço e escala extremos. Por exemplo, na imagem 12, um pixel é comparado com seus 8 vizinhos, assim como comparado com os 9 pixels na próxima escala e os 9 pixels na escala anterior. Se esse pixel é um local extremo, ele é um ponto-chave em potencial. Isto é, este ponto-chave é melhor representado nesta escala.

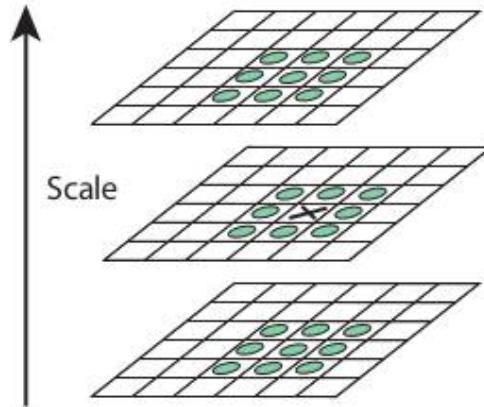


Figura 12 - Exemplo de funcionamento de detecção de espaço-escala extrema

No caso, as funções ficariam da seguinte forma:

$$g_\sigma(x) = \frac{1}{2\pi\sigma^2} e^{-\frac{1}{2}\frac{x^T x}{\sigma^2}} \quad (7)$$

$$I_\sigma = g_\sigma * I, \sigma >= 0 \quad (8)$$

$$\nabla^2 g_\sigma(x) \quad (9)$$

$$DoG_\sigma(o, s) = I_\sigma(o, s + 1) - I_\sigma(o, s) \quad (10)$$

Onde 7 é a função padrão do operador gaussiano (núcleo), a equação 9 é o operador LoG, 10 é o operador DoG e ∇^2 é o operador Laplaciano.

2.1.2 Localização de pontos-chaves

A localização dos pontos extremos pode cair em um extremo local e não global. Logo, após a utilização do DoG e com os pontos-chaves em potencial localizados, eles precisam ser refinados para melhorar o resultado. Para isso, são utilizadas Séries de Taylor na escala e no espaço, e, se a intensidade nesse extremo é menor que o valor limite, este é rejeitado. Os *frames* do SIFT (pontos-chaves) são extraídos baseados nos

extremos locais (picos) a partir do DoG. Numericamente, extremos locais são elementos que possuem um menor (ou maior) valor em uma vizinhança em um espaço 3x3x3 (em escala e espaço). Depois de extraídos, estes pontos são interpolados quadraticamente (este passo é muito importante, especialmente nas escalas de menor resolução, para ter uma localização precisa do ponto-chave na resolução completa). Finalmente, eles são filtrados para eliminar respostas de baixo contraste ou respostas próximas as bordas.

Picos que são pequenos, na maior parte das vezes são gerados a partir de ruídos e necessitam ser descartados também. Isso é feito com uma comparação de valor absoluto do DoG no pico com o valor do pico limite e é descartado caso este valor é menor que o limite.

Para eliminar respostas em bordas, normalmente os picos mais rasos ou horizontais, são gerados por bordas e não possuem características estáveis, portanto estes picos precisam ser removidos. Para isso, dado um pico (x, y, σ) , o algoritmo avalia a matriz Hessiana (x,y) do DoG na escala σ . Então é computado um valor para esta equação (11):

$$v = \frac{(T_r D(x, y, \sigma))^2}{\text{Det } D(x, y, \sigma)} \quad (11)$$

Onde, T_r é o traço, ou seja, $T_r(H) = D_{xx} + D_{yy}$ e a matriz D é do tipo

$$D = \begin{bmatrix} \frac{\partial^2 \text{DoG}}{\partial x^2} & \frac{\partial^2 \text{DoG}}{\partial x \partial y} \\ \frac{\partial^2 \text{DoG}}{\partial x \partial y} & \frac{\partial^2 \text{DoG}}{\partial y^2} \end{bmatrix}$$

No caso, v possui um valor mínimo (igual a 4) quando os autovalores da Jacobiana são iguais (pico curvado) e aumentam à medida que um dos autovalores aumenta e os outros permanecem baixos. Os picos são retidos se $v < \frac{(t_e+1)(t_e+1)}{t_e}$, onde t_e é o limite da borda.

2.1.3 Atribuição de orientação

Agora, uma orientação é atribuída a cada ponto-chave para obter a invariância à rotação da imagem. Uma vizinhança é obtida, dependente da escala, do gradiente da magnitude 12 e da direção 13 (usando diferenças finitas), ao redor da localização do ponto-chave.

$$m(x, y) = \sqrt{(L(x+1, y) - L(x-1, y))^2 + (L(x, y+1) - L(x, y-1))^2} \quad (12)$$

$$\theta = \tan^{-1} \left(\frac{(L(x, y + 1) - L(x, y - 1))}{(L(x + 1, y) - L(x - 1, y))} \right) \quad (13)$$

Então, um histograma de 36 orientações (*bins*) cobrindo 360 graus é criado. Onde ele é ponderado pelo gradiente da magnitude e por uma janela Gaussiana circular onde σ vale 1.5 em relação à escala do ponto-chave 13.

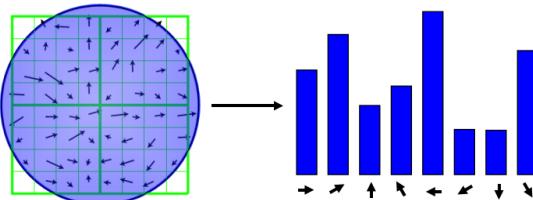


Figura 13 - Exemplo do resultado obtido do histograma orientado

O ponto mais do histograma é obtido e qualquer pico acima de 80% é considerado no cálculo da orientação. Pontos-chaves são criados com a mesma localização e escala, mas em diferentes direções, o que contribui para a estabilidade da correspondência.

2.1.4 Descriptor de pontos-chaves

Com os pontos-chaves criados a partir do histograma orientado, cria-se agora o descriptor de pontos-chaves.

Uma vizinhança 16x16 ao redor do ponto-chave é escolhida e esta mesma vizinhança é dividida em 16 sub-blocos 4x4. Para cada bloco, um histograma orientado com 8 *bin* é criado. Logo, temos 128 valores válidos de *bin*. Esses valores são representados em forma de vetor para expressar o descriptor de pontos-chaves 14.

Além disso, são tomadas algumas medidas para deixar o descriptor mais robusto, como, por exemplo, invariante à luminosidade, rotação, etc.

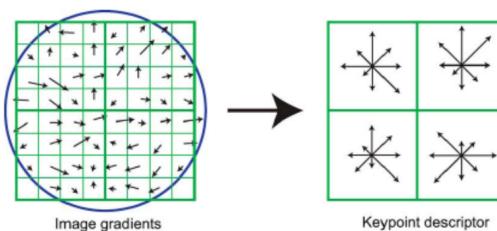


Figura 14 - Exemplo de um descriptor de pontos-chaves, com uma matriz 2x2 e uma região 8x8

2.1.5 Combinação de pontos-chaves

Pontos-chaves entre duas imagens são combinados a partir da identificação da vizinhança mais próxima. Mas, em alguns casos, a segunda combinação mais próxima pode ser parecida com a primeira. Isso se dá por ruídos presentes nas imagens ou algo assim.

Nesse caso, a razão da distância mais próxima para a segunda distância mais próxima é utilizada. Se essa razão for maior que 0.8, essa combinação é descartada. Esse método elimina cerca de 90% de combinações falsas, enquanto descarta apenas cerca de 5% de combinações corretas.

2.2 Triangulação – *Full pairwise image matching*

Com os pontos de interesse (*features*) extraídos, podemos agora fazer a triangulação entre os pontos das imagens.

A triangulação nada mais é que uma estimativa de um ponto em 3 dimensões, dado pelo menos duas câmeras conhecidas, onde, cada câmera com a projeção do *feature* correspondente àquele ponto 3D 15.

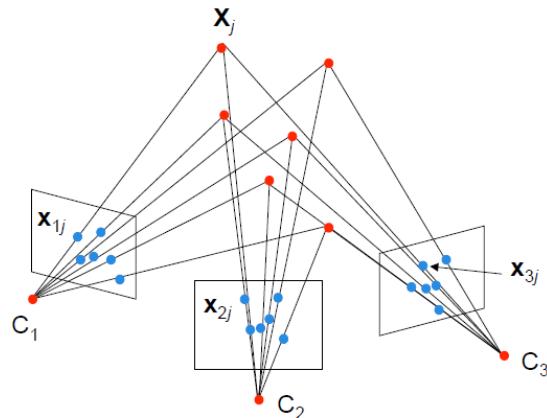


Figura 15 - Uma triangulação utilizando um ponto qualquer, X_j . Onde cada câmera C_1, C_2, C_3 possui um *feature* correspondente a cada uma delas, respectivamente, X_{1j}, X_{2j}, X_{3j} .

Infelizmente, não é tão simples assim. Existem muitos fatores que contribuem para aumentar a dificuldade da triangulação: ruídos, posição das câmeras, o feixe das projeções não se encontram no mesmo ponto 3D, não se tem informação da projeções nas câmeras, etc. Entretanto, existem diversos algoritmos para resolução de cada um dos problemas enfrentados.

Como o foco deste manuscrito está no *software* de reconstrução VisualSfM, atentamos apenas ao algoritmo utilizado pelo mesmo. Neste caso, ele utiliza um algoritmo

chamado *Bundle Adjustment*.

Este algoritmo é utilizado para minimizar o erro geométrico proveniente da reprojeção da triangulação [16](#). Dentro dele, existe a técnica de resolução de problemas não-lineares chamada Levenberg-Marquardt.

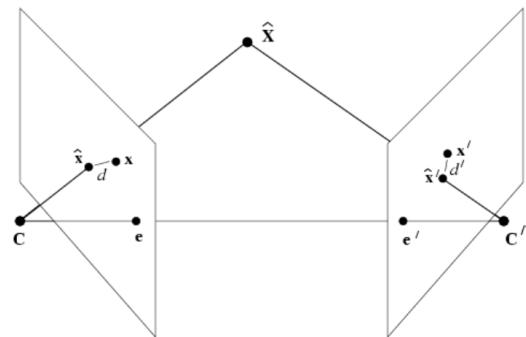


Figura 16 - Erro proveniente da reprojeção, onde os pontos x e x' estão mais próximos das medidas reais da imagem.

3 RECONSTRUÇÃO DENSA

3.1 Introdução

3.2 MVE

Um dos algoritmos utilizados para a técnica de reconstrução densa é o MVE – *Multi-View Environment*, feito por Simon Fuhrmann, Fabian Langguth e Michael Goesele. Este algoritmo utiliza fotos e produz uma malha triangular superficial como resultado. Diferente das reconstruções baseadas nas geometria das imagens, o MVE é focado na reconstrução multi-escala, um quesito importante na reconstrução de esculturas e acervo cultural. Portanto, com esta técnica é possível reconstruir grandes volumes de dados, contendo regiões detalhadas em alta resolução, em comparação com o resto da cena. O sistema ainda possui uma interface gráfica para o uma reconstrução baseada no SfM, amigável ao usuário (UMVE), onde permite a visualização e inspeção das imagens, mapas de profundidade e renderizar cenas e malhas 3D.

Sua base de operação é basicamente [17](#):

1. Estrutura da formação – *Structure-from-Motion* (SfM)

- Reconstrói os parâmetros da câmera (posição e orientação) e seus dados de calibração (distância focal e distorção radial), encontrando correspondências esparsas mas estáveis entre as imagens. (Já foi abordado em outra seção deste manuscrito).

2. Múltiplas visões estéreo – *Multi-View Stereo* (MVS)

- Utiliza a posição estimada das câmeras, encontrando as correspondências visuais nas imagens. Estas correspondências são trianguladas, produzindo a informação 3D, e, consequentemente a reconstrução 3D densa.

3. Reconstrução de superfícies – Surface Reconstruction

- Tem como entrada uma densa nuvem de pontos, ou mapas de profundidade individuais. Produz uma malha superficial globalmente consistente.

Como não existem muitas opções para algoritmos de SfM, o MVE permite a utilização de *softwares* externos como o *Bundler* ou o próprio *VisualSfM*.

Uma vez com o passo do SfM feito, partimos para o MVS. Com os parâmetros de câmera conhecidos, a reconstrução densa geométrica é feita. Existem diversos algoritmos para a reconstrução densa, o MVE no caso, utiliza um algoritmo próprio, feito por um

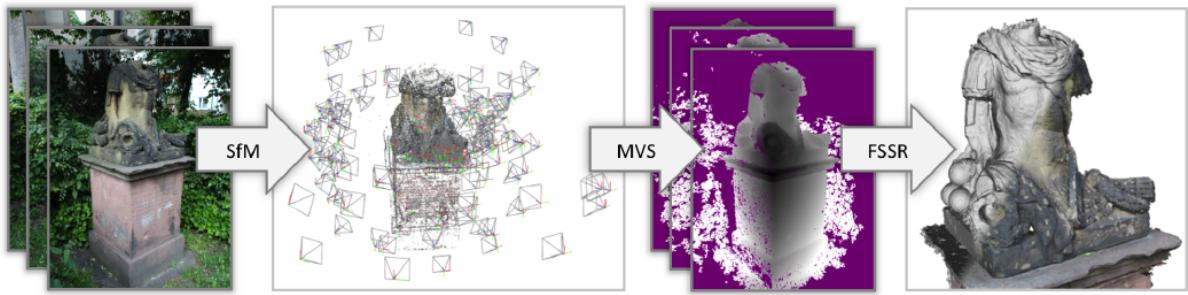


Figura 17 - Funcionamento do MVE. Começando com múltiplas imagens, técnicas SfM são empregadas para reconstruir os parâmetros das câmeras e os conjuntos de pontos esparsos. Mapas de profundidade são computados para cada imagem usando o MVS. Finalmente, uma malha colorida é extraída da união de todos os mapas de profundidade usando um algoritmo de aproximações de reconstruções de superfícies (FSSR).

de seus criadores, Michael Goesele (*Multi-View Stereo for Community Photo Collections approach*), que reconstrói um mapa de profundidade para cada foto.

Embora abordagens baseadas em mapeamentos de profundidade produzirem uma grande quantidade de redundância, (isso se dá por causa das inúmeras fotos que são sobrepostas e possuírem partes similares da mesma cena), este algoritmo é altamente escalável para grandes cenas, pois apenas um pequeno conjunto de fotos vizinhas é necessário para a reconstrução. Outra vantagem da utilização dos mapas de profundidade como representação intermediária é que a geometria é parametrizada em seu domínio natural, e os dados por foto (como a cor, por exemplo) estão diretamente acessíveis nas imagens.

A redundância excessiva nos mapas de profundidade pode ser pesado. Não com relação ao armazenamento, mas na questão do processamento computacional exigido nos mapas de profundidade. Porém, esta abordagem foi capaz de produzir uma geometria detalhada e superar o ruído nos mapas de profundidades individuais.

3.2.1 Guia de reconstrução com o MVE

Um bom conjunto de dados é gerado se algumas regras simples forem seguidas:

- Para que o algoritmo do MVS consiga fazer uma triangulação com qualquer posição 3D, o conjunto de dados terá que ter, no mínimo, cinco fotos.
- As fotos devem ser tiradas com uma boa quantidade de sobreposição. A menos que o conjunto de dados se torne muito grande, uma grande quantidade de fotos não prejudicará a qualidade. Mas terá uma compensação do sistema, no que diz respeito à qualidade e desempenho.

- Para a triangulação funcionar, é necessário que tenha o efeito de paralaxe [18](#) (Aparente mudança na posição do objeto). Ou seja, é interessante que o conjunto de imagens seja duplicado.
- A câmera deverá ser reposicionada, de preferência.

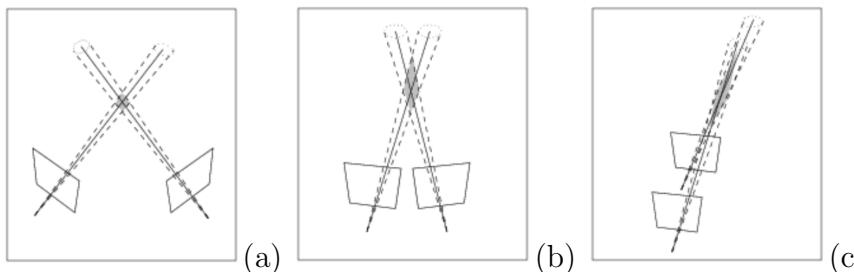


Figura 18 - Caso o espaçamento entre as câmeras seja grande, a informação extraída das imagens em comum será menor (a). Se a angulação do efeito de paralaxe seja baixa, terá a mesma informação sobre um ponto em questão (c). Ou seja utilizando ou (a), ou (c). Pode ser que a reconstrução fique incerta. Para que o efeito paralaxe tenha maior proveito das imagens das câmeras, é necessário que as câmeras estejam dispostas como (b), conseguindo extrair uma boa quantidade e qualidade de informações do ponto.

Criando uma cena: Uma visualização contém dados por exibição (como imagens, mapas de profundidade ou outros dados). Uma cena é uma coleção de visualizações, que constitui um conjunto de dados. Uma nova cena pode ser criada utilizando a interface gráfica UMVE, ou por linha de comando (*makescene*).

Tecnicamente, a cena é criada como um diretório no sistema de arquivos (com o nome do conjunto de dados). Este, por sua vez, contém outro diretório (*views*), com todas as visualizações guardadas com uma extensão de arquivos em .MVE.

Criar uma nova cena, criará apenas o diretório (*views*) vazio. A importação de fotos criará arquivos .MVE para cada foto. Esse processo importará meta-dados provenientes das imagens (*tags EXIF*), que é necessário para estimar a distância focal para cada foto. Caso estes meta-dados não estejam disponíveis, uma distância focal padrão é assumida pelo sistema, porém se essa distância adotada for uma péssima suposição, com relação ao conjunto de dados utilizado, pode vir a acontecer erros no SfM.

Reconstrução SfM: Pode ser configurada e iniciada usando a interface gráfica UMVE ou por linha de comando (*sfmrecon*). A interface guia através da detecção de *features*, combinação emparelhada (*pairwise matching*) e uso incremental do SfM. Que, por sua vez, a reconstrução SfM começa a partir de um par inicial, e adiciona, de forma incremental, mais vistas à reconstrução [20](#).

Múltiplas visões estéreo – *Multi-View Stereo* (MVS): Usando as imagens junto com os parâmetros obtidos das câmeras, é possível reconstruir a geometria densa utilizando o

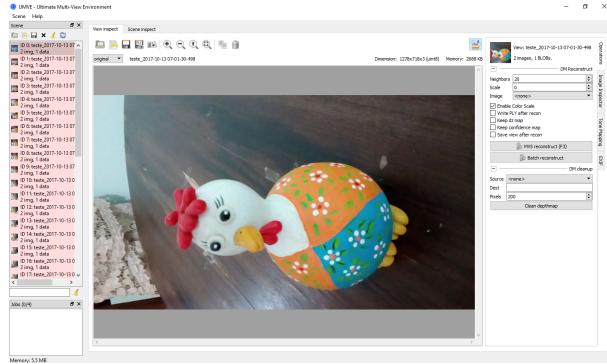


Figura 19 - Interface gráfica (UMVE)

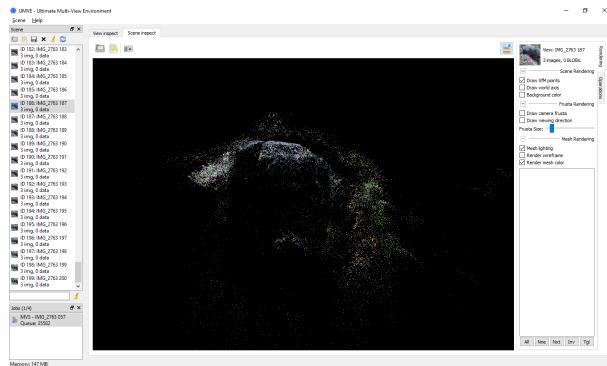


Figura 20 - Reconstrução baseada em nuvem de pontos gerada a partir da reconstrução SfM.

MVS. Isso pode ser feito utilizando a interface gráfica (UMVE) ou por linha de comando (*dmrecon*).

O parâmetro mais importante é o nível de resolução em que os mapas de profundidade são reconstruídos: Caso seja nível 0 (ou L0), a reconstrução é feita usando o tamanho original das imagens. Se for nível 1 (ou L1), a reconstrução corresponde a metade do tamanho (um quarto dos números de pixels), e assim por diante.

Com a resolução das câmeras atuais, uma reconstrução L0 é raramente usada, pois geram mapas de profundidade mais dispersos com um custo computacional elevado, o que acarreta em dificuldades para encontrar as correspondências densas das imagens. Geralmente utiliza-se o L2, pois o processo é mais rápido, gerando mapas de profundidades completos, já que utiliza imagens menores [21](#).

Reconstrução de superfícies – Surface Reconstruction: Utiliza-se a linha de comando *scene2pet*, que combina todos os mapas de profundidade em uma única e grande nuvem de pontos. Nesta fase, um valor de escala é atribuído a cada ponto, que indica o tamanho atual da região da superfície na qual o ponto foi mensurado. Esta informação adicional permite o uso de várias propriedades benéficas usando a abordagem de reconstrução da superfície FSSR. A seguir, as ferramentas FSSR calculam uma representação volumétrica de escala múltipla a partir dos pontos (na qual não precisa de nenhum ajuste



Figura 21 - Uma imagem de entrada (à esquerda) e sua correspondência em mapas de profundidade (à direita), onde a parte roxa significa que não foi encontrada nenhuma malha naquela região.

de parâmetros explícitos) e uma malha final é extraída. Esta malha pode parecer desordenada devido à regiões não confiáveis e à componentes isolados, oriundos de medidas imprecisas. Logo, a malha é limpa, retirando pequenos componentes isolados e regiões não confiáveis da superfície.

Experiência com o MVE: A utilização do *software* é bem intuitiva, seja por linha de comando ou pela interface gráfica (neste modo, fica mais fácil visualizar cada etapa da reconstrução). Amplamente configurável, podendo escolher a vizinhança, escala, manter o mapa de profundidade, ver os dados *EXIF* de cada imagem, dentre outras configurações.

Entretanto, para a aplicação proposta neste projeto, não é muito interessante, visto que ele utiliza a informação das câmeras (*EXIF*) e das imagens e, como as imagens empregadas na reconstrução são, tecnicamente, vídeos cortados em determinados *frames*, não é possível obter a informação das câmeras [22](#), logo o *software* não tem tanta aplicabilidade neste caso, pois recai no problema dos parâmetros padrões adotados para as câmeras não serem bons o suficiente para estes conjuntos de dados, a menos que sejam tiradas fotos sequenciais de alguma escultura ou objeto que se deseja gerar a reconstrução densa, pois dessa forma, as informações necessárias das câmeras estarão armazenadas.

Com isso em mente, foi gerada uma reconstrução de um vídeo gravado de uma escultura no Jardim do Nêgo. O vídeo foi cortado em *frames* onde foram geradas 200 imagens base.

A partir disso, foi executado, todos os passos de uma reconstrução utilizando o MVE, de forma que, foram utilizadas as duas opções, tanto por linha de comando, quanto pela interface gráfica (UMVE).

Pela interface gráfica, o processo todo de reconstrução foi rápido (cerca de 30 minutos) [23](#), ao passo que por linha de comando, levou cerca de 11 horas e 30 minutos.

O UMVE não sinaliza quando o processo em execução termina, então, a explicação para essa discrepância no tempo é devido à execução de outro comando, sobrepondo o

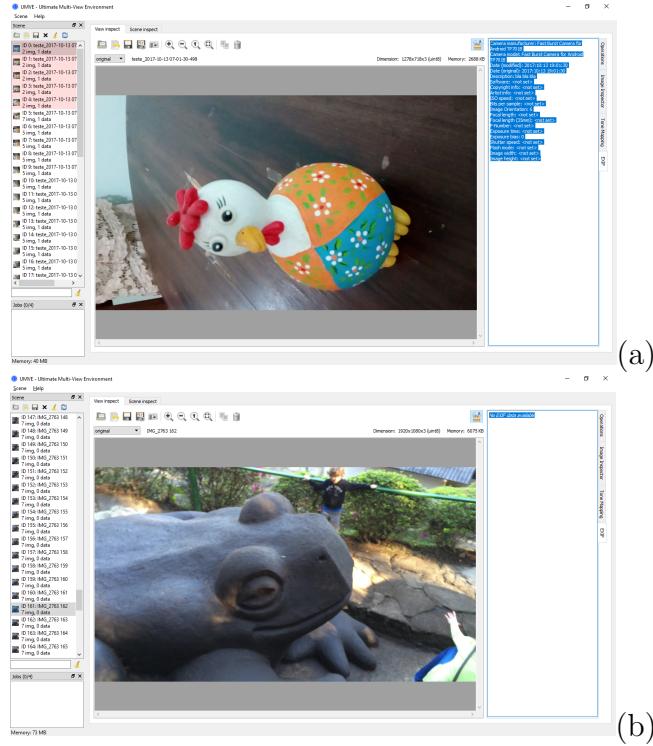


Figura 22 - A figura (a) é um exemplo onde a imagem possui dados na extensão *EXIF* (destacado em azul). Ao passo que a figura (b) é um frame de um vídeo, que não possui os dados das câmeras (destacado em azul).

que já estava sendo executado, sem deixar terminá-lo.

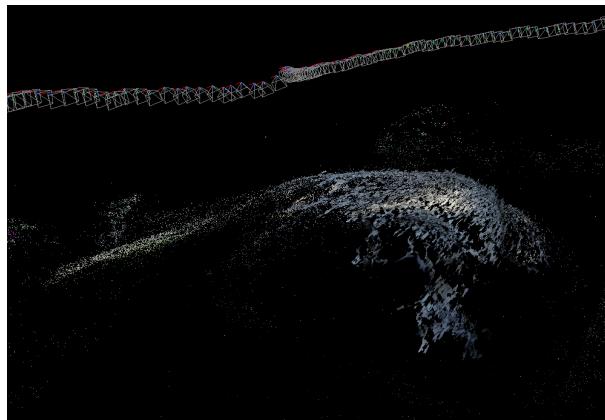


Figura 23 - Final da reconstrução via UMVE, percebe-se que alguns pontos não foram considerados, tendo como resultado uma "nuvem de pontos" mais densa, basicamente.

Na reconstrução por linha de comando também é possível visualizar em qual etapa da execução o algoritmo está [24](#), configurar alguns parâmetros e inclusive mostrar a porcentagem de progresso do comando. Foram executados os comandos declarados nesta seção. O *sfmrecon* demorou cerca de 1 minuto e meio [25](#).



Figura 24 - Processos dentro do comando *sfmrecon*, onde (a) estão sendo detectadas as *features* do conjunto de imagens. Em (b) está computado o *pairwise matching* e em (c) está no processo do *Bundle Adjustment*, usando condições-padrão para as câmeras.

O próximo comando, *dmrecon* demorou cerca de 4 horas, usando como configuração um nível L2, com 20 vizinhos [26](#). Usando um nível L0, o algoritmo rodou durante 6 horas aproximadamente e foi cancelado devido à demora na execução.

Usando o *scene2pet*, é necessário em qual nível estamos reconstruindo e também uma saída válida. Por exemplo: ”*scene2pset.exe -Fnivel cena output*”. Onde o nível poderá ser um 0 (-F0), 1 (-F1) e assim por diante, a cena é o *input* e o *output* é um arquivo de extensão configurável, neste caso *.ply* [27](#). Este comando foi rápido, demorou cerca de 10 minutos, levando em conta todos os níveis.

Para juntar todos os níveis do *scene2pet*, foi usado o *fssrecon*, que gera uma única reconstrução. Este processo demorou bastante, cerca de 7 horas [28](#). Que teve como resultado a malha [29](#).

```

Selected Prompt de Comando
Rejected 201 tracks with large error.
Rejected 70 tracks behind cameras.
Rejected 674 tracks with unstable angle.
Deleted 0 of 23278 tracks (0.00%) above a threshold of 0.0159941.
Skipping full bundle adjustment (skipping 5 views).

Adding next view ID 65 (143 of 200)...
Collected 12 2D-3D correspondences.
Selected 10 2D-3D correspondences inliers (83%).
Reconstructed camera 65 with focal length 1
Running single camera bundle adjustment...
PBA: MSE 5.00345e-07 -> 5.00159e-07 ($), 3 iter, 327ms.
Triangulated 1 new tracks, rejected 945 bad tracks.
Rejected 201 tracks with large error.
Rejected 70 tracks behind cameras.
Rejected 674 tracks with unstable angle.
Deleted 0 of 23279 tracks (0.00%) above a threshold of 0.0159941.
Skipping full bundle adjustment (skipping 5 views).
SFM reconstruction finished.
Running final bundle adjustment...
PBA: MSE 5.0055e-07 -> 4.9486e-07 ($), 26 iter, 75509ms.
Camera 56, focal length: 0.935861 -> 0.935935, distortion: -0.0506553
Camera 57, focal length: 0.996948 -> 0.938748, distortion: -0.0554248
Camera 58, focal length: 0.955135 -> 0.953855, distortion: -0.0439305
Camera 59, focal length: 0.957488 -> 0.956769, distortion: -0.0595935
Camera 60, focal length: 0.963651 -> 0.964237, distortion: -0.0612002
Camera 61, focal length: 0.955873 -> 0.956757, distortion: -0.076264
Camera 62, focal length: 0.955131 -> 0.956728, distortion: -0.08512
Camera 63, focal length: 0.960946 -> 0.963876, distortion: -0.0631805
Camera 64, focal length: 0.970816 -> 0.975268, distortion: -0.0136306

```

Figura 25 - Término do comando *sfmrecon*, onde demorou cerca de 1 minuto e meio (75509 milisegundos).

```

Selected Prompt de Comando
Count: 178570 filled: 67000 Queue: 22340
Count: 221173 filled: 75000 Queue: 6875
Count: 174699 filled: 68000 Queue: 22135
Count: 178779 filled: 69000 Queue: 21589
Count: 228433 filled: 76000 Queue: 3431
Count: 183540 filled: 70000 Queue: 20540
Filled 76658 pixels, i.e. 59.1 %.
MVS took 204 seconds.
Count: 187961 filled: 71000 Queue: 20256
Count: 191974 filled: 72000 Queue: 20095
Count: 196084 filled: 73000 Queue: 19739
Count: 202042 filled: 74000 Queue: 17974
Count: 206923 filled: 75000 Queue: 17279
Count: 210777 filled: 76000 Queue: 16925
Count: 216323 filled: 77000 Queue: 15475
Count: 221385 filled: 78000 Queue: 13979
Count: 226689 filled: 79000 Queue: 12274
Count: 234778 filled: 80000 Queue: 10341
Count: 248287 filled: 81000 Queue: 8352
Count: 248127 filled: 82000 Queue: 4630
Count: 254555 filled: 83000 Queue: 3094
Filled 83611 pixels, i.e. 64.5 %.
MVS took 216 seconds.
Reconstruction took 14502576ms.
Saving views back to disc...
Saving views to MVE files... done.

C:\Users\Desktop\Documents\UERJ\mve-20160517-win64>
C:\Users\Desktop\Documents\UERJ\mve-20160517-win64>
```

Figura 26 - Término do comando *dmrecon*, onde demorou cerca de 4 horas (14502576 milisegundos).

Finalmente, basta limpar a malha atual com o comando *meshclean*, onde foi obtido o resultado ??.

```

Prompt de Comando - fssrecon pset_L0.ply pset_L1.ply pset_L2.ply pset_L3.ply final-output-mesh.ply

Processing view "IMG_2763_190" (with colors)...
Processing view "IMG_2763_191" (with colors)...
Processing view "IMG_2763_192" (with colors)...
Processing view "IMG_2763_194" (with colors)...
Processing view "IMG_2763_193" (with colors)...
Processing view "IMG_2763_195" (with colors)...
Processing view "IMG_2763_196" (with colors)...
Processing view "IMG_2763_197" (with colors)...
Processing view "IMG_2763_198" (with colors)...
Processing view "IMG_2763_199" (with colors)...
Processing view "IMG_2763_200" (with colors)...
Writing final point set (13543640 points)...
Writing PLY file (13543640 verts, with colors, with normals, with confidences, with values, 0 faces, with colors)... done.

C:\Users\Desktop\Documents\UERJ\mve-20160517-win64>scene2pet -F3 teste pset_L3.ply
MVE Scene to Pointset (built on May 17 2016, 12:36:22)
Using depthmap "depth-L3" and color image "undist-L3"
Initializing scene with 200 views...
Initialized 200 views (max ID is 199), took 104ms.
Writing final point set (0 points)...
Writing PLY file (0 verts, with colors, with normals, with confidences, with values, 0 faces, with colors)... done.

C:\Users\Desktop\Documents\UERJ\mve-20160517-win64>fssrecon pset_L0.ply pset_L1.ply pset_L2.ply pset_L3.ply final-output-mesh.ply
Floating Scale Surface Reconstruction (built on May 17 2016, 12:36:32)
Loading: pset_L0.ply...
Loading samples took 0ms.
Loading: pset_L1.ply...

```

Figura 27 - Execução dos comandos *scene2pet*, nos níveis -F0, -F1, -F2 e -F3.

```

Selecionar Prompt de Comando

Loading: pset_L3.ply...
Loading samples took 0ms.
Limiting octree to 20 levels...
Octree contains 19019463 samples in 5267793 nodes on 16 levels.
    Level 7: 3 samples
    Level 8: 1330 samples
    Level 9: 34013 samples
    Level 10: 509845 samples
    Level 11: 3294553 samples
    Level 12: 8815390 samples
    Level 13: 6128926 samples
    Level 14: 235361 samples
    Level 15: 42 samples
Computing sampling of the implicit function...
Sampling the implicit function at 6796595 positions, fetch a beer...
Processing voxel 6796595 (100.00%, 421:19, ETA 307445734561825:51)...
Generated 6796595 voxels, took 25292543ms.
Extracting isosurface...
    Sanity-checking input data... took 430 ms.
    Computing Marching Cubes indices... took 8041 ms.
    Computing isovertices... took 14438 ms.
    Computing isopolygons... took 41304 ms.
    Computing triangulation... took 5218 ms.
    Done. Surface extraction took 69698ms.
Deleting zero confidence vertices... took 219ms.
Mesh output file: final-output-mesh.ply
Writing PLY file (1826729 verts, with colors, with confidences, with values, 3640878 faces)... done.
All done. Remember to clean the output mesh.

C:\Users\Desktop\Documents\UERJ\mve-20160517-win64>

```

Figura 28 - Progressão do comando *fssrecon*, onde possui o ETA – *Estimated Time of Arrival*.

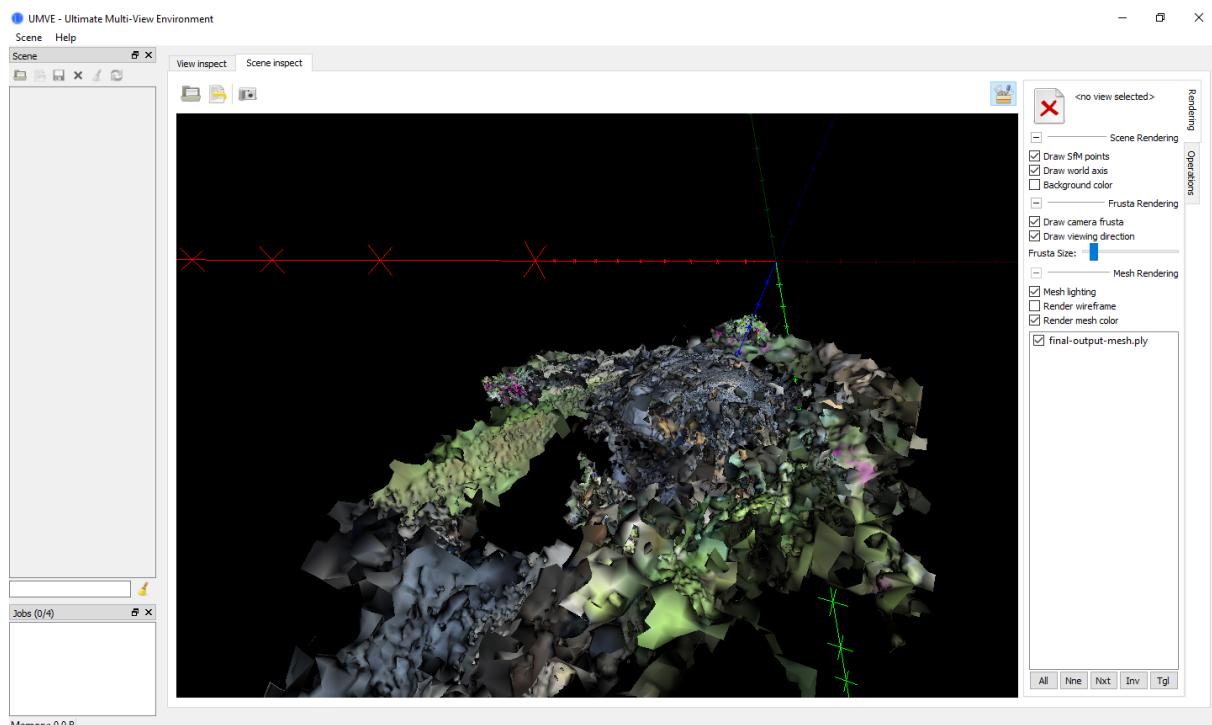


Figura 29 - Malha com ruídos proveniente do comando *fssrecon*.

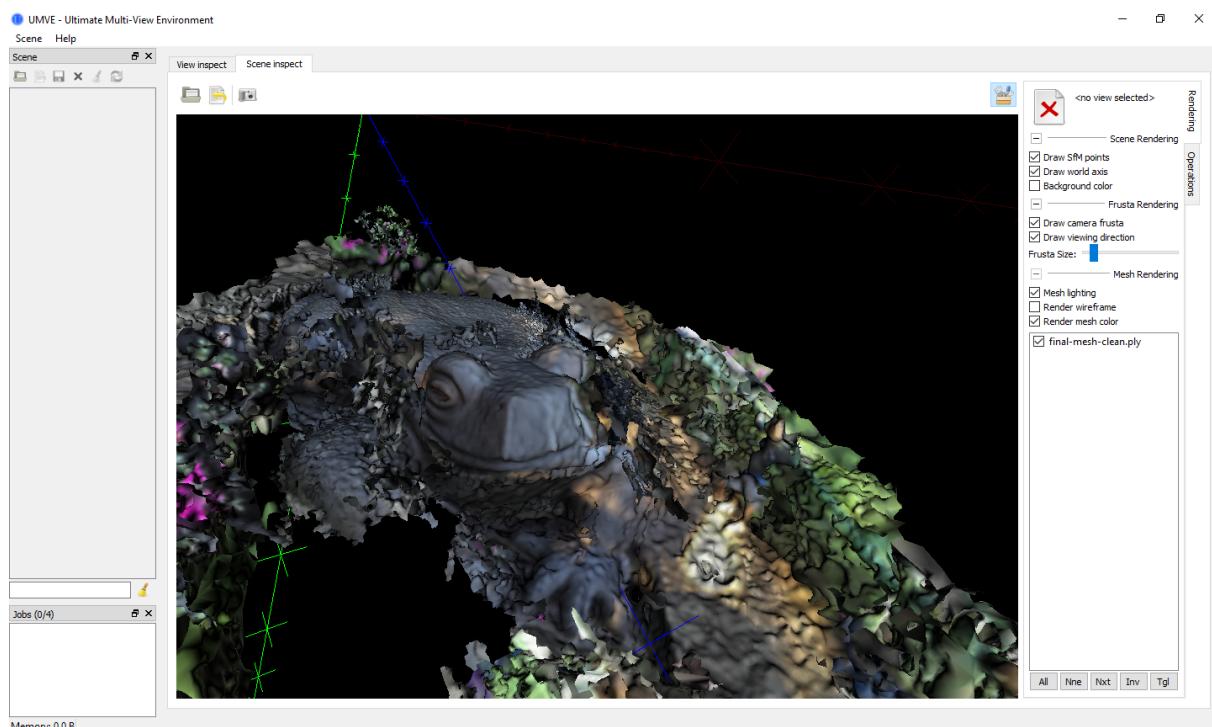


Figura 30 - Resultado final, após a remoção dos ruídos da malha.

4 VISUALSFM

Introdução

VisualSfM é um *software* baseado em fotogrametria que faz todo o processo de reconstrução 3D de um objeto e que pode usá-lo por linha de comando ou então pela interface gráfica, que é ótima, por sinal. É altamente customizável, podendo utilizar o CUDA da NVIDIA ou OpenGL, especificar a lista de pares para correspondência de imagens, usar detectores de *features* próprios, velocidade da detecção de *features*, da reconstrução densa, dentre outros parâmetros. Ou seja, é um *software* robusto, que pode ser usado em Linux, Windows ou até mesmo Mac.

Procedimento

Sua linha de reconstrução é parecida com o MVE 3.2, porém é mais intuitiva. Em sua interface, possui um Log de mensagens e erros que por ventura venham a acontecer e na parte de cima, alguns botões 31

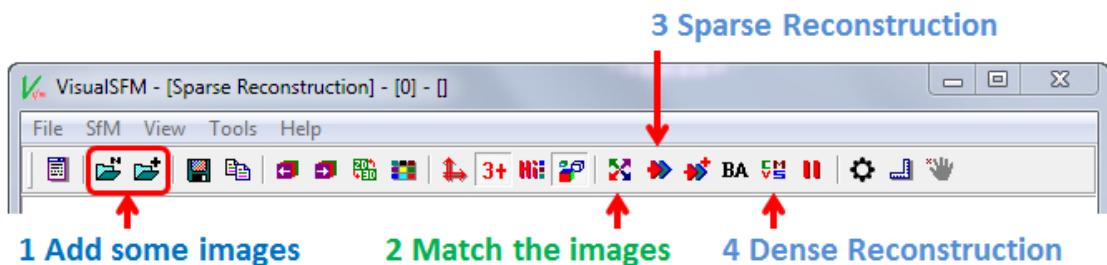


Figura 31 - Botões na parte superior da interface gráfica, este seria o *pipeline* padrão de funcionamento do *software*.

Como demonstrado na imagem 31, o funcionamento seria da seguinte forma:

- **1 - Adicionar algumas imagens.** Este é o primeiro passo, para começar uma reconstrução, primeiro adiciona-se imagens ao *software*, pode ser uma única foto, um conjunto de fotos, incrementar o conjunto já existente ou então abrir um arquivo de extensão .nvm, que é interpretado como uma reconstrução esparsa previamente feita.
- **2 - Correspondência de imagens.** Agora, o *software* roda o algoritmo SIFT, realizando todas as correspondências entre os *features*.
- **3 - Reconstrução esparsa.** Neste passo, o VisualSfM roda o algoritmo de reconstrução esparsa em todos os *features* descobertos no passo passado. (PBA).

PBA – Parallel Bundle Algorithm

”Bundle” refere-se aos feixes de luz que refletem em cada feature 3D e vão para o centro de cada câmera da cena a ser reconstruída. Com isso, o Bundle Adjustment é o problema de refinhar uma reconstrução visual para produzir estimativas com a visualização de parâmetros (estimativa e/ou calibração de câmeras) juntamente com as estruturas 3D.

O PBA é um algoritmo utilizado para minimizar o erro geométrico proveniente da reprojeção de cada feature da etapa de triangulação. Implementado em GPU (Graphic Processor Unit) para computar a Distância de Transformação Euclidiana (EDT – Euclidean Distance Transform) para uma imagem binária em 2D ou em dimensões superiores. Particionando a imagem em pequenas bandas, para serem processadas e, posteriormente, juntando-as simultaneamente, o PBA calcula o EDT exato com ótimo trabalho linear total, alto nível de paralelismo e um bom padrão de acesso à memória. Este algoritmo foi um dos precursores ao tentar explorar o máximo desempenho da GPU no cálculo da EDT exata.

- **4 - Reconstrução densa.** Finalmente, acaba a reconstrução rodando o algoritmo de reconstrução densa CMVS/PMVS-2 embutido no próprio VisualSfM.

CMVS/PMVS-2 (*Clustering Views for Multi-view Stereo / Patch-based for Multi-view Stereo*)

Muitos algoritmos Multi-View Stereo (MVS) não escalam tão bem com um grande número de imagens de entrada ou em uma alta resolução, pois necessitam de muita memória e recursos computacionais. A palavra-chave do CMVS é escalabilidade, pois seu propósito é utilizar imagens provenientes de sites na internet, em diferentes resoluções, como o Flickr.com. O CMVS usa a saída do Structure from Motion – SfM (mais especificamente a saída do passo anterior, do PBA) e utiliza como entrada. Após isso, decompõe as imagens de entrada como um conjunto de clusters de imagens com tamanhos gerenciáveis. O MVS pode ser usado para processar cada cluster de forma independente e em paralelo, onde a união das reconstruções de todos os clusters não deve perder detalhes que poderiam ser obtidos através do conjunto de imagens.

A formulação dos clusters é projetada para satisfazer três restrições: (1) as imagens redundantes são excluídas dos clusters (compactade), (2) cada cluster é pequeno o suficiente para uma reconstrução MVS (restrição de tamanho) e (3) as reconstruções MVS destes clusters resultam em uma perda mínima de conteúdo e detalhes em comparação com o que pode ser obtido através do processamento do conjunto completo de imagens (cobertura). A compactade é importante para a eficiência computacional, mas também para melhorar precisão, pois as coleções de fotos da Internet

geralmente contêm centenas ou milhares de fotos adquiridas de quase mesmo ponto de vista, ou seja, um conjunto composto inteiramente informações duplicadas.

Em outras palavras, a sobreposição de clusters é definida por:

- Minimizar $\sum_k |C_k|$ (compacidade)
- $\forall k |C_k| \leq \alpha$, onde α é determinado por recursos computacionais, principalmente por limitações de memória. (tamanho)
- $\forall i \frac{\# \text{ pontos cobertos em } I_i}{\# \text{ pontos em } I_i} \geq \delta$, onde δ é uma constante de proporção de pontos cobertos. (cobertura)

O CMVS algoritmo, pode ser resumido em quatro passos:

- Filtro SFM – agrupamento de pontos SFM
- Seleção de imagens – remove imagens redundantes
- Divisão de cluster – reforça a restrição de tamanho
- Adição de imagens – reforça a cobertura

4.0.2 Filtro SFM

A obtenção de medidas precisas de visibilidade de pontos é fundamental para o sucesso do procedimento de visualização baseado em clusters. Os recursos da imagem não detectados ou incomparáveis levam a erros nas estimativas de visibilidade do ponto V_j (geralmente na forma de imagens que estão faltando). Obtemos estimativas de visibilidade mais confiáveis ao agregar dados da visibilidade em uma vizinhança local, e mesclando os pontos nessa vizinhança. A posição do ponto mesclado é a média de seus vizinhos, enquanto a visibilidade se torna a união. Este passo também reduz significativamente o número de pontos SFM e melhora o tempo de execução das três etapas restantes. Especificamente, a partir de um conjunto de pontos SFM, um ponto é selecionado, combinado com seus vizinhos (mesclado) e, este ponto mesclado é emitido, após isso, o ponto original e seus vizinhos são removidos do conjunto de entrada. Esse procedimento é repetido até o conjunto de entrada estar vazio. O conjunto de pontos mesclados torna-se o novo conjunto de pontos, que, pode ser denotado por P_j^2 .

4.0.3 Seleção de imagens

Começando com o conjunto completo de imagens, cada imagem é testada e removida se a restrição de cobertura ainda for realizada após a remoção. O teste de remoção é realizado para todas as imagens enumeradas em ordem crescente de resolução de imagem (# de pixels), de modo que as imagens de baixa resolução sejam removidas primeiro. Observe que as imagens são descartadas permanentemente nesta etapa para acelerar as seguintes etapas principais de otimização.

4.0.4 Divisão de cluster

Em seguida, é aplicada a restrição de tamanho dividindo os clusters, ignorando a cobertura. Mais especificamente, um cluster de imagens é dividido em componentes menores caso viole a restrição de tamanho. A divisão de um cluster é realizada pelo algoritmo Normalized-Cuts [23] em um gráfico de visibilidade, onde os nós são imagens. O peso dA borda entre um par de imagens (I_l, I_m) mede o quanto a I_l e I_m contribuem, juntos, para a reconstrução MVS em pontos SFM relevantes:

$e_{lm} = \sum_{P_j \in \Theta^{lm}} \frac{f(P_j, I_l, I_m)}{f(P_j, V_j)}$, onde Θ^{lm} denota um conjunto de pontos SFM visíveis em I_l e I_m . Intuitivamente, as imagens com alta contribuição no MVS têm pesos altos entre eles e são menos propensos a serem cortados. A divisão de um cluster se repete até que a restrição de tamanho seja satisfeita para todos os clusters.

4.0.5 Adição de imagens

A restrição de cobertura pode ter sido violada na etapa anterior, e agora são adicionadas imagens a cada cluster para cobrir mais pontos SFM e restabelecer a cobertura. Nesta etapa, primeiro é construída uma lista de ações possíveis, onde cada ação mede a eficácia de adicionar uma imagem a um cluster para aumentar a cobertura. Para cada ponto SFM que está descoberto, P_j , deixe $C_k = \text{argmax}_{Cl} f(P_j, Cl)$ ser o cluster com a máxima precisão de reconstrução. Então, para P_j , é criada uma ação $(I \rightarrow C_k)$, g que adiciona a imagem $I (\in V_j, \notin C_k)$ a C_k , onde g mede a eficácia. Só são consideradas ações que adicionam imagens ao C_k em vez de cada cluster que poderia cobrir P_j , para eficiência computacional. Uma vez que as ações

com a mesma imagem e com o mesmo cluster são geradas a partir de vários pontos SFM, ocorre uma mescla dessas ações ao resumir a eficácia medida g . As ações na lista são classificadas em uma ordem decrescente de sua eficácia. Tendo construído uma lista de ações, uma abordagem seria tomar a ação com a pontuação mais alta, então refazer a lista novamente, o que é computacionalmente muito caro.

Em vez disso, consideramos ações cujas pontuações são mais de 0,7 vezes a pontuação mais alta na lista, em seguida, repete-se a ação a partir do topo da lista. Como uma ação pode alterar a eficácia de outras ações semelhantes, depois de tomar uma ação, remove-se quaisquer conflito da lista, onde duas ações $(I \rightarrow C), g, (I' \rightarrow C')$, g' estão em conflito se I' e I são vizinhos. A construção da lista e a adição da imagem são repetidas até que a restrição de cobertura seja satisfeita.

Após a adição da imagem, a restrição de tamanho pode ser violada e, neste caso, as duas últimas etapas são repetidas até que ambas as restrições sejam satisfeitas.

O passo seguinte, depois de obtido o cluster das imagens, é empregado algum algoritmo de reconstrução MVS, neste caso, o PMVS-2 (Patch-based Multiview Stereo Version 2).

4.0.6 PMVS-2

O PMVS utiliza a técnica de DoG e cantos de Harris. O DoG é utilizado para detecção de bordas, subtraindo o resultado de dois Gaussianos com escalas diferentes (Secao TAL). O operador de Harris emprega uma auto-correlação local para melhorar a consistência da borda, extraíndo a borda e os cantos dos features das imagens. A resposta de Harris é positiva em regiões com cantos, negativas em bordas e pequenas em regiões planas. Além disso, no PMVS, usando pontos de amostras das imagens como sementes, as linhas epipolares são usadas para decidir a região correspondente (dentro de uma área $2x2$ pixels) em outra imagem, gerando patches (cada uma definida com seu centro, normal e visibilidade) para atender às restrições na visibilidade, e levando à uma correspondência baseada em patches entre imagens. A correspondência Multi-view no PMVS é baseada em patches e depende da consistência fotográfica média de todos os pares visíveis. Um patch é reconstruído usando maximizando o valor médioda consistência da foto e, em seguida, aceitando somente se o número de imagens visíveis for maior ou igual a três.

A superfície do objeto é aproximada por um pequeno retângulo (o patch). O patch(p) é um retângulo modelado pela posição central $c(p)$, pelo vetor normal $n(p)$, pelos eixos x e y e pela imagem de referência $R(p)$, onde a imagem é a que melhor

representa a visibilidade do patch. Seu tamanho é determinado por sua projeção na imagem de referência $R(p)$.

A imagem é dividida em células (grid), de $\beta \times \beta$ pixels (usualmente 2×2). O ideal é reconstruir um patch por célula. Quanto menor a célula, maior será a densidade na nuvem de pontos final.

O PMVS pode ser dividido em algumas etapas:

- Inicialização
 - Detecção de features*
 - Correspondência guiada*
- Expansão
- Filtragem

4.0.7 Detecção de features

O PMVS padrão utiliza o DoG em conjunto com o algoritmo de cantos de Harris, onde é criada uma linha epipolar, e todos os pontos em comum nesta linha são considerados consistentes para a reconstrução. Após isso cria-se o patch onde o $c(p)$ é calculado pela triangulação dos features detectados das imagens. A normal $n(p)$ é o cálculo da relação do vetor $c(p)$, multiplicado pela centro óptico da imagem, pelo módulo do numerador. E $R(p)$ é a imagem de referência propriamente dita. São otimizadas as orientações e posições de todos os patches. Com a inicialização finalizada, temos como resultado a reconstrução esparsa da escultura. No caso do VisualSfM, como a reconstrução esparsa já é feita em passos anteriores (com o PBA), na realidade o PMVS-2 só é empregado para a reconstrução densa, ou seja, a inicialização não é feita pelo PMVS-2 no VisualSfM.

4.0.8 Expansão

Cada ponto 3D na nuvem de pontos é usado como semente para um algoritmo de expansão (aumento da região). Um patch utilizado como semente é expandido da seguinte forma:

Um novo patch é projetado em uma célula vizinha; A posição é definida para a interseção do raio projetado para trás e no plano de seu patch pai, usando a mesma orientação (o vetor normal é propagado) e a mesma imagem de referência. Novamente, são otimizadas as orientações e posições, porém, do novo patch.

4.0.9 Filtragem

É aplicada uma consistência de visibilidade global, onde os patches que não são visíveis pelos centros ópticos das imagens, são descartados (estão dentro da superfície). Para isso, são utilizados dois filtros: filtro de qualidade e filtro de visibilidade.

4.0.9.1 Filtro de Qualidade

A mesma região de superfície pode ser reconstruída em múltiplos clusters com qualidade de reconstrução variável: grupos próximos produzem pontos densos e precisos, enquanto cachos distantes produzem pontos escassos e ruidosos. Queremos filtrar o último, que é realizado pelo seguinte filtro de qualidade. Deixe P_j e V_j denotarem um ponto MVS e suas informações de visibilidade estimadas pelo algoritmo MVS, respectivamente.

4.0.9.2 Filtro de Visibilidade

Além disso, o VisualSfM é capaz de mostrar a matriz de correspondência de *features*, número de *features*, rodar um *Bundle Adjustment*, usar um Level 0 no PVMS, alterar a memória de GPU usada na reconstrução, deletar uma reconstrução indesejável, alterar parâmetros e rodar novamente o passo a passo acima.

5 EXPERIMENTOS

No presente trabalho, nos concentramos no objetivo proposto descrito na Seção ??.

5.1 Procedimento

Primeiramente, filmamos algumas esculturas utilizando a câmera de um *smartphone* convencional na resolução de 1920x1080 pixels. Esta filmagem foi realizada varrendo toda (ou maioria) da superfície da escultura em 360° com o intuito de ter toda a escultura reconstruída 32. Após isso, fizemos mais alguns vídeos, pegando alguns pontos que possuíam mais detalhes e que, com uma única varredura, não era capaz de reproduzir uma boa reconstrução.

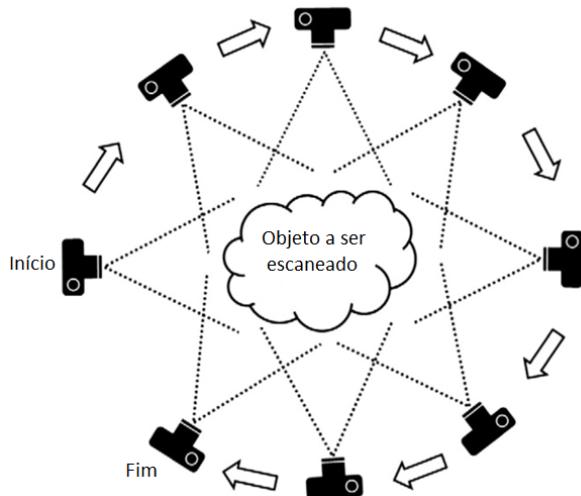


Figura 32 - Exemplo de como foi realizada a varredura da escultura

Com este material, foram feitos "cortes" em determinados *frames* do vídeo, com atenção para não cortar em *frames* muito juntos, pois aumentaria o número de correspondências ambíguas entre as imagens e com isso, o processamento da reconstrução demoraria mais. E não usar *frames* muito distantes, o que ocorreria o inverso, com menos correspondências, ficariam buracos na reconstrução. Como descrito na Seção 3.2. Com isso em mente, foram reconstruídas duas esculturas: uma com um único vídeo, usando o VisualSfM, totalizando 200 imagens e outra com dois vídeos, com o MVE, com dois vídeos, que, ao cortá-los, totalizou cerca de 280 imagens.

Além de esculturas ao ar livre, fizemos alguns testes em ambiente fechado, dentro de uma casa, por exemplo. Foi utilizado um objeto feito de cabaça (casca de abóbora) na qual possui uma superfície propícia para uma reconstrução (Seção 0.4, sobre superfícies

Tabela 4 - Tempos obtidos da reconstrução do objeto usando o VisualSfM

Procedimento	Tempo
Carregamento de imagens	50 segundos
Calcular pares correspondentes de <i>features</i>	159 segundos
Gerar a reconstrução esparsa do modelo	135 segundos
Gerar a reconstrução densa do modelo	1416 segundos

Lambertianas).

Com o procedimento descrito anteriormente, a partir dos vídeos feitos, obtemos um total de 200 imagens em um vídeo superficial e mais 24 imagens mais detalhadas do objeto, ambos numa resolução de 1080x1920 pixels. E, para um mesmo conjunto de imagens, rodamos tanto o VisualSfM quanto o MVE.

5.1.1 Resultados da reconstrução do objeto com o VisualSfM

Seguindo o passo-a-passo de reconstrução do *software*, obtemos os seguintes resultados:

A figura 35 mostra, o resultado da reconstrução esparsa do algoritmo PBA. Não é tão nítida como na figura 34, a quantidade de ruídos, provenientes de outros objetos (o VisualSfM só identifica objetos estáticos) presentes na cena, e não é possível limpar a malha no próprio *software*, somente por meio de programas externos.

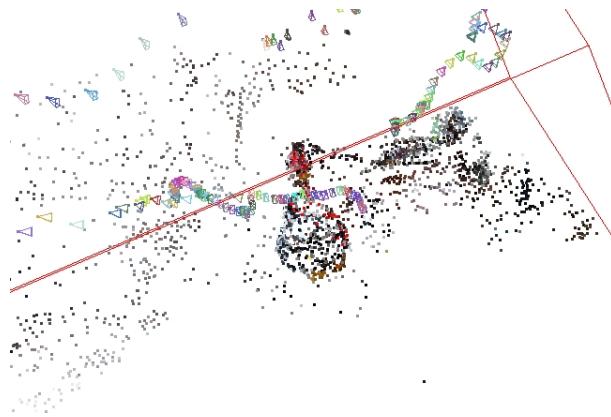


Figura 33 - Reconstrução esparsa do objeto no VisualSfM

Fizemos uma outra reconstrução, utilizando os dois vídeos (gerando 224 imagens), caso fosse usado um conjunto maior, o programa parava de funcionar por falta de memória, mesmo após ajustar parâmetros (como o número de vizinhos, número de *cores* do processador, *level* do PMVS usado, entre outros) para melhorar esse problema. Com isso em mente, conseguimos os seguintes resultados:

Percebemos que não foi tão proveitoso (qualitativamente) usar mais imagens neste



Figura 34 - Reconstrução densa do objeto no VisualSfM

Tabela 5 - Tempos obtidos da reconstrução do objeto, com 224 imagens usando o VisualSfM

Procedimento	Tempo
Carregamento de imagens	60 segundos
Calcular pares correspondentes de <i>features</i>	200 segundos
Gerar a reconstrução esparsa do modelo	162 segundos
Gerar a reconstrução densa do modelo	1920 segundos

caso, inclusive o algoritmo perdeu a referência do objeto e gerou um segundo modelo na reconstrução esparsa [36](#), e consequentemente, na reconstrução densa [37](#) e [38](#). O que gerou uma cerca incoerência na reconstrução.



Figura 35 - Reconstrução esparsa do objeto com 224 imagens no VisualSfM

5.1.2 Resultados da reconstrução do objeto com o MVE

Com a interface gráfica (UMVE), criamos uma nova cena e inserimos, primeiramente, as 200 fotos do objeto. Em seguida, utilizando as linhas de comando do MVE, fizemos o procedimento padrão de reconstrução do *software*. E, obtivemos os seguintes resultados:

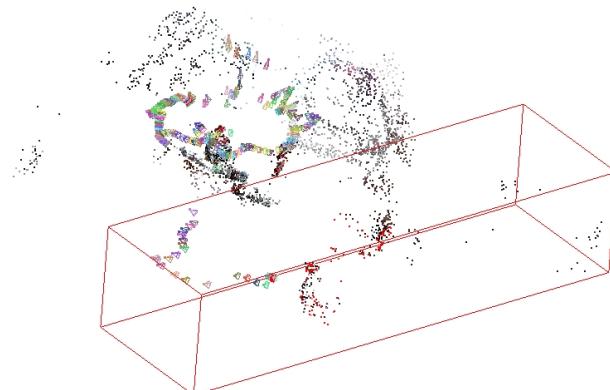


Figura 36 - Foi gerado dois modelos esparsos do objeto a partir do conjunto inicial de 224 imagens, provavelmente, proveniente da falta de parâmetros da câmera



Figura 37 - Reconstrução do primeiro modelo do objeto no VisualSfM com 224 imagens



Figura 38 - Reconstrução do segundo modelo do objeto no VisualSfM com 224 imagens

Figura 39 - Tempo gasto da etapa *sfmrecon* do MVE

Figura 40 - Tempo da etapa *dmrecon* do MVE

Figura 41 - Tempo da etapa *fssrecon* do MVE

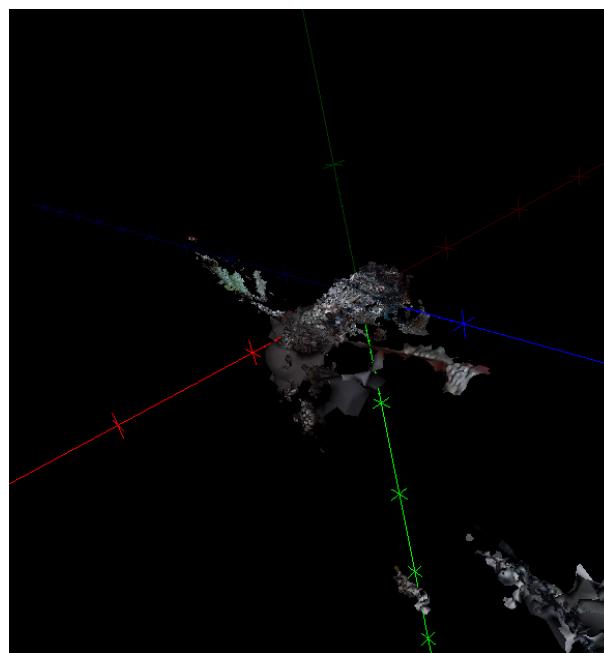


Figura 42 - Resultado da etapa *fssrecon* do MVE

A etapa de *scene2pset* demorou cerca de 20 segundos (total). Porém percebemos que a reconstrução não foi satisfatória, o *software* se confundiu, e não conseguiu obter os parâmetros corretos das câmeras utilizadas. A partir disso, o erro se propagou e gerou

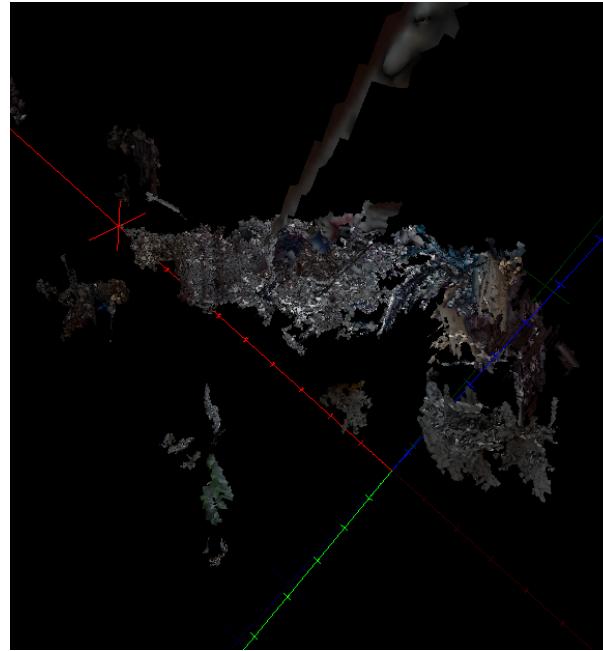


Figura 43 - Resultado da etapa *meshclean*, da etapa anterior 42

essa reconstrução acima 42 e 43.

Rodamos também, com as 224 fotos, só foi possível executar o passo *sfmrecon* 44, pois o MVE não conseguiu rodar o comando *dmrecon* por algum motivo, e não gerou nenhum resultado para a continuação do algoritmo 45.

```
■ Execução Fazendo de Conexão
Pair 111,112: 198 matches, 272 H-normals (92%)  

Pair 111,113: 180 matches, 272 H-normals (92%)  

Pair 111,114: 184 matches, 184 H-normals (72%)  

Pair 111,115: 175 matches, 175 H-normals (72%)  

Pair 111,116: 180 matches, 171 H-normals (95%)  

Pair 111,117: 177 matches, 171 H-normals (95%)  

Pair 111,118: 179 matches, 150 H-normals (98%)  

Pair 111,119: 177 matches, 172 H-normals (92%)  

Pair 111,120: 178 matches, 117 H-normals (62%)  

Pair 111,121: 175 matches, 175 H-normals (72%)  

Pair 111,122: 177 matches, 161 H-normals (98%)  

Pair 111,123: 177 matches, 151 H-normals (98%)  

Pair 111,124: 177 matches, 152 H-normals (95%)  

Pair 111,125: 177 matches, 152 H-normals (95%)  

Pair 111,126: 171 matches, 150 H-normals (75%)  

Pair 111,127: 171 matches, 150 H-normals (75%)  

Pair 111,128: 171 matches, 150 H-normals (94%)  

Pair 111,129: 168 matches, 150 H-normals (75%)  

Pair 111,130: 165 matches, 150 H-normals (75%)  

Pair 111,131: 169 matches, 162 H-normals (95%)  

Pair 111,132: 166 matches, 162 H-normals (95%)  

Pair 111,133: 164 matches, 160 H-normals (98%)  

Pair 111,134: 165 matches, 164 H-normals (98%)  

Pair 111,135: 163 matches, 163 H-normals (98%)  

Pair 111,136: 164 matches, 164 H-normals (98%)  

Pair 111,137: 164 matches, 160 H-normals (98%)  

Pair 111,138: 166 matches, 160 H-normals (98%)  

Pair 111,139: 168 matches, 110 H-normals (75%)  

Pair 111,140: 159 matches, 200 H-normals (95%)  

Pair 111,141: 162 matches, 162 H-normals (95%)  

Pair 111,142: 162 matches, 162 H-normals (95%)  

Rejected 7 raw tracks rejected 100 bad tracks.
Rejected 0 camera had a camera error.  

Rejected 0 cameras failed cameras.  

Accepted 778 raw tracks. Using a threshold of 0.816697.  

Running full bundle adjustment... (20 min, 8 iter, 32ms).  

Avg. reprojection error: 0.00054713 (mm), 0.816697  

Camera 324, track length: 1 -> 0.00009299, direction: 1.0094  

Avg. reprojection error: 0.00054713 (mm), 0.816697  

Sfm reconstruction took [0:00:11].  

Writing bundle (224 cameras, 7 features); galite_loprg_porto/synth_N.net.  

Writing cameras; galite_loprg_porto/synth_N.cam.  

Writing features; galite_loprg_porto/synth_N.feature.  

Scaling view; C:/Users/Desktop/Documents/USP/sem-2016/417-vid3d/galite_loprg_porto/view/view_0122.mov  

2016/10/26 16:38:11.148443
```

Figura 44 - Resultado da etapa *sfmrecon*, com todas as imagens



```
■ Selecionar Prompt de Comando
C:\Users\juliohenr\Downloads\10_0_1064\dmrecon
This program uses Python 2.7.1. To use the command line, enter the following command:
C:\Users\juliohenr\Desktop\Documents\dmrecon\dmrecon.py
C:\Users\juliohenr\Desktop\Documents\dmrecon\dmrecon.py
C:\Users\juliohenr\Desktop\Documents\dmrecon\dmrecon.py gallina_longs_pento
C:\Users\juliohenr\Desktop\Documents\dmrecon\dmrecon.py gallina_longs_pento
This program was built on May 17 2014, 11:36:21
Initialised 224 total features (14 223), took 39ms.
Reading feature file (224 total features)...done.
Setting scale 1 for 3886x938 Image...
Setting scale 1 for 3886x938 Image...
Reconstruction took 27ms...
Saving vtexs to Mat files... done.
C:\Users\juliohenr\Desktop\Documents\dmrecon\dmrecon.py
```

Figura 45 - Resultado da etapa *dmrecon*, com todas as imagens

CONCLUSÃO

Apresentamos técnicas de reconstruções utilizando fotogrametria, mais especificamente para esculturas à céu aberto, aprendendo sobre a calibração de equipamentos, softwares a serem utilizados e sobre como fazer uma boa varredura, cobrindo toda a escultura com uma câmera comum de celular.

Trabalhos futuros

Identificamos os seguintes caminhos para a evolução deste projeto:

- **Realizar uma varredura com o Kinect.** Embora seja custoso, tanto fisicamente quanto computacionalmente, seria interessante ter um parâmetro de comparação com as técnicas de fotogrametria Kinect, que se mostrou muito promissor em um ambiente fechado.
- **Validação adicional.** Ter resultados mais expressivos, em questão quantitativa e não só qualitativa, para realizar uma engenharia mais completa do sistema, comparando valores em diferentes técnicas empregadas.
- **Constatar na prática, o melhor método de varredura da escultura.** Verificamos que um dos melhores modos de se escanear uma escultura de grande porte seria escaneá-la várias vezes, a fim de que se pegue todos os detalhes, cobrindo toda a área a ser reconstruída. Mas será que este é realmente o melhor método?
- Automatizar o corte de *frames* do vídeo.