



UNIVERSIDADE DO ESTADO DO
RIO DE JANEIRO



INSTITUTO POLITÉCNICO
GRADUAÇÃO EM ENGENHARIA
DE COMPUTAÇÃO

Pedro Felipe Pena Barata

Aplicações de técnicas atuais em reconstrução 3D
fotogramétrica

Nova Friburgo

2017



UNIVERSIDADE DO ESTADO DO
RIO DE JANEIRO

IPRJ
Instituto Politécnico
Universidade do Estado do Rio de Janeiro

INSTITUTO POLITÉCNICO
GRADUAÇÃO EM ENGENHARIA
DE COMPUTAÇÃO

Pedro Felipe Pena Barata

Aplicações de técnicas atuais em reconstrução 3D fotogramétrica

Trabalho de Conclusão de Curso apresentado, como requisito parcial para obtenção do título de Graduado em Engenharia de Computação, ao Departamento de Modelagem Computacional do Instituto Politécnico, da Universidade do Estado do Rio de Janeiro.

Orientador: Prof. Dr. Ricardo Fabbri

Nova Friburgo

2017

Pedro Felipe Pena Barata

Aplicações de técnicas atuais em reconstrução 3D fotogramétrica

Trabalho de Conclusão de Curso apresentado, como requisito parcial para obtenção do título de Graduado em Engenharia de Computação, ao Departamento de Modelagem Computacional do Instituto Politécnico, da Universidade do Estado do Rio de Janeiro.

Aprovada em 23 de Novembro de 2017.

Banca Examinadora:

Prof. Dr. Ricardo Fabbri (Orientador)
Departamento de Modelagem Computacional – UERJ

Prof. Dr. Edirlei Soares – UERJ

Prof. Dr. Roberto Pinheiro – UERJ

Nova Friburgo
2017

AGRADECIMENTOS

A Deus por ter me dado saúde e força para superar as dificuldades.

À minha família por sempre me apoiar, até nos momentos mais dificeis.

À UERJ e todo seu corpo docente, além da direção e administração, que mesmo sem ter condições ideais de funcionamento, realizam seu trabalho com tanto amor e dedicação, trabalhando incansavelmente para que nós, alunos, possamos contar com um ensino de extrema qualidade.

Ao meu professor e orientador Ricardo Fabbri, pelo suporte no pouco tempo que lhe coube, pelas suas correções e incentivos.

Talvez não tenha conseguido fazer o melhor, mas lutei para que o melhor fosse feito.

Não sou o que deveria ser, mas Graças a Deus, não sou o que era antes.

Marthin Luther King

RESUMO

BARATA, Pedro Felipe Pena. *Aplicações de técnicas atuais em reconstrução 3D fotogramétrica*. 2017. 71 f. Trabalho de Conclusão de Curso (Graduação em Engenharia de Computação) – Departamento de Modelagem Computacional, Instituto Politécnico, Universidade do Estado do Rio de Janeiro, Nova Friburgo, 2017.

A área de reconstrução 3D vem sido amplamente explorada. Sensores de profundidade, tanto aéreos quanto terrestres, têm sido empregados em diferentes aplicações já há muito tempo. Entretanto, constantes melhorias na tecnologia, sobretudo, no *hardware* e *software* no âmbito da reconstrução, fizeram com que nas últimas duas décadas, novas técnicas surgissem.

Muitos cientistas que utilizavam a fotogrametria pura – isto é, usando sensores de imagens convencionais – haviam convertido seus esforços à área dos sensores a *laser*. Além de executarem uma reconstrução mais rápida e confiável de objetos com baixa textura, tais sensores possuem uma altíssima acurácia, compensando seu alto custo inicial. Isto dificultou e desacelerou o processo de descoberta de novos algoritmos e métodos em fotogrametria pura.

Graças a avanços recentes, a fotogrametria, aliada a novos algoritmos, como o *Structure from Motion* (SfM), pontos de interesse e o casamento entre imagens, por exemplo, consegue competir com escaneadores a *laser* e sensores de profundidade. As características mais bem-reconhecidas das técnicas recentes, no entanto, são a robustez, flexibilidade, e praticidade, não sendo claro se na prática podem competir com escaneadores a *laser* quanto à precisão em aplicações de interesse.

Neste trabalho, investiga-se a praticidade de técnicas atuais combinando SfM e MVS (*Multi-View Stereo*), utilizando softwares como o MVE (FUHRMANN; LANGGUTH; GOESELE, 2014) e o VisualSfM (WU et al., 2011b). Em particular, relata-se um estudo de até onde é possível chegar apenas utilizando-se a câmera de um *smartphone*, visando aplicação futura à preservação completa do patrimônio do Jardim do Nêgo, em Nova Friburgo. Essa tecnologia é confrontada com outros tipos de técnicas empregadas em grandes projetos, como o Kinect, da Microsoft, e sua aplicação em SfM, bem como técnicas clássicas de escaneamento a *laser*, tais como as empregadas no projeto *Digital Michelangelo* de preservação de esculturas liderado pela Universidade de Stanford.

Palavras-chave: Fotogrametria. VisualSfM. MVE – *Multi-View Reconstruction Environment*. Reconstrução 3D.

ABSTRACT

BARATA, Pedro Felipe Pena. *Applications of current photogrammetric 3D reconstruction techniques.* 2017. 71 f. Trabalho de Conclusão de Curso (Graduação em Engenharia de Computação) – Departamento de Modelagem Computacional, Instituto Politécnico, Universidade do Estado do Rio de Janeiro, Nova Friburgo, 2017.

The field of 3D reconstruction has been widely explored. Range sensors, both aerial and terrestrial, have long been employed in different applications. However, constant improvements in technology, especially in hardware and software in the context of reconstruction, have led to the emergence of new techniques in the past two decades.

Many scientists that used pure photogrammetry – *i.e.*, using conventional imaging sensors – have converted their efforts into the area of laser sensors. Such sensors, beyond providing a faster and more reliable reconstruction for objects with low texture information, provide high accuracy, justifying their initial cost. This hindered and slowed down the process of discovering new algorithms and methods in pure photogrammetry.

Thanks to recent advances, photogrammetry, coupled with new algorithms such as Structured Motion (SfM), interest points and image matching, for instance, can compete with laser scanners and other range sensors. While Recent techniques are well-known for robustness, flexibility and ease of use, it is not yet clear whether they can compete with laser scanners in terms of precision in applications of interest.

In this work, we investigate the practical applicability of current techniques combining SfM and MVS (*Multi-View Stereo*), using softwares such as MVE (**FUHRMANN; LANGGUTH; GOESELE, 2014**) and VisualSfM (**WU et al., 2011b**). In particular, we study how far can one go by using a standard smartphone camera, aiming at a future application to the complete preservation of the sculpture garden Jardim do Nêgo at Nova Friburgo. This technology will be confronted against other types of techniques employed in major projects, such as Microsoft’s Kinect and its application in SfM, as well as classical techniques of laser scanning of sculptures, such as those employed in the Digital Michelangelo project, lead by Stanford University.

Keywords: Photogrammetry. VisualSfM. MVE – Multi-View Reconstruction

Environment. 3D Reconstruction.

LISTA DE FIGURAS

Figura 1 - Kinects de primeira geração (a) consistindo de câmeras e projetores infra-vermelho (b) e de segunda geração, consistindo de tecnologia ToF (c). Ambos os kinects são largamente utilizados para escaneamento em tempo real, formando a base de escaneadores manuais (d), porém nem sempre são úteis para preservação detalhada de patrimônio. Um dos objetivos deste projeto é explorar os limites desta tecnologia.	13
Figura 2 - A reconstrução usando-se Kinect (de primeira ou segunda geração) usando software atual de super-resolução (c) fornece precisão similar a um sistema estéreo de média resolução, inferior um sistema a <i>laser</i> de alta qualidade (d) porém de baixo custo e muito mais versátil devido ao sistema de aquisição manual e a software amplamente utilizado e desenvolvido (WANG et al., 2015).	14
Figura 3 - Protótipo do escaneador a <i>laser</i> de triangulação. O objeto a ser escaneado é uma réplica em tamanho real de um sarcófago egípcio (a). O escaneador foi reconfigurado para escanear objetos maiores, pois a escultura possui 517 centímetros (b), o da cabeça também sofreu uma reconfiguração, este escaneador gira em 90 graus, que faz o <i>laser</i> rotacionar, da posição horizontal para a vertical e também roda em torno da cabeça como um todo (c). Para a reconstrução, o primeiro passo foi alinhar cerca de 100 scans em diversas posições, após isso, utilizado um alinhamento automático em pares dos scans, utilizando um algoritmo modificado de iterações de pontos próximos (ICP - <i>Iterated-Closest-Points</i>). Após isso, faz-se um processo de relaxação global a fim de minimizar erros de alinhamento por toda a estátua. Depois de alinhados, usa-se o algoritmo de profundidade volumétrica de processamento de imagens (VRIP - <i>Volumetric Range Image Processing</i> - de Brian Curless) (d) (LEVOY et al., 2000)	15
Figura 4 - Algumas esculturas do Jardim do Nêgo (WITNESS, 2014)	15
Figura 5 - Exemplo de um projetor de padrões utilizando um <i>laser</i> visível. (OPTO..., 2017).	18
Figura 6 - Como era feito o escaneamento da estátua de David (a), composto por dois escaneadores, sendo (b) o escaneador principal (da cabeça) e estruturas para alcançar todos os pontos necessários (LEVOY et al., 2000).	20
Figura 7 - Escultura “Noite”, de Michelangelo.	20

Figura 8 - Alguns tipos de cinzéis que provavelmente foram usados por Michelangelo na escultura de "St. Matthew". (LEVOY et al., 2000)	21
Figura 9 - Imagem de um Kinect V1 aberto, constituído de uma câmera infravermelho (IR - <i>Infra-Red</i>), uma câmera RGB e um projetor IR. (SMISEK; JANCOSEK; PAJDLA, 2013)	25
Figura 10 - Exemplo de como é a saída de uma imagem interpretada pelo Kinect, onde cada disposta na imagem corresponde à profundidade ou distância da cena para o Kinect, e preto corresponde a pontos sem informação confiável. (SILBERMAN DEREK HOIEM; FERGUS, 2012)	26
Figura 11 - Representação visual do acerto do deslocamento. A parte em preto é a imagem IR e o contorno em branco é a imagem de profundidade do alvo. (SMISEK; JANCOSEK; PAJDLA, 2013)	28
Figura 12 - Posição e orientação do Kinect (com as câmeras IR e RGB) e o par estéreo SLR (<i>Left, Right</i>) em conjunto com pontos de calibração 3D reconstruídos em alvos de calibração planar. (SMISEK; JANCOSEK; PAJDLA, 2013)	28
Figura 13 - Imagens iniciais para reconstrução 3D (SMISEK; JANCOSEK; PAJDLA, 2013)	29
Figura 14 - Resultados da reconstrução SfM, onde (a) é a reconstrução do SLR e (b) o resultado do Kinect. Qualitativamente ambas são satisfatórias (SMISEK; JANCOSEK; PAJDLA, 2013)	30
Figura 15 - Funcionamento do Kinect Fusion, adquirindo o mapa de profundidade com a câmera do Kinect, onde há várias falhas devido à falta de dados. Em alguns segundos é realizada uma reconstrução 3D realista de uma cena estática apenas movendo o Kinect ao redor da cena. Após isso, uma nuvem de pontos ou uma malha 3D densa pode ser produzida. (IZADI et al., 2011)	30
Figura 16 - Processo de escaneamento e geração do modelo 3D no Kinect Fusion. (IZADI et al., 2011)	31
Figura 17 - Procedimento padrão da maioria dos sistemas baseados em SfM e MVS (SWEENEY, 2016)	32
Figura 18 - É aplicado um filtro gaussiano na imagem original (a), com $\sigma = 1$, tendo como resultado a imagem (b). Um outro filtro gaussiano é usado, porém, neste caso, o $\sigma = 2$ (c). Após isso, subtrai-se (b) de (c), obtendo o filtro DoG (d)	34
Figura 19 - Exemplo de funcionamento de detecção de espaço-escala extrema	34
Figura 20 - Exemplo do resultado obtido do histograma orientado	36
Figura 21 - Exemplo de um descritor de pontos-chaves, com uma matriz 2x2 e uma região 8x8	37

Figura 22 - Uma triangulação utilizando um ponto qualquer, X_j . Onde cada câmera C_1, C_2, C_3 possui um <i>feature</i> correspondente a cada uma delas, respectivamente, X_{1j}, X_{2j}, X_{3j}	38
Figura 23 - Funcionamento do MVE. Começando com múltiplas imagens, técnicas SfM são empregadas para reconstruir os parâmetros das câmeras e os conjuntos de pontos esparsos. Mapas de profundidade são computados para cada imagem usando o MVS. Finalmente, uma malha colorida é extraída da união de todos os mapas de profundidade usando um algoritmo de aproximações de reconstruções de superfícies (FSSR – <i>Floating Scale Surface Reconstruction</i>). (FUHRMANN; LANGGUTH; GOESELE, 2014)	39
Figura 24 - Caso o espaçamento entre as câmeras seja grande, a informação extraída das imagens em comum será menor (a). Se a angulação do efeito de paralaxe seja baixa, terá a mesma informação sobre um ponto em questão (c). Ou seja utilizando ou (a), ou (c). Pode ser que a reconstrução fique incerta. Para que o efeito paralaxe tenha maior proveito das imagens das câmeras, é necessário que as câmeras estejam dispostas como (b), conseguindo extrair uma boa quantidade e qualidade de informações do ponto. (STRICKER, 2015)	40
Figura 25 - Interface gráfica (UMVE)	41
Figura 26 - Reconstrução baseada em nuvem de pontos gerada a partir da reconstrução SfM.	42
Figura 27 - Uma imagem de entrada (à esquerda) e sua correspondência em mapas de profundidade (à direita), onde a parte roxa significa que não foi encontrada nenhum mapa naquela região (FUHRMANN; LANGGUTH; GOESELE, 2014).	43
Figura 28 - Botões na parte superior da interface gráfica, este seria o procedimento padrão de funcionamento do <i>software</i> . (WU et al., 2011b)	44
Figura 29 - Dado um ponto de um objeto 3D \hat{X} , sua reprojeção nas câmeras C e C' , são, respectivamente, x e x' . Esses pontos possuem um erro de reprojeção d e d' e ao utilizar o PBA/MCBA, os pontos x e x' serão reajustados como \hat{x} e \hat{x}' , respectivamente. (STRICKER, 2015)	45
Figura 30 - Usabilidade dos filtros de qualidade e visibilidade, onde são aplicados fora do núcleo, assim como em paralelo. À esquerda, um ponto MVS P é testado usando os filtros. À direita, temos pseudo-códigos, onde os loops destacados em azul podem ser executados em paralelo. (FURUKAWA et al., 2010).	53
Figura 31 - Exemplo de como foi realizada a varredura da escultura	55

Figura 32 - Reconstrução esparsa da escultura do Jardim do Nêgo no VisualSfM com 197 imagens.	56
Figura 33 - Resultados da reconstrução densa da escultura do Jardim do Nêgo usando o VisualSfM, em dois ângulos diferentes (a) e (b).	57
Figura 34 - Reconstrução esparsa do objeto no VisualSfM com 200 imagens.	57
Figura 35 - Reconstrução densa do objeto no VisualSfM com 200 imagens.	57
Figura 36 - Reconstrução esparsa do objeto com 224 imagens no VisualSfM.	58
Figura 37 - Foram gerados dois modelos esparsos do objeto a partir do conjunto inicial de 224 imagens, provavelmente, proveniente da falta de parâmetros da câmera.	58
Figura 38 - Reconstruções densas do primeiro (a) e do segundo (b) modelo do objeto no VisualSfM com 224 imagens.	59
Figura 39 - A figura (a) é um exemplo onde a imagem possui dados na extensão <i>EXIF</i> (destacado em azul). Ao passo que a figura (b) é um frame de um vídeo, que não possui os dados das câmeras (destacado em azul).	59
Figura 40 - Final da reconstrução via UMVE, percebe-se que alguns pontos não foram considerados, tendo como resultado uma "nuvem de pontos" mais densa, basicamente.	60
Figura 41 - Processos dentro do comando <i>sfmrecon</i> , onde (a) estão sendo detectadas as <i>features</i> do conjunto de imagens. Em (b) está computado o <i>pairwise matching</i> e em (c) está no processo de <i>Bundle Adjustment</i> (CHOUDHARY ,), usando condições-padrão para as câmeras.	61
Figura 42 - Término do comando <i>sfmrecon</i> , onde demorou cerca de 1 minuto e meio (75509 milisegundos).	61
Figura 43 - Término do comando <i>dmrecon</i> , onde demorou cerca de 4 horas (14502576 milisegundos).	62
Figura 44 - Execução dos comandos <i>scene2pset</i> , nos níveis -F0, -F1, -F2 e -F3.	62
Figura 45 - Progressão do comando <i>fssrecon</i> , onde possui o ETA – <i>Estimated Time of Arrival</i>	63
Figura 46 - Malha com ruídos proveniente do comando <i>fssrecon</i>	63
Figura 47 - Resultado final, após a remoção dos ruídos da malha.	64
Figura 48 - Tempo gasto da etapa <i>sfmrecon</i> do MVE	65
Figura 49 - Tempo da etapa <i>dmrecon</i> do MVE	65
Figura 50 - Tempo da etapa <i>fssrecon</i> do MVE	65
Figura 51 - Resultado da etapa <i>fssrecon</i> do MVE	66
Figura 52 - Resultado da etapa <i>meshclean</i> , da etapa anterior 51	66
Figura 53 - Resultado da etapa <i>sfmrecon</i> , com todas as imagens	67
Figura 54 - Resultado da etapa <i>dmrecon</i> , com todas as imagens	67

SUMÁRIO

1	INTRODUÇÃO	12
1.1	Objetivos	17
2	RECONSTRUÇÃO 3D ATIVA	18
2.1	Projeto de preservação das esculturas de Michelangelo	18
3	TÉCNICAS DE LUZ ESTRUTURADA E <i>TIME OF FLIGHT</i>	24
3.1	Kinect	24
4	TÉCNICAS DE RECONSTRUÇÃO BASEADAS EM FOTOGRAFIA	32
4.1	MVE – <i>Multi-View Reconstruction Environment</i>	38
4.2	VisualSfM	43
5	EXPERIMENTOS	55
5.1	Procedimento	55
5.1.1	<u>Resultados da reconstrução com o VisualSfM</u>	56
5.1.2	<u>Resultados da reconstrução com o MVE</u>	59
6	CONCLUSÃO	68
	REFERÊNCIAS	69

1 INTRODUÇÃO

Introdução e Justificativa

A reconstrução 3D de cenas gerais a partir de múltiplos pontos de vista usando-se câmeras convencionais, sem aquisição controlada, é um dos grandes objetivos de pesquisa em visão computacional, ambicioso até mesmo para os dias de hoje. Aplicações incluem a reconstrução de modelos 3D para uso em videogames ([ABLAN, 2007](#)), filmes ([ABLAN, 2007](#)), arqueologia, arquitetura, modelagem 3D urbana (*e.g.*, Google Streetview); técnicas de *match-moving* em cinematografia para fusão de conteúdo virtual e filmagem real ([DOB-BERT, 2012](#)), a organização de uma coleção de fotografias com relação a uma cena (*e.g.*, o sistema *Phototourism* ([AGARWAL et al., 2010](#)) e a funcionalidade *Look Around* do Google Panoramio e Steet View), manipulação robótica, e a metrologia a partir de câmeras na indústria automobilística e metal-mecânica.

Os desafios estão ligados às escolhas de grande escala de representações adequadas e de técnicas que possam modelar simultaneamente com materiais drasticamente diferentes (*e.g.*, não-Lambertianos), modelos geométricos (*e.g.*, variedades curvilíneas gerais, descontinuidades, texturas, deformações, em escalas diferentes), tipos de regiões (com ou sem textura), condições de iluminação variadas, sombras, fortes diferenças de perspectivas, desbalanceamento devido a excesso de detalhes em partes menos importantes, número arbitrário de objetos e câmeras não-calibradas.

Mesmo que um sistema completo esteja fora do alcance da tecnologia atual, um progresso significativo tem sido atingido nos últimos anos. Por um lado, uma tecnologia operacional tem evoluído, mais recentemente para sistemas de grande escala ([AGARWAL et al., 2011](#)), a partir do desenvolvimento da detecção robusta de *features* ([MIKOLAJCZYK, 2002](#)), o *fitting/ajuste* robusto e seleção de correspondências baseados em RANSAC, e o desenvolvimento de métodos de geometria projetiva para calibrar duas ou três imagens e progressivamente adicionar imagens e extrair estrutura 3D dessas *features* na forma de nuvens de pontos. Com o código fonte do sistema Bundler ([SNAVELY et al., 2010](#)) liberado por Noah Snavely, e sua subsequente incorporação ao sistema VisualSfM ([WU et al., 2011b](#)), torna-se possível tentar utilizar este sistema para a reconstrução de patrimônio cultural em larga escala, como um jardim de esculturas. Um dos objetivos do presente trabalho é estudar até onde se pode chegar com a aplicação de tais técnicas recentes à futura reconstrução completa do Jardim do Nêgo, em Nova Friburgo, como parte de um projeto maior.

No paradigma usando-se apenas imagens convencionais – denominado **reconstrução estéreo multiocular passiva** – a posição das câmeras são estimadas a partir apenas de imagens, usando pontos de interesse; em seguida, uma nuvem de pontos é re-

construída, Figuras 34, 34, 36 e 26. As câmeras podem então ser utilizadas para obter modelos mais detalhados de reconstrução, como algoritmos de densificação (FURUKAWA; PONCE, 2007) e interpolação (HAIGHT, 1967) da nuvem de pontos, bem como demais algoritmos densos de visão estéreo multi-perspectiva/multi-ocular, como os do grupo de Michel Goesele (FUHRMANN; LANGGUTH; GOESELE, 2014), também com código disponível. Tais algoritmos, no entanto, apresentam problemas, em particular a reconstrução suaviza partes bem-delineadas do objeto, e pode conter buracos em áreas homogêneas. Pode-se, portanto, utilizar no futuro a reconstrução 3D de curvas desenvolvida pelo grupo do prof. Fabbri (USUMEZBAS; FABBRI; KIMIA, 2016; FABBRI; KIMIA, 2016; FABBRI; KIMIA, 2010; FABBRI; GIBLIN; KIMIA, 2012) para auxiliar na reconstrução mais bem-delinada nesses casos problemáticos, bem como para ajudar no problema de escalarabilidade quando a reconstrução 3D se torna muito grande.

Um segundo paradigma, denominado **reconstrução estéreo multiocular ativa**, tem se tornado economicamente viável devido à indústria de videogames, e consiste na utilização de sistemas que alteram o funcionamento de câmeras convencionais, típicamente usando-se projetores infra-vermelho, *laser* ou câmeras ToF (*Time of Flight*), como no caso dos dispositivos Kinect, Figura 1.

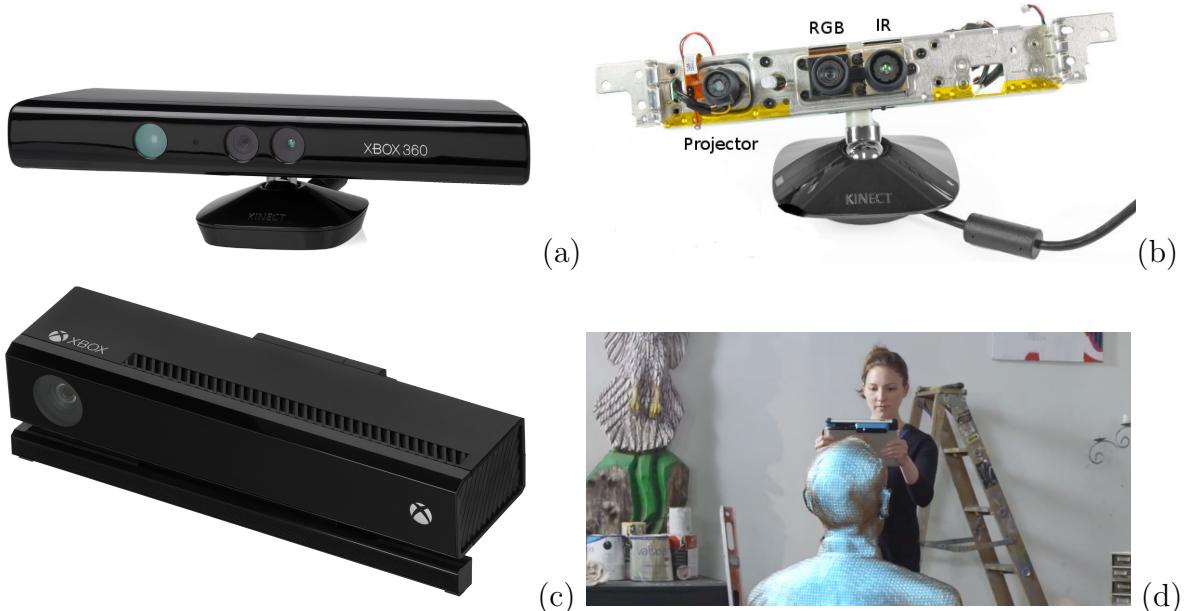


Figura 1 - Kinects de primeira geração (a) consistindo de câmeras e projetores infra-vermelho (b) e de segunda geração, consistindo de tecnologia ToF (c). Ambos os kinects são largamente utilizados para escaneamento em tempo real, formando a base de escaneadores manuais (d), porém nem sempre são úteis para preservação detalhada de patrimônio. Um dos objetivos deste projeto é explorar os limites desta tecnologia.

A preservação de patrimônio tem sido realizada tradicionalmente com escaneadores dedicados de alto custo, como no famoso projeto de escaneamento *in situ* da escultura David, chamado *Digital Michelangelo* (LEVOY et al., 2000), Figura 3. O projeto teve

início em 1992 e tem como objetivo a utilização de escaneadores a *laser* de profundidade (*Rangefinder Scanners*), aliado a algoritmos que combinam diferentes profundidades e cores da imagem, para realizar uma digitalização da parte externa e da superfície de forma acurada da estátua de David. Note-se, porém, que esse método pode ser utilizado em diferentes objetos no mundo real, como partes de máquinas, artefatos culturais e na indústria de video games, por exemplo. Para as partes mais detalhadas, foi utilizado um escaneador de menor escala que faz uma pequena triangulação com laser de profundidade.

Mais recentemente, pode-se considerar tecnologias mais acessíveis, similares às de altíssimo custo do projeto Digital Michelangelo e popularizadas na última década pela indústria de entretenimento, notadamente pelo projeto Natal/Kinect (SMISEK; JANCOSEK; PAJDLA, 2013; WANG et al., 2015). A reconstrução usando-se Kinect (de primeira ou segunda geração) usando software atual de super-resolução, é inferior à de um sistema a *laser* de alta qualidade, sendo, porém de baixo custo e muito mais versátil devido ao sistema de aquisição manual e a software amplamente utilizado e desenvolvido (WANG et al., 2015), Figura 2.

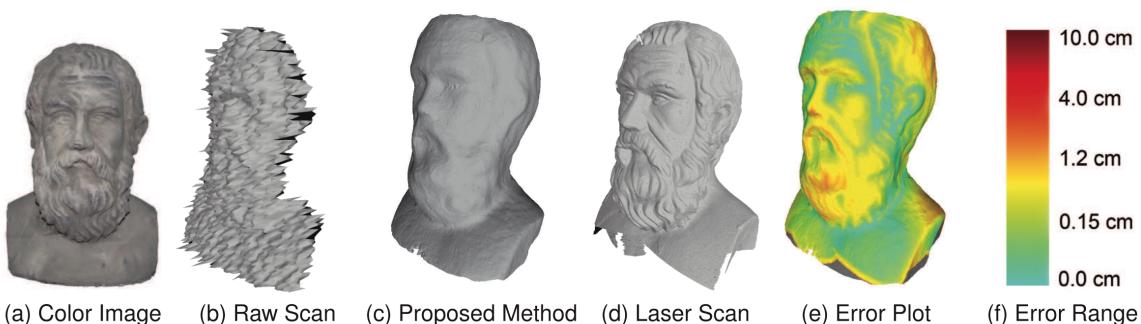


Figura 2 - A reconstrução usando-se Kinect (de primeira ou segunda geração) usando software atual de super-resolução (c) fornece precisão similar a um sistema estéreo de média resolução, inferior um sistema a *laser* de alta qualidade (d) porém de baixo custo e muito mais versátil devido ao sistema de aquisição manual e a software amplamente utilizado e desenvolvido (WANG et al., 2015).

O Jardim do Nêgo, Nova Friburgo

No caso de Nova Friburgo, há a necessidade redobrada de preservação de patrimônio a céu aberto, em especial devido às chuvas e deslizamentos inerentes à região. O Jardim do Nêgo consiste em grandes esculturas em encostas, cobertas por um tapete de vegetação, as quais desfrutam de grande reconhecimento regional e internacional (WITNESS, 2014), Figura 4.

Idealizado e criado por Geraldo Simplicio (Nêgo), artista cearense que mora no local

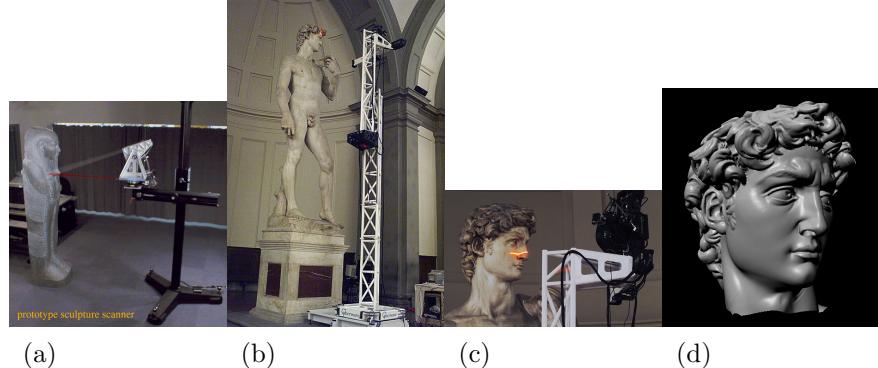


Figura 3 - Protótipo do escaneador a *laser* de triangulação. O objeto a ser escaneado é uma réplica em tamanho real de um sarcófago egípcio (a). O escaneador foi reconfigurado para escanear objetos maiores, pois a escultura possui 517 centímetros (b), o da cabeça também sofreu uma reconfiguração, este escaneador gira em 90 graus, que faz o *laser* rotacionar, da posição horizontal para a vertical e também roda em torno da cabeça como um todo (c). Para a reconstrução, o primeiro passo foi alinhar cerca de 100 scans em diversas posições, após isso, utilizado um alinhamento automático em pares dos scans, utilizando um algoritmo modificado de iterações de pontos próximos (ICP - *Iterated-Closest-Points*). Após isso, faz-se um processo de relaxação global a fim de minimizar erros de alinhamento por toda a estátua. Depois de alinhados, usa-se o algoritmo de profundidade volumétrica de processamento de imagens (VRIP - *Volumetric Range Image Processing* - de Brian Curless) (d) (LEVOY et al., 2000)



Figura 4 - Algumas esculturas do Jardim do Nêgo (WITNESS, 2014)

a mais de 30 anos, e que ganhou notoriedade por suas esculturas de barro, com traços singulares e técnicas únicas. Hoje, trabalha para reconstruir o Jardim após a tragédia de 2011 na região serrana, onde algumas estruturas foram destruídas. Portanto, com o consentimento do Nêgo, surgiu a motivação desta pesquisa: além de explorar métodos de reconstrução, também tem o objetivo de ajudar a criar sistemas completos para eternizar um patrimônio que é reconhecido no mundo todo.

A preservação das esculturas do Jardim do Nêgo se mostra um desafio à pesquisa em reconstrução 3D, pois apresentam curvas bem delineadas, que são representadas de maneira suavizada e empobrecida por métodos convencionais. Algumas esculturas apresentam pouca textura, com apenas um leve padrão de musgo. Seria de grande interesse avaliar o

potencial de técnicas atuais de reconstrução 3D geral que não exigem controle preciso de aquisição, as quais têm seu código fonte disponível na internet.

1.1 Objetivos

Pretende-se, ao longo deste projeto, ganhar experiência com técnicas modernas de reconstrução 3D fotogramétrica, no contexto de uma aplicação bem-definida de preservação de patrimônio.

O objetivo concreto é explorar as tecnologias supracitadas para desenvolver um esquema de escaneamento de patrimônio usando software aberto, câmeras e escaneadores de baixo custo, representando o estado da arte em reconstrução 3D sem restrições de aquisição. Perguntas fundamentais a serem respondidas são: que nível de detalhe, facilidade e precisão se pode obter usando-se apenas imagens e software aberto? É possível utilizar escaneadores de baixo custo baseados em Kinect com melhorias significativas em termos de qualidade, conveniência ou tempo de processamento? Quais são as restrições desses sistemas? Seria útil, na prática, uma reconstrução de curvas para auxiliar na reconstrução de nuvem de pontos e de superfícies densas? Onde o estado da arte deve ser avançado de forma a permitir uma solução mais conveniente e completa para a preservação de patrimônio?

O principal objetivo em termos de pesquisa científica será comparar as diferentes abordagens do estado da arte disponíveis para reconstrução 3D e explicitar suas limitações práticas.

Organização deste manuscrito

Este trabalho foi estruturado da seguinte maneira: Introduzimos métodos baseados em reconstrução a *laser* no Capítulo 2, apresentando, de uma maneira mais técnica, o projeto *Digital Michelangelo* na Seção 2.1, que foi um dos pioneiros na técnica de conservação de acervos culturais. No próximo Capítulo 3, discutimos o uso do Kinect, da Microsoft, no que tange à calibração do sistema para o uso em tecnologias *Structure from Motion*. Adiante, no Capítulo 4, abordaremos o tema central do trabalho: técnicas de reconstrução baseadas em fotogrametria, com o emprego de dois softwares, o MVE 4.1 e o VisualSfM 4.2 e seus respectivos funcionamentos. Ao final, apresentamos experimentos e conclusões do trabalho, bem como sugestões para implementações e trabalhos futuros.

2 RECONSTRUÇÃO 3D ATIVA

Introdução

A técnica de reconstrução 3D baseada em *laser* é conhecida desde o século passado, pois oferece uma alta qualidade geométrica de dados, até mesmo para regiões sem textura. Neste capítulo, abordaremos o projeto clássico de escaneamento da escultura de Michelangelo, Davi, que utiliza escaneadores por laser, também relacionados a técnicas de luz estruturada e uma técnica conhecida como *Time of Flight*, ou tempo de voo, Figura 5. Esse processo se baseia em projetar um padrão conhecido (muitas vezes, grades ou barras horizontais, via *laser* ou luz infra-vermelho) em uma cena. A forma como o padrão se deforma quando atinge superfícies permite que sistemas de visão calculem a profundidade e informações das superfícies dos objetos na cena.

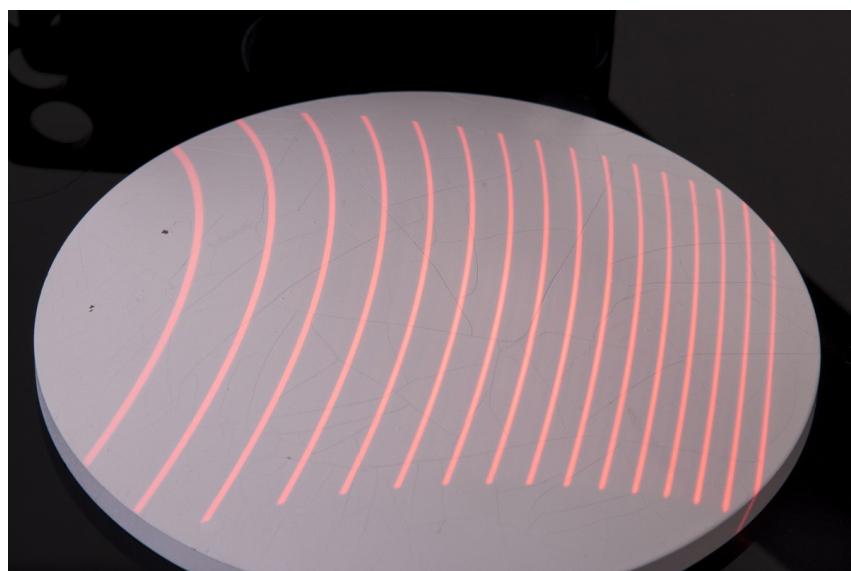


Figura 5 - Exemplo de um projetor de padrões utilizando um *laser* visível. ([OPTO...](#), 2017).

2.1 Projeto de preservação das esculturas de Michelangelo

Introdução

O projeto Digital Michaelangelo ([LEVOY et al., 2000](#)) tem como motivação avançar a tecnologia de digitalização 3D e criar um acervo digital sobre alguns dos principais artefatos culturais. Foram utilizados sensores de profundidade (*range finders*) para triangulação, sensores de profundidade baseados em ToF (*Time of Flight*), câmeras digitais

e um software de calibração. Uma equipe de mais de 30 professores pesquisadores, funcionários e estudantes das Universidades de Stanford e de Washington, bem como pesquisadores de empresas privadas, passaram os anos de 1998 e 1999 na Itália escaneando esculturas de Michelangelo.

O principal componente de hardware do sistema é um escaneador de triangulação a *laser*, que é composto por quatro eixos motorizados, um projetor a *laser*, uma câmera de profundidade, uma câmera de cores RGB e uma luz branca [6](#), isso tudo acrescido de suportes e estruturas para o escaneamento de estátuas grandes. O objetivo de um escaneador deste porte era capturar marcas menores que um milímetro, das ferramentas utilizadas por Michelangelo em suas esculturas, Figura [8](#). Para isso, foram testadas diversas resoluções, tendo sido decidido um espaçamento Y (ao longo da faixa do *laser*) de 1/4 mm e uma resolução Z (profundidade) de pelo menos duas vezes este valor. Isso resultou em uma visualização de 14 cm de largura (ao longo da faixa do *laser*) por 14 cm de profundidade. Caso esta resolução fosse menor, as marcas de cinzel ficariam borradadas e, se fosse maior, o conjunto de dados produzido seria gigantesco. Felizmente, a maioria das estátuas feitas por Michelangelo foram esculpidas com um mármore encontrado em Carrara, chamado Statuario, uma pedra altamente uniforme, não direcional e constituída de grãos finos. Além disso, com exceção de “Noite” [7](#), as esculturas não são polidas e cobertas por terra, o que aumenta a dispersão superficial e reduz a abaixo da superfície. Nesse contexto, a dispersão abaixo da superfície causa alguns problemas: não se pode assumir que a superfície é Lambertiana ideal ([BASRI; JACOBS, 2003](#)), o que mudou a forma com que a renderização dos modelos seria feita e diminuiu a qualidade de disposição de dados.

Calibração

O objetivo de calibrar o aparato era encontrar um mapeamento de coordenadas 2D no seu alcance e cores para coordenadas 3D em um quadro de referência global. Idealmente, este quadro deve ser a estátua (estacionária). Porém, na prática o aparato tornou-se a própria referência. O mapeamento final do aparato à estátua foi realizado alinhando-se novas reconstruções com aquelas provenientes de varreduras previamente existentes, conforme detalhado no artigo original ([LEVOY et al., 2000](#)).

Para calibrar qualquer sistema, primeiramente escolhe-se um modelo matemático que se aproxime do comportamento do sistema, então estima-se parâmetros desse modelo medindo o comportamento do sistema. No caso do projeto de David, o modelo matemático natural era um modelo geométrico 3D parametrizado da cabeça digitalizada e do aparato. Se os componentes do sistema forem suficientemente independentes, a calibração pode ser dividida em estágios, correspondente a cada componente do sistema. Por isso o aparato foi

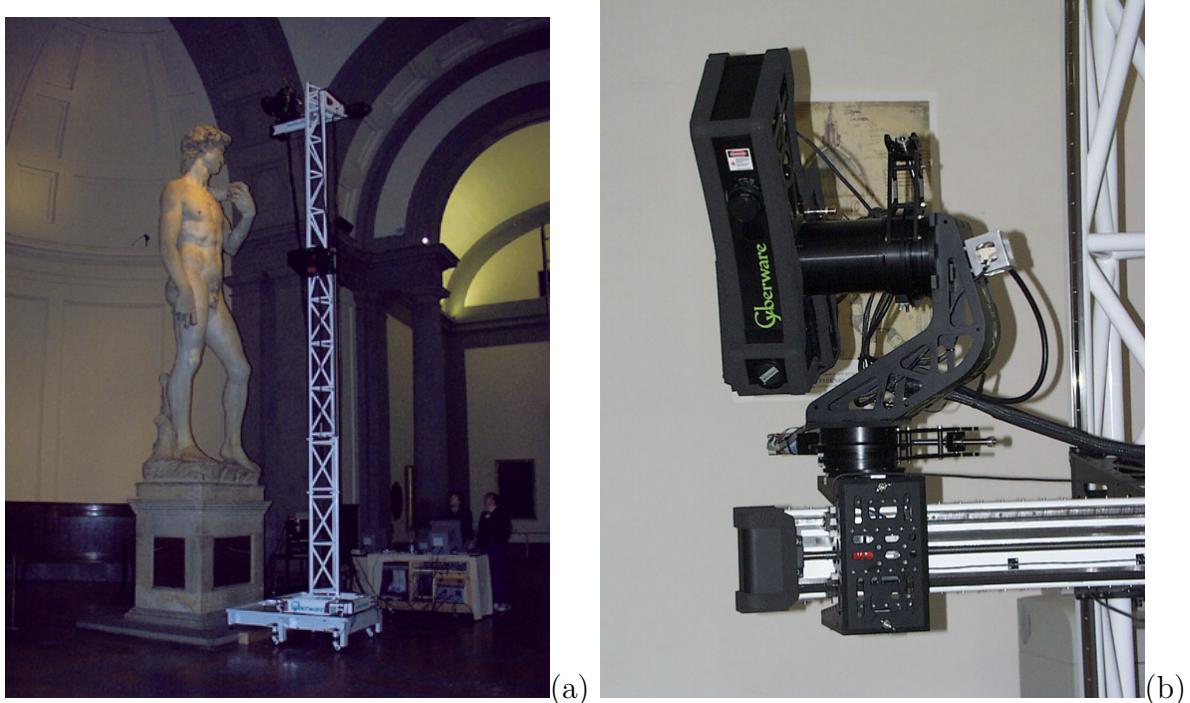


Figura 6 - Como era feito o escaneamento da estátua de David (a), composto por dois escaneadores, sendo (b) o escaneador principal (da cabeça) e estruturas para alcançar todos os pontos necessários (LEVOY et al., 2000).

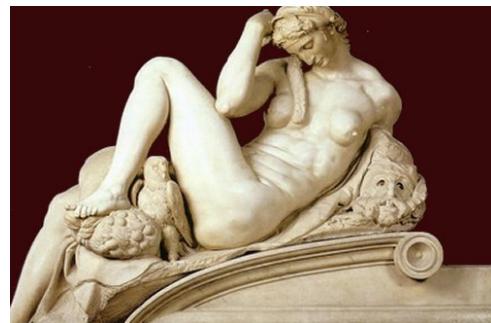


Figura 7 - Escultura “Noite”, de Michelangelo.

construído pensando na rigidez (independência), pois particionar a calibração em etapas reduz o grau de liberdade em cada etapa, e com isso, o número de medidas necessárias para calibrar este estágio.

Em um sistema mecânico, tal particionamento também reduz o volume físico total no qual essas medidas de calibração devem ser tomadas, o que é relevante dado que o sistema de aquisição é bastante grande. Além disso, uma calibração em etapas é menos suscetível à propagação de erros, pois, caso uma calibração falhasse, seria apenas uma parte da calibração e não o sistema como um todo. No projeto de David, a calibração foi dividida em seis etapas distintas:

1. Um mapeamento 2D a partir de coordenadas de *pixels* das imagens da câmera de profundidade para localizações físicas na camada de laser

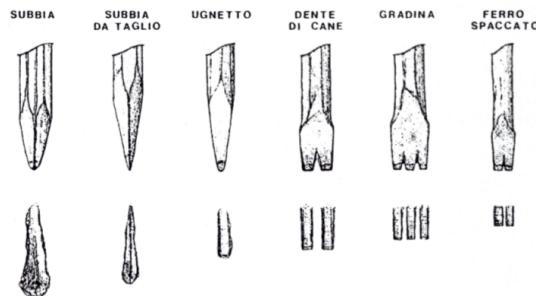


Figura 8 - Alguns tipos de cincéis que provavelmente foram usados por Michelangelo na escultura de "St. Matthew". (LEVOY et al., 2000).

2. Uma transformação rígida 2D/3D do sistema de coordenadas da camada de *laser* para esferas de aço anexadas à cabeça do escaneador
3. Transformação rígida 3D para acomodar o rolamento da cabeça do escaneador em 90° (ao remontá-lo) em relação ao conjunto *pan-tilt*
4. A localização do eixo de rotação de inclinação *tilt* e o mapeamento não-linear dos comandos de movimento para ângulos de rotação físicos
5. A localização do eixo de rotação *pan* e o mapeamento de seus comandos de movimento para ângulos de rotação físicos
6. A localização do eixo de translação, que também depende de como o conjunto *pan-tilt* está montado no braço horizontal

O resultado da calibração pode ser descrito como uma concatenação de seis matrizes 4x4:

$$\begin{bmatrix} \text{translação} \\ \text{horizontal} \end{bmatrix} \begin{bmatrix} \text{rotação} \\ \text{pan} \end{bmatrix} \begin{bmatrix} \text{rotação} \\ \text{de} \\ \text{tilt} \end{bmatrix} \begin{bmatrix} \text{rotação} \\ \text{de} \\ \text{rolamento} \end{bmatrix} \begin{bmatrix} \text{laser para a} \\ \text{cabeça do} \\ \text{escaneador} \end{bmatrix} \begin{bmatrix} \text{imagem} \\ \text{para o} \\ \text{laser} \end{bmatrix}.$$

Procedimento de digitalização

Um operador move interativamente a cabeça do escaneador através de uma sequência de movimentos, definindo os limites do volume a ser escaneado. O volume que pode ser coberto em uma única varredura foi delimitado por conta de quatro fatores:

- O campo de visão e os limites de movimento do escaneador
- A queda na qualidade da varredura com o aumento da obliquidade do laser

- Oclusões, tanto do *laser* quanto da linha de visão da câmera
- Obstruções físicas, como paredes, estátuas ou o próprio equipamento

Uma vez planejada a varredura, um *script* de digitalização é executado automaticamente, levando desde alguns minutos, até horas para terminar, dependendo da largura da área a ser coberta. A partir do *script*, são feitas as etapas de escaneamento de profundidade (*laser*) e do escaneamento da fotometria (câmera digital RGB).

Primeiramente faz-se o escaneamento fotogramétrico da geometria da escultura:

1. Alinhamento manual
2. ICP – *Iterative Closest Point* para uma câmera existente
3. ICP automático para todos os pares sobrepostos
4. Relaxação global para espalhar o erro
5. Reunir utilizando métodos volumétricos

Após isso, ocorre o escaneamento fotométrico e o processamento das cores da escultura:

1. Compensação da iluminação do ambiente
2. Descarte de pixels com sombra ou reflexos especulares
3. Mapeia-se os vértices (uma cor por vértice)
4. Correção da irradiância e reflectância difusa

Limitações:

- Inter-reflexões são ignoradas
- Dispersões subterrâneas (*subsurface scattering*) são ignoradas
- Tratamento de efeito difuso como Lambertiano
- Uso de normais de superfícies suavizadas

O projeto não teve mais nenhum avanço desde o verão de 2004, por falta de financiamento. Como resultado, modelos de alta qualidade só existem do David na resolução de 1,0 mm (56 milhões de triângulos) e São Mateus a 0,25 mm (372 milhões de triângulos). Um modelo também existe para o Atlas em 0,25 mm (aproximadamente 500 milhões de triângulos), mas contém erros de alinhamento. Também foram disponibilizadas algumas métricas sobre este projeto na Tabela 1.

Tabela 1 - Métricas do projeto de reconstrução da escultura David

Números de objetos escaneados	10 estátuas + 2 edificações + 1.163 fragmentos de mapa
Menor e maior objetos escaneados	1 polegada (fragmentos de mapa) e 23 pés (David)
Resolução espacial dos dados	0,29mm para geometria, 0,125mm para cor
Complexidade do maior conjunto de dados	2 bilhões de polígonos + 7.000 imagens (David)
Tamanho do maior conjunto de dados	32 <i>gigabytes</i> (David)
Quantia total de dados capturados	250 <i>gigabytes</i>
Tamanho do maior escaneador	24 pés de altura, 1.800 libras de peso
Peso total do equipamento levado para a Itália	4 toneladas
Número de pessoas envolvidas	32 (sem incluir subcontratantes e colaboradores)
Tempo médio para escaneamento	1 semana (exceto o David, que levou 1 mês)
Tempo total de escaneamento	5,00 horas de trabalho
Total de tempo para processamento de dados	4.000 horas de trabalho (até agora)
Custo do projeto	\$2.000.000

Porém, devido ao seu alto custo com equipamentos, com softwares especializados e na necessidade de estações robustas para armazenamento dos dados e para escaneamento de patrimônios, outras técnicas foram emergindo com o passar dos anos, como a fotogrametria passiva, usando apenas imagens, que será abordada ao decorrer deste manuscrito.

3 TÉCNICAS DE LUZ ESTRUTURADA E *TIME OF FLIGHT*

Introdução

A técnica de luz estruturada é um **método fotogramétrico ativo** que consegue determinar a localização de objetos no alcance do sensor de infra-vermelho, a partir de alterações nos padrões conhecidos de um projetor infra-vermelho. Um exemplo recente de escaneador de luz estruturada de baixo custo é o Kinect versão ([SMISEK; JANCOSEK; PAJDLA, 2013](#)), que também serve como base para uma série de scanners que utilizam o mesmo hardware. Uma vantagem clara em relação aos escaneadores a *laser* é a velocidade e o baixo custo; uma desvantagem é a precisão, conforme discutido mais adiante. Existe também, um outro método fotogramétrico ativo denominado *Time of Flight* ([GOKTURK; YALCIN; BAMJI, 2004](#)), que em vez de padrões infra-vermelho ou laser, emite fôtons a cada pixels, que viajam na velocidade da luz. O valor resultante da diferença da emissão e do retorno dos fôtons aos detectores é utilizado na criação de uma distribuição de probabilidade localizando o evento detectado a uma distância do eixo do escaneador.

Até recentemente, a técnica ToF foi extremamente cara e restrita a baixas resoluções, devido à necessidade de equipamento capaz de medir fôtons refletidos em uma escala de picosegundos. Tal técnica foi barateada em ordens de magnitude pela indústria de entretenimento, no lançamento recente do Kinect versão 2 ([LACHAT et al., 2015; VALGMA, 2016](#)). Além do baixo custo permitido pelo Kinect 2, uma vantagem desta técnica é a alta velocidade de escaneamento e maior robustez dos resultados se comparado à técnica de luz estruturada e mesmo escaneadores a *laser*. No entanto, ela não pode ser aplicada com confiabilidade em ambientes abertos, e não supera a precisão de um bom escaneador a *laser*. Note-se que, no entanto, escaneadores a *laser* Não são adequados para aplicações em tempo real; porém, para o nosso objetivo de preservação de patrimônio, o requisito de escaneamento em tempo real é secundário, sendo desejável apenas para aplicações em que uma previsão rápida da reconstrução 3D é desejada pelo arqueólogo, ou para realidade aumentada. A seguir, discutimos essas tecnologias de reconstrução 3D ativas em maiores detalhes.

3.1 Kinect

Introdução

Criado pela Microsoft para fins recreativos (como no console de videogame XBox, por exemplo), o Kinect se tornou uma das mais conhecidas ferramentas de reconstrução

3D no cenário atual. Sua primeira versão (Kinect V1) [9](#), ainda atual, utiliza uma técnica similar à empregada no projeto *Digital Michelangelo* da Universidade de Stanford, com luz estruturada, porém, diferentemente dos escaners a *laser*, o Kinect é mais rápido e tem um custo monetário baixo, acessível ao público em geral (desde entusiastas e amadores até profissionais da área).

O Kinect versão 2 é composto de uma câmera RGB-D (*red, green, blue* e *depth*) e utiliza uma projeção de fótons, sendo mais robusto que seu antecessor, para ambientes fechados e para fins de escaneamento de formas humanas (como esqueleto, músculos, e até mesmo para medir o batimento cardíaco, por exemplo). Devido à técnica empregada para reconhecimento 3D *Time of Flight*, ele é muito sensível às texturas presentes no objeto, ou seja, esculturas com diferentes superfícies, diferentes refletâncias, lambertianas ou especulares, por exemplo, podem acarretar em problemas ou buracos nas reconstruções. Além disso, existem outros obstáculos, como a dificuldade em que o fóton emitido rebate em várias superfícies antes de ser detectado pelo sensor. Portanto, para o uso em áreas externas, a primeira versão do Kinect se sai melhor.

O Kinect versão 1 é composto por duas câmeras: uma RGB apenas para cores e aparência, e outra câmera infra-vermelho para profundidade, atuando em sincronia com um projetor de padrões em infra-vermelho (IR ou *infra-red*). O projetor IR lança uma matriz de padrões que já é previamente conhecida pelo sistema do Kinect, e, a partir disso, qualquer deformação deste padrão é captada pela câmera IR, o que identifica se um objeto está no alcance dos sensores ou não. O espectro infra-vermelho é utilizado por não ser percebido pela visão humana. A resposta é composta por 3 saídas: uma imagem de intensidades IR, uma RGB e a profundidade de cada pixel.

A seguir, será usado o termo “Kinect” para o Kinect versão 1, pois este é ainda o modelo mais utilizado na literatura para o escaneamento de objetos, conforme é o foco deste trabalho, em vez do rastreamento em tempo real para entretenimento, que é dominado pelo Kinect versão 2.

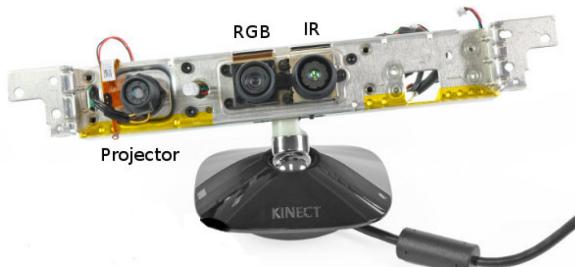


Figura 9 - Imagem de um Kinect V1 aberto, constituído de uma câmera infra-vermelho (IR - *Infra-Red*), uma câmera RGB e um projetor IR. ([SMISEK; JANCOSEK; PAJDLA, 2013](#)).

Processo de calibração

A principal saída do Kinect é correspondente à profundidade da cena. Na realidade, em vez de providenciar uma profundidade Z , ele retorna uma profundidade inversa, D . Essa informação é construída a partir da triangulação da imagem IR com o padrão conhecido do projetor.



Figura 10 - Exemplo de como é a saída de uma imagem interpretada pelo Kinect, onde cada disposta na imagem corresponde à profundidade ou distância da cena para o Kinect, e preto corresponde a pontos sem informação confiável. (SILBERMAN DEREK HOIEM; FERGUS, 2012).

Na literatura, foram realizados alguns experimentos associando o uso do Kinect V1 como um escaneador de baixo custo em reconstruções (SMISEK; JANCOSSEK; PAJDLA, 2013), tarefa para a qual não foi originalmente projetado. Primeiramente, foi executada uma calibração do Kinect para este tipo de reconstrução, onde, a partir de experimentos, o sistema foi modelado como

$$q(z) = 2.73z^2 + 0.74z - 0.58 \quad (1)$$

onde z é a profundidade em metros, e q a quantização, em milímetros. O modelo geométrico do Kinect foi criado com um sistema multi-ocular (*multi-view*) considerando o RGB, IR e a profundidade.

$$\begin{bmatrix} u \\ v \\ 1 \end{bmatrix} = k \begin{bmatrix} s \\ t \\ 1 \end{bmatrix} \quad (2)$$

$$\begin{bmatrix} s \\ t \\ 1 \end{bmatrix} = \underbrace{(1 + k_1 r^2 + k_2 r^4 + k_5 r^6) \begin{bmatrix} p \\ q \\ 0 \end{bmatrix}}_{\text{distorção radial}} + \underbrace{\begin{bmatrix} 2k_3 pq + k_4(r^2 + 2p^2) \\ 2k_4 pq + k_3(r^2 + 2q^2) \\ 1 \end{bmatrix}}_{\text{distorção tangencial}} \quad (3)$$

$$r^2 = p^2 + q^2, \begin{bmatrix} pz \\ qz \\ z \end{bmatrix} = R(X - C), \quad (4)$$

onde k_n é o parâmetro de distorção, matriz de calibração da câmera K , rotação R e centro de projeção C . A profundidade é associada à geometria da câmera IR, que retorna a profundidade inversa ao longo do eixo z . Os valores de u e de v são dados pela equação 3,

$$X_{IR} = \frac{1}{c_1 d + c_0} dis^{-1} \left(K_{IR}^{-1} \begin{bmatrix} x + u_0 \\ y + v_0 \\ 1 \end{bmatrix}, k_{IR} \right) \quad (5)$$

$$u_{RGB} = K_{RGB} dis(R_{RGB}(X_{IR} - C_{RGB}), k_{RGB}). \quad (6)$$

Associamos o sistema de coordenadas do Kinect com a câmera IR e, consequentemente, $R_{IR} = I$ (identidade) e $C_{IR} = 0$. O ponto 3D X_{IR} é construído a partir da medição de $[x, y, d]^\top$ da equação 5 e produz uma imagem RGB, Equação 6.

Em 5, dis é a distorção, proveniente de 3, k_{IR} e k_{RGB} são, respectivamente, distorção relacionada à IR e à RGB. K_{IR} é a matriz de calibração da câmera IR, K_{RGB} é a matriz de calibração da câmera RGB. R_{RGB} e C_{RGB} são, a matriz de rotação e de centro da câmera RGB, respectivamente.

A calibração ocorreu usando o mesmo alvo nas câmeras IR e RGB, mesmos pontos 3D, e consequentemente, a mesma posição relativa das câmeras. O sistema de coordenadas global do Kinect faz a posição relativa da câmera igual a R_{RGB} , C_{RGB} .

Também foi observado que existe um deslocamento entre imagem IR e a imagem da profundidade criada pelo Kinect. Para contornar este problema, uma série de experimentos foram executados, gerando 2.

Foi observado que após a calibração, o Kinect gerava erros residuais complexos, que para compensar esse erro residual, foi criada uma correção em z , onde é subtraído da coordenada Z_{IR} de 5. Para validar essa correção, a correção-z das imagens foram

Tabela 2 - Valores de deslocamentos e sua média

Imagen	1	2	3	4	Média
u_0	2,8	2,9	3,0	3,4	3,0
v_0	3,0	2,7	2,8	3,1	2,9

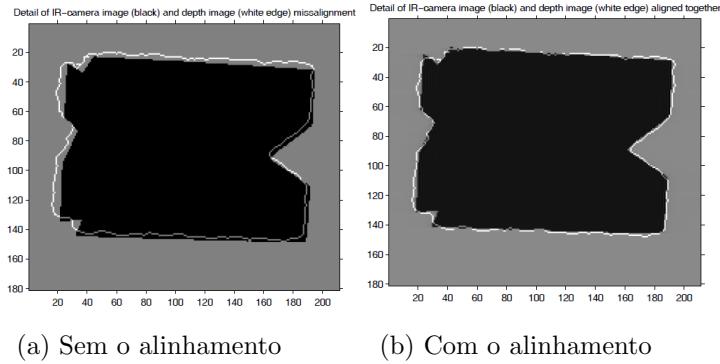


Figura 11 - Representação visual do acerto do deslocamento. A parte em preto é a imagem IR e o contorno em branco é a imagem de profundidade do alvo. (SMISEK; JANCSEK; PAJDLA, 2013)

construídas a partir dos resíduos das imagens ímpares e aplicadas nas pares, e o vice-versa. Depois da aplicação da correção-z , a media dos erros diminuiu aproximadamente 0,25mm. Como parâmetro de comparação, foram dispostas 2 câmeras diferentes, no mesmo ambiente do Kinect.

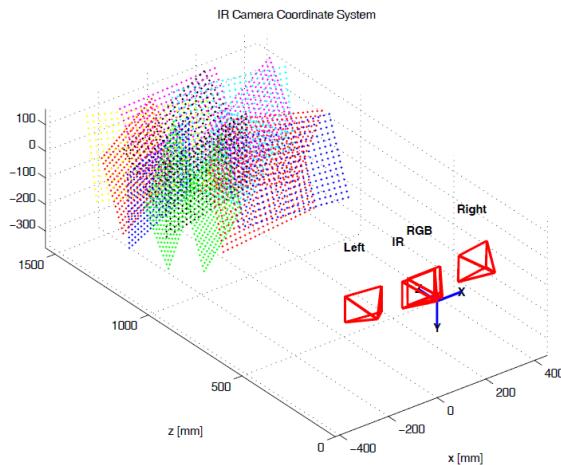


Figura 12 - Posição e orientação do Kinect (com as câmeras IR e RGB) e o par estéreo SLR (*Left*, *Right*) em conjunto com pontos de calibração 3D reconstruídos em alvos de calibração planar. (SMISEK; JANCSEK; PAJDLA, 2013).

Tabela 3 - Resultados dos testes executados no ambiente descrito anteriormente

Método	Erro geométrico e [mm]		
	$\mu(e)$	$\sigma(e)$	$\max(e)$
SLR Stereo	1,57	1,15	7,38
Kinect	2,39	1,67	8,64
SR-4000	27,62	18,20	133,85

Uso do Kinect com *Structure from Motion*

Com o sistema calibrado, o Kinect foi testado usando técnicas *Structure from Motion*, onde a figura a seguir compara a superfície 3D de nuvem de pontos com uma com Kinect (SMISEK; JANCOSEK; PAJDLA, 2013). O resultado é tão bom quanto ao mais acurado resultado de *Multi-View Stereo*.

O Kinect, com o procedimento de calibração, pode ser combinado com técnicas *SfM* e *multi-view stereo*, o que abre uma nova metodologia na área de reconstrução 3D. Quanto à qualidade da reconstrução, o Kinect ficou melhor que o SR-4000 e perto do 3.5M SLR Stereo, figuras 13, 14 e tabela 3.

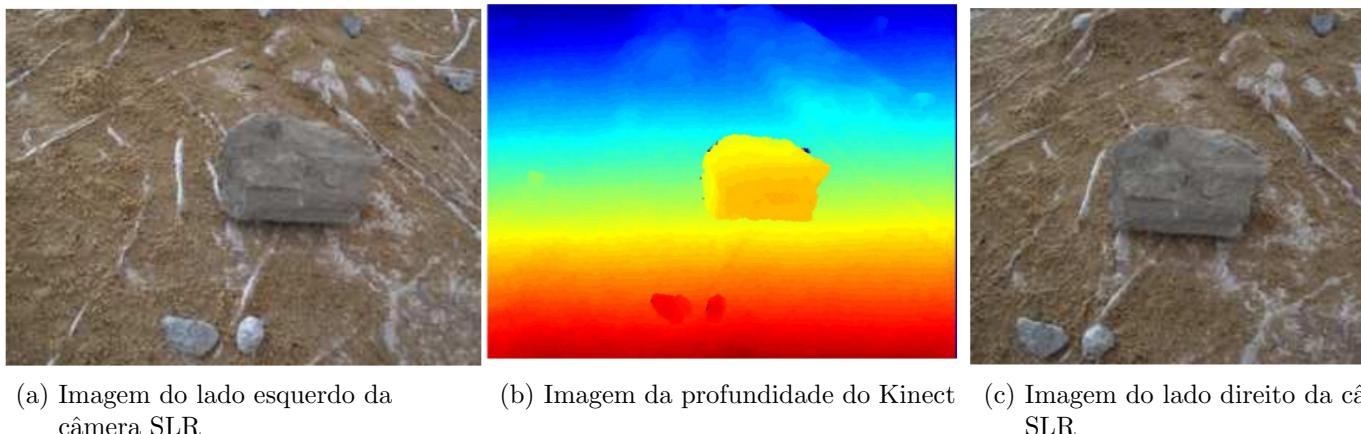


Figura 13 - Imagens iniciais para reconstrução 3D (SMISEK; JANCOSEK; PAJDLA, 2013).

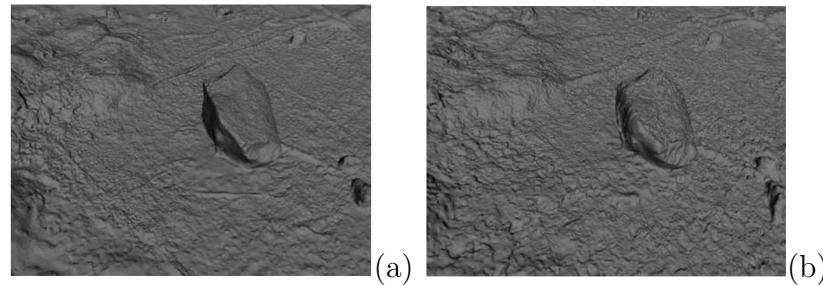


Figura 14 - Resultados da reconstrução SfM, onde (a) é a reconstrução do SLR e (b) o resultado do Kinect. Qualitativamente ambas são satisfatórias (SMISEK; JANCSEK; PAJDLA, 2013).

O Kinect é tão utilizado para fins pessoais e empresariais, que existem alguns softwares prontamente disponíveis para utilizá-lo como uma ferramenta de reconstrução 3D, sendo a maioria deles acessíveis (incluindo um pacote de ferramentas que a própria Microsoft disponibilizou para adaptar o Kinect ao Windows).

Além disso, a Microsoft criou um software para Windows chamado Kinect Fusion, que promove escaneamentos usando o Kinect, de um dado objeto e cria um modelo 3D. O usuário pode pintar uma cena com o Kinect e, ao mesmo tempo, interagir com o modelo 3D detalhado.

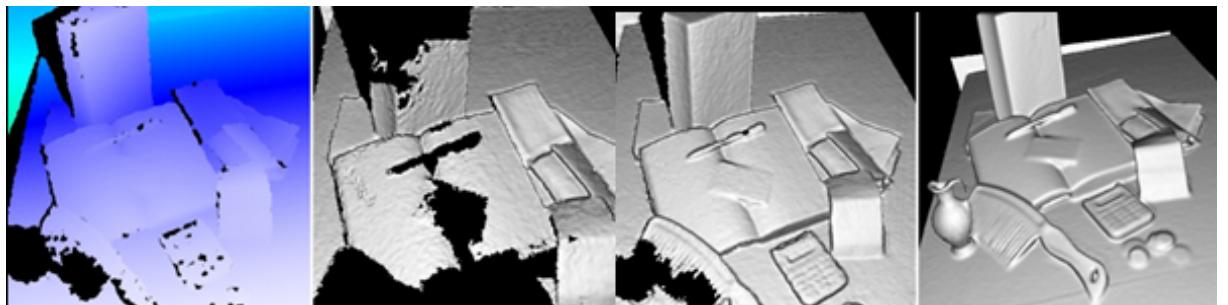


Figura 15 - Funcionamento do Kinect Fusion, adquirindo o mapa de profundidade com a câmera do Kinect, onde há várias falhas devido à falta de dados. Em alguns segundos é realizada uma reconstrução 3D realista de uma cena estática apenas movendo o Kinect ao redor da cena. Após isso, uma nuvem de pontos ou uma malha 3D densa pode ser produzida. (IZADI et al., 2011)

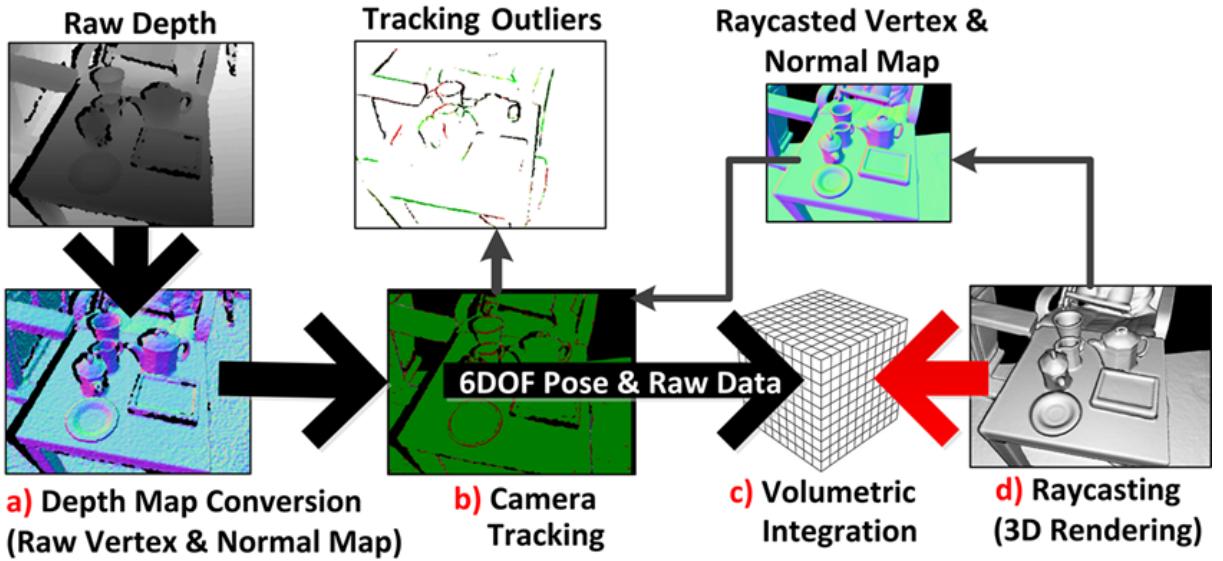


Figura 16 - Processo de escaneamento e geração do modelo 3D no Kinect Fusion. (IZADI et al., 2011)

Outro programa conhecido é o *Skanect*, que tem a versão gratuita com a qual é possível fazer escaneamentos básicos, bem como a versão paga, que possibilita uma configuração mais detalhada, como por exemplo: a delimitação do objeto que será reconstruído; exportar o arquivo em diferentes formatos (*.PLY* e *.OBJ*, formatos para exportação para programas que trabalham o modelo gerado, como Blender ou Sculptris); escolher o número de faces a ser exportado; e suporte a demais formatos como *STL* (próprio para a impressora 3D, através de software como o *Cura*) e *VRML*, além de salvar também as cores do modelo.

Entretanto, uma desvantagem que diminui a aplicabilidade do Kinect é que ele foi projetado para funcionar bem em espaços fechados, com detecção de formas humanas e movimentações. Ou seja, numa aplicação *in situ* já não funcionaria muito bem, pois além de não conseguir escanear os detalhes em alta definição de uma escultura, ele necessita de uma fonte de energia externa, diferentemente de um *smartphone* ou câmera convencional, o que dificulta a acessibilidade. Ademais, como é gerada uma reconstrução em tempo real (não tem uma forma de salvar em *cache* ou internamente), ele precisa estar ligado a um computador para fazer o escaneamento. Algumas empresas vendem soluções mais convenientes de escaneamento 3D baseado no hardware do Kinect, porém o custo desta alternativa pode ser considerável se comparado a câmeras convencionais.

4 TÉCNICAS DE RECONSTRUÇÃO BASEADAS EM FOTOGRAMETRIA

Introdução

A reconstrução 3D pelo método da estrutura do movimento, ou *Structure from Motion (SfM)*. Tem como base a utilização de pontos de interesse (*features*), que são pontos ou áreas em comum entre as imagens usadas na reconstrução. Para encontrar estes pontos, diferentes algoritmos são empregados.

A maioria dos métodos baseados em SfM e MVS (*Multi-View Stereo*) tem uma abordagem similar e funcionam com os seguintes passos 17:

- Obtenção de imagens
- Processamento dos parâmetros de câmera para cada imagem
- Reconstrução da geometria 3D de uma cena com um conjunto de imagens e seus parâmetros correspondentes

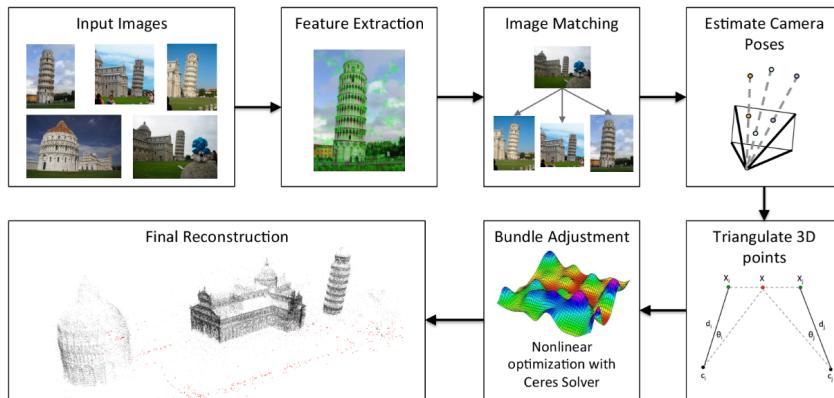


Figura 17 - Procedimento padrão da maioria dos sistemas baseados em SfM e MVS (SWEENEY, 2016).

Neste trabalho, abordaremos o uso de dois softwares baseados em MVS: o MVE (FUHRMANN; LANGGUTH; GOESELE, 2014) e o VisualSfM (WU et al., 2011b). Ambos utilizam os passos supracitados, que, posteriormente serão comentados. O que difere um do outro é a partir da etapa de reconstrução esparsa e densa, onde o MVE emprega um algoritmo de mapas de profundidade enquanto o VisualSfM utiliza um sistema baseado em *Bundle Adjustment*.

O passo de obtenção de imagens, será discutido no Capítulo de experimentos 5. Seguimos adiante com os algoritmos para processamento das imagens de entrada.

SIFT – *Scale Invariant Feature Transform*

Primeiramente, utiliza-se o SIFT (algoritmo de detecção de pontos de interesse, invariante à escala e à transformações, como rotação, translação e iluminação da imagem, por exemplo). O algoritmo pode ser dividido em cinco etapas, das quais:

- Detecção de espaço-escala extremos – *Scale-space Extrema Detection*
- Localização de pontos-chaves – *Keypoint Localization*
- Atribuição de orientação – *Orientation Assignment*
- Descritor de pontos-chaves – *Keypoint Descriptor*
- Combinação de pontos-chaves – *Keypoint Matching*

Detecção de espaço-escala extremos

Em casos com cantos pequenos, a detecção funciona bem. Porém, raramente utilizaremos a mesma janela para detectar pontos-chaves em imagens com diferentes escalas, pois utilizamos imagens grandes e, consequentemente, cantos grandes. Para isso, precisamos de janelas grandes também.

Para resolver este problema, o filtro de escala-espacó é usado: o Laplaciano de Gaussiano (*Laplacian of Gaussian* – LoG). O LoG atua como um detector de partículas em diferentes tamanhos σ . (Onde σ é o parâmetro de escala). Por exemplo, o núcleo Gaussiano com σ baixo, tem como resposta um alto valor para um canto pequeno. Enquanto um núcleo gaussiano com alto σ , se encaixa bem para um canto maior. Com esta lógica, podemos encontrar um máximo local através da escala e o espaço, o que nos fornece uma lista de $(x, y\sigma)$, o que significa que existe um ponto-chave em potencial, com o par (x, y) na escala σ .

Porém, como o LoG é um pouco custoso, computacionalmente. O SIFT utiliza um algoritmo aproximado do LoG, o DoG (Diferença de Gaussianos – *Difference of Gaussians*). O DoG é a diferença de um filtro Gaussiano de uma imagem, com dois valores diferentes de escala σ .

Uma aplicação prática do filtro DoG é a sequência de imagens a seguir:

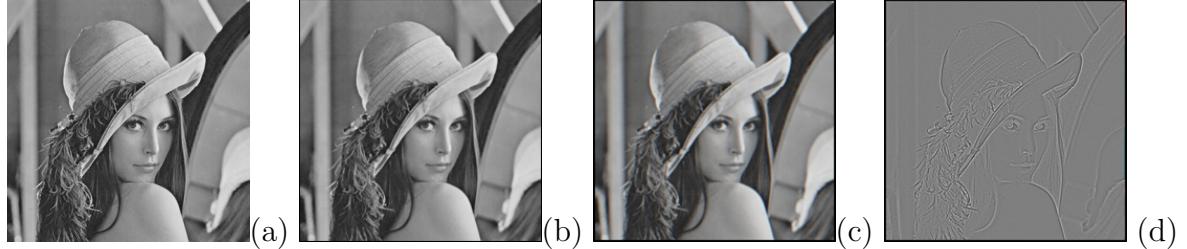


Figura 18 - É aplicado um filtro gaussiano na imagem original (a), com $\sigma = 1$, tendo como resultado a imagem (b). Um outro filtro gaussiano é usado, porém, neste caso, o $\sigma = 2$ (c). Após isso, subtrai-se (b) de (c), obtendo o filtro DoG (d).

Uma vez que o DoG é aplicado, as imagens são utilizadas com o espaço e escala extremos. Por exemplo, na imagem 19, um pixel é comparado com seus 8 vizinhos, assim como comparado com os 9 pixels na próxima escala e os 9 pixels na escala anterior. Se esse pixel é um local extremo, ele é um ponto-chave em potencial. Isto é, este ponto-chave é melhor representado nesta escala.

No caso, as funções ficariam da seguinte forma:

$$g_\sigma(x) = \frac{1}{2\pi\sigma^2} e^{-\frac{1}{2} \frac{x^T x}{\sigma^2}} \quad (7)$$

$$I_\sigma = g_\sigma * I, \sigma \geq 0 \quad (8)$$

$$\nabla^2 g_\sigma(x) \quad (9)$$

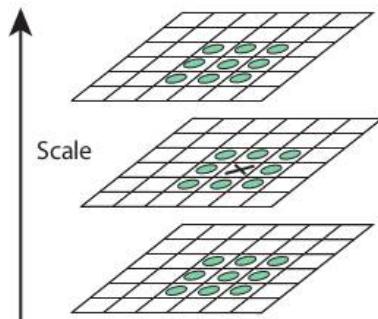


Figura 19 - Exemplo de funcionamento de detecção de espaço-escala extrema

$$DoG_\sigma(o, s) = I_\sigma(o, s + 1) - I_\sigma(o, s) \quad (10)$$

Onde 7 é a função padrão do operador gaussiano (núcleo), a equação 9 é o operador LoG, 10 é o operador DoG e ∇^2 é o operador Laplaciano.

Localização de pontos-chaves

A localização dos pontos extremos pode cair em um extremo local e não global. Logo, após a utilização do DoG e com os pontos-chaves em potencial localizados, eles precisam ser refinados para melhorar o resultado. Para isso, são utilizadas Séries de Taylor na escala e no espaço, e, se a intensidade nesse extremo é menor que o valor limite, este é rejeitado. Os *frames* do SIFT (pontos-chaves) são extraídos baseados nos extremos locais (picos) a partir do DoG. Numericamente, extremos locais são elementos que possuem um menor (ou maior) valor em uma vizinhança em um espaço 3x3x3 (em escala e espaço). Depois de extraídos, estes pontos são interpolados quadraticamente (este passo é muito importante, especialmente nas escalas de menor resolução, para ter uma localização precisa do ponto-chave na resolução completa). Finalmente, eles são filtrados para eliminar respostas de baixo contraste ou respostas próximas as bordas.

Picos que são pequenos, na maior parte das vezes são gerados a partir de ruídos e necessitam ser descartados também. Isso é feito com uma comparação de valor absoluto do DoG no pico com o valor do pico limite e é descartado caso este valor é menor que o limite.

Para eliminar respostas em bordas, normalmente os picos mais rasos ou horizontais, são gerados por bordas e não possuem características estáveis, portanto estes picos precisam ser removidos. Para isso, dado um pico (x, y, σ) , o algoritmo avalia a matriz Hessiana (x,y) do DoG na escala σ . Então é computado um valor para esta equação (11):

$$v = \frac{(T_r D(x, y, \sigma))^2}{\text{Det } D(x, y, \sigma)} \quad (11)$$

Onde, T_r é o traço, ou seja, $T_r(H) = D_{xx} + D_{yy}$ e a matriz D é do tipo

$$D = \begin{bmatrix} \frac{\partial^2 DoG}{\partial x^2} & \frac{\partial^2 DoG}{\partial x \partial y} \\ \frac{\partial^2 DoG}{\partial x \partial y} & \frac{\partial^2 DoG}{\partial y^2} \end{bmatrix}$$

No caso, v possui um valor mínimo (igual a 4) quando os autovalores da Jacobiana são iguais (pico curvado) e aumentam à medida que um dos autovalores aumenta e os

outros permanecem baixos. Os picos são retidos se $v < \frac{(t_e+1)(t_e+1)}{t_e}$, onde t_e é o limite da borda.

Atribuição de orientação

Agora, uma orientação é atribuída a cada ponto-chave para obter a invariância à rotação da imagem. Uma vizinhança é obtida, dependente da escala, do gradiente da magnitude 12 e da direção 13 (usando diferenças finitas), ao redor da localização do ponto-chave.

$$m(x, y) = \sqrt{(L(x + 1, y) - L(x - 1, y))^2 + (L(x, y + 1) - L(x, y - 1))^2} \quad (12)$$

$$\theta = \tan^{-1} \left(\frac{(L(x, y + 1) - L(x, y - 1))}{(L(x + 1, y) - L(x - 1, y))} \right) \quad (13)$$

Então, um histograma de 36 orientações (*bins*) cobrindo 360 graus é criado. Onde ele é ponderado pelo gradiente da magnitude e por uma janela Gaussiana circular onde σ vale 1.5 em relação à escala do ponto-chave 20.

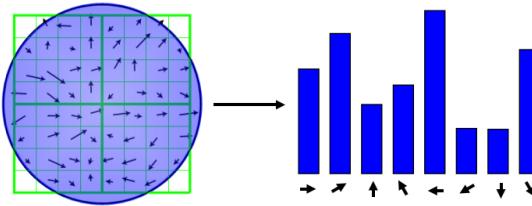


Figura 20 - Exemplo do resultado obtido do histograma orientado

O ponto mais alto do histograma é obtido e qualquer pico acima de 80% é considerado no cálculo da orientação. Pontos-chaves são criados com a mesma localização e escala, mas em diferentes direções, o que contribui para a estabilidade da correspondência.

Descriptor de pontos-chaves

Com os pontos-chaves criados a partir do histograma orientado, cria-se agora o descriptor de pontos-chaves.

Uma vizinhança 16x16 ao redor do ponto-chave é escolhida e esta mesma vizinhança é dividida em 16 sub-blocos 4x4. Para cada bloco, um histograma orientado com 8 *bin* é

criado. Logo, temos 128 valores válidos de *bin*. Esses valores são representados em forma de vetor para expressar o descritor de pontos-chaves 21.

Além disso, são tomadas algumas medidas para deixar o descritor mais robusto, como, por exemplo, invariante à luminosidade, rotação, etc.

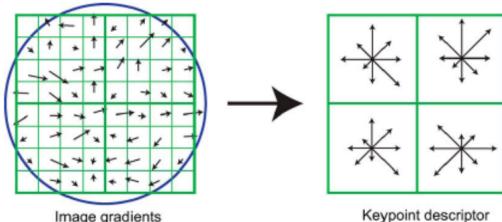


Figura 21 - Exemplo de um descritor de pontos-chaves, com uma matriz 2x2 e uma região 8x8

Combinação de pontos-chaves

Pontos-chaves entre duas imagens são combinados a partir da identificação da vizinhança mais próxima. Mas, em alguns casos, a segunda combinação mais próxima pode ser parecida com a primeira. Isso se dá por ruídos presentes nas imagens ou algo assim.

Nesse caso, a razão da distância mais próxima para a segunda distância mais próxima é utilizada. Se essa razão for maior que 0.8, essa combinação é descartada. Esse método elimina cerca de 90% de combinações falsas, enquanto descarta apenas cerca de 5% de combinações corretas.

Triangulação – *Full pair-wise image matching*

Com os pontos de interesse (*features*) extraídos, podemos agora fazer a triangulação entre os pontos das imagens.

A triangulação nada mais é que uma estimativa de um ponto em 3 dimensões, dado pelo menos duas câmeras conhecidas, onde, cada câmera com a projeção do *feature* correspondente àquele ponto 3D 22.

Infelizmente, não é tão simples assim. Existem muitos fatores que contribuem para aumentar a dificuldade da triangulação: ruídos, posição das câmeras, o feixe das projeções não se encontram no mesmo ponto 3D, não se tem informação da projeções nas câmeras, dentre outros. Entretanto, existem diversos algoritmos para resolução de cada um dos problemas enfrentados.

Com a extração dos *features* das imagens selecionadas, as próximas etapas da

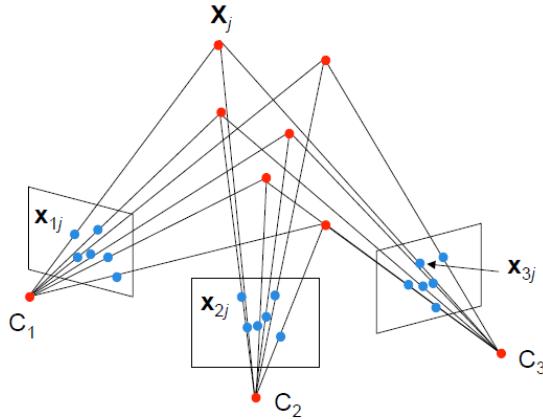


Figura 22 - Uma triangulação utilizando um ponto qualquer, X_j . Onde cada câmera C_1, C_2, C_3 possui um *feature* correspondente a cada uma delas, respectivamente, X_{1j}, X_{2j}, X_{3j} .

reconstrução para um dos sistemas se diferem, e a partir de agora, faremos abordagens individuais para cada um deles.

4.1 MVE – *Multi-View Reconstruction Environment*

Introdução

Um dos algoritmos utilizados para a técnica de reconstrução densa é o MVE – *Multi-View Reconstruction Environment* (FUHRMANN; LANGGUTH; GOESELE, 2014). Este algoritmo utiliza fotos e produz uma malha triangular superficial como resultado. Diferentemente das reconstruções baseadas nas geometrias das imagens, o MVE é focado na reconstrução multi-escala, um quesito importante na reconstrução de esculturas e acervo cultural. Portanto, com esta técnica é possível reconstruir grandes volumes de dados, contendo regiões detalhadas em alta resolução, em comparação com o resto da cena. O sistema ainda possui uma interface gráfica para o uma reconstrução baseada no SfM, amigável ao usuário (conhecida como UMVE), onde permite a visualização e inspeção das imagens, mapas de profundidade e renderizar cenas e malhas 3D.

Sua base de operação é basicamente 23:

1. Estrutura da formação – *Structure-from-Motion* (SfM)

- Reconstrói os parâmetros da câmera (posição e orientação) e seus dados de calibração (distância focal e distorção radial), encontrando correspondências esparsas, mas estáveis entre as imagens.

2. Múltiplas visões estéreo – *Multi-View Stereo* (MVS)

- Utiliza a posição estimada das câmeras, encontrando as correspondências visuais nas imagens. Estas correspondências são trianguladas, produzindo a informação 3D, e, consequentemente a reconstrução 3D densa.

3. Reconstrução de superfícies – *Surface Reconstruction*

- Tem como entrada uma densa nuvem de pontos, ou mapas de profundidade individuais. Produz uma malha superficial globalmente consistente.

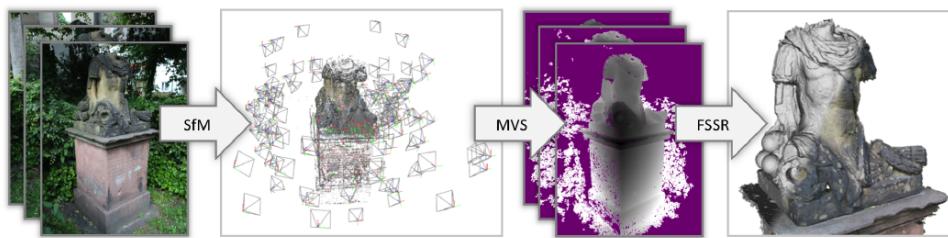


Figura 23 - Funcionamento do MVE. Começando com múltiplas imagens, técnicas SfM são empregadas para reconstruir os parâmetros das câmeras e os conjuntos de pontos esparsos. Mapas de profundidade são computados para cada imagem usando o MVS. Finalmente, uma malha colorida é extraída da união de todos os mapas de profundidade usando um algoritmo de aproximações de reconstruções de superfícies (FSSR – *Floating Scale Surface Reconstruction*). (FUHRMANN; LANGGUTH; GOESELE, 2014)

Como não existem muitas opções para algoritmos de SfM, o MVE permite a utilização de *softwares* externos como o *Bundler* (SNAVELY et al., 2010) ou o próprio *VisualSfM*.

Uma vez com o passo do SfM feito, partimos para o MVS. Com os parâmetros de câmera conhecidos, a reconstrução densa geométrica é feita. Existem diversos algoritmos para a reconstrução densa, o MVE no caso, utiliza um algoritmo próprio, feito por um de seus criadores, Michael Goesele (GOESELE et al., 2007), que reconstrói um mapa de profundidade para cada foto.

Embora abordagens baseadas em mapeamentos de profundidade produzam uma grande quantidade de redundâncias, (isso se dá por causa das inúmeras fotos que são sobrepostas e possuem partes similares da mesma cena), este algoritmo é altamente escalável para grandes cenas, pois apenas um pequeno conjunto de fotos vizinhas é necessário para a reconstrução. Outra vantagem da utilização dos mapas de profundidade como representação intermediária é que a geometria é parametrizada em seu domínio natural, e os dados por foto (como a cor, por exemplo) estão diretamente acessíveis nas imagens.

Essa redundância excessiva nos mapas de profundidade pode ser pesado. Não com relação ao armazenamento, mas na questão do processamento computacional exigido nos mapas. Porém, esta abordagem foi capaz de produzir uma geometria detalhada e superar o ruído nos mapas de profundidade individuais.

Guia de reconstrução com o MVE

Existem algumas recomendações para se ter uma boa reconstrução com o MVE ([RE-CONSTRUCTION... , ; FUHRMANN; LANGGUTH; GOESELE, 2014](#)). Um bom conjunto de dados é gerado se algumas regras simples forem seguidas:

- Para que o algoritmo do MVS consiga fazer uma triangulação com qualquer posição 3D, o conjunto de dados terá que ter, no mínimo, cinco fotos.
- As fotos devem ser tiradas com uma boa quantidade de sobreposição. A menos que o conjunto de dados se torne muito grande, uma grande quantidade de fotos não prejudicará a qualidade. Mas terá uma compensação do sistema, no que diz respeito à qualidade e desempenho.
- Para a triangulação funcionar, é necessário que tenha o efeito de paralaxe [24](#) (Aparente mudança na posição do objeto). Ou seja, é interessante que o conjunto de imagens seja duplicado.
- A câmera deverá ser reposicionada, de preferência.

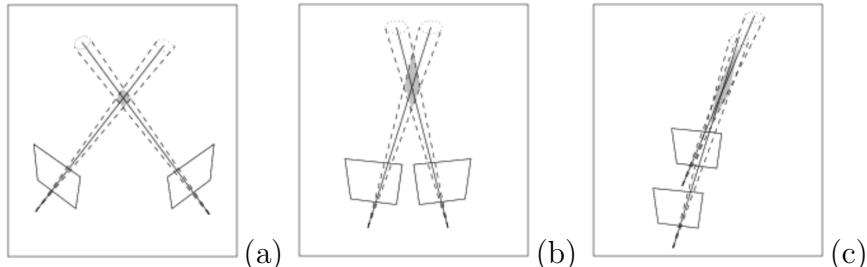


Figura 24 - Caso o espaçamento entre as câmeras seja grande, a informação extraída das imagens em comum será menor (a). Se a angulação do efeito de paralaxe seja baixa, terá a mesma informação sobre um ponto em questão (c). Ou seja utilizando ou (a), ou (c). Pode ser que a reconstrução fique incerta. Para que o efeito paralaxe tenha maior proveito das imagens das câmeras, é necessário que as câmeras estejam dispostas como (b), conseguindo extrair uma boa quantidade e qualidade de informações do ponto. ([STRICKER, 2015](#))

Criando uma cena

Uma visualização contém dados por exibição (como imagens, mapas de profundidade ou outros dados). Uma cena é uma coleção de visualizações, que constitui um

conjunto de dados. Uma nova cena pode ser criada utilizando a interface gráfica UMVE, Figura 25, ou por linha de comando (*makescene*).

Tecnicamente, a cena é criada como um diretório no sistema de arquivos (com o nome do conjunto de dados). Este, por sua vez, contém outro diretório (*views*), com todas as visualizações guardadas com uma extensão de arquivos em .MVE.

Criar uma nova cena, criará apenas o diretório (*views*) vazio. A importação de fotos criará arquivos .MVE para cada foto. Esse processo importará meta-dados provenientes das imagens (*tags EXIF*), que é necessário para estimar a distância focal para cada foto. Caso estes meta-dados não estejam disponíveis, uma distância focal padrão é assumida pelo sistema, porém se essa distância adotada for uma péssima suposição, com relação ao conjunto de dados utilizado, pode vir a acontecer erros no SfM.

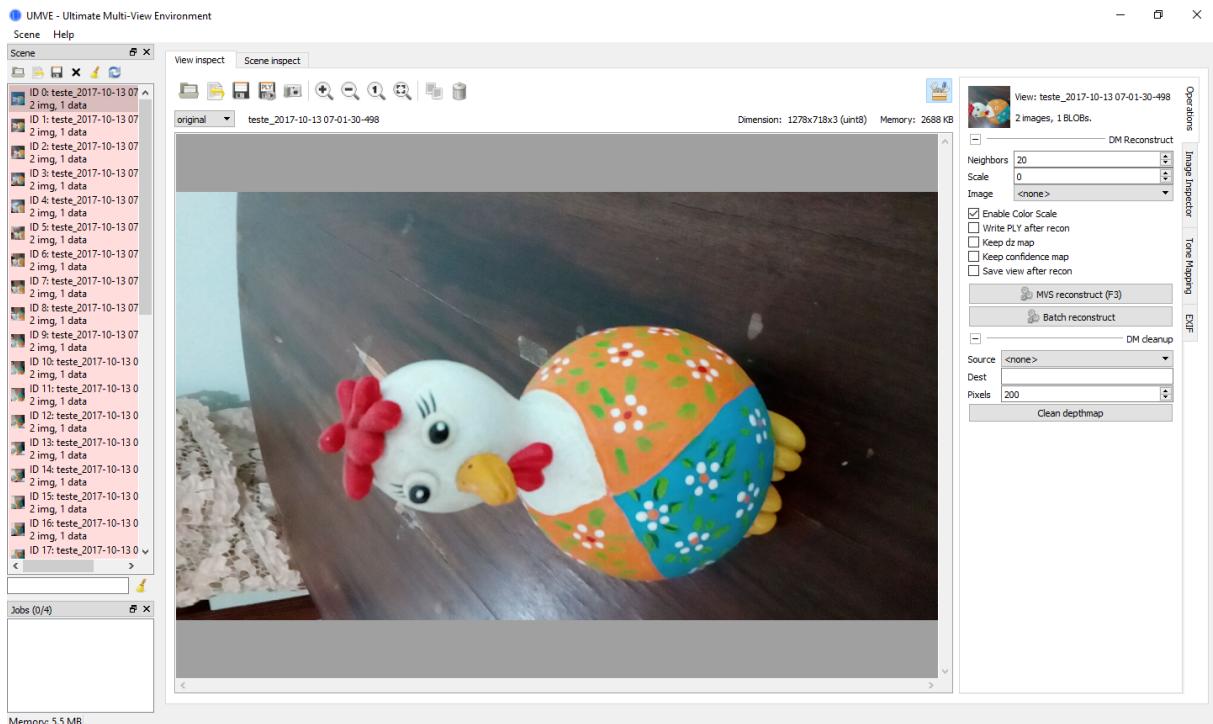


Figura 25 - Interface gráfica (UMVE)

Reconstrução SfM

Pode ser configurada e iniciada usando a interface gráfica UMVE ou por linha de comando (*sfmrecon*). A interface guia através da detecção de *features*, combinação emparelhada (*pairwise matching*) e uso incremental do SfM. Que, por sua vez, a reconstrução SfM começa a partir de um par inicial, e adiciona, de forma incremental, mais vistas à reconstrução 26.

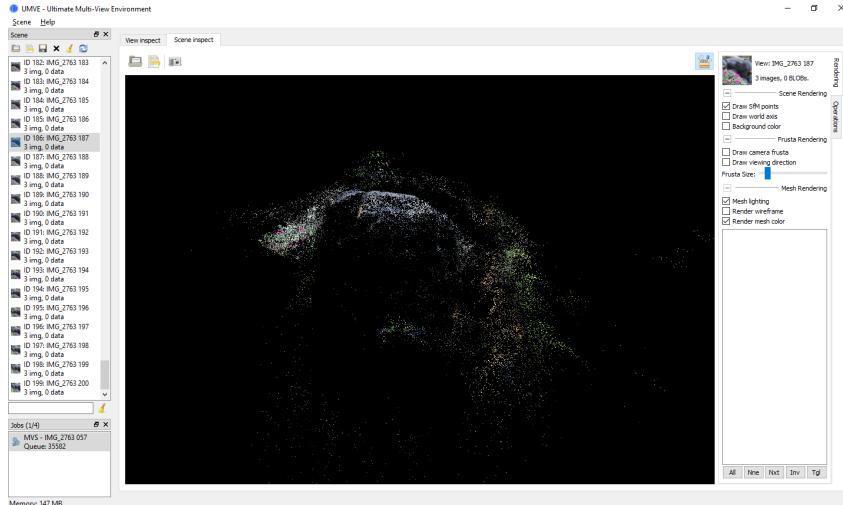


Figura 26 - Reconstrução baseada em nuvem de pontos gerada a partir da reconstrução SfM.

Múltiplas visões estéreo – *Multi-View Stereo* (MVS)

Usando as imagens junto com os parâmetros obtidos das câmeras, é possível reconstruir a geometria densa utilizando o MVS. Isso pode ser feito utilizando a interface gráfica (UMVE) ou por linha de comando (*dmrecon*).

O parâmetro mais importante é o nível de resolução em que os mapas de profundidade são reconstruídos: Caso seja nível 0 (ou L0), a reconstrução é feita usando o tamanho original das imagens. Se for nível 1 (ou L1), a reconstrução corresponde a metade do tamanho (um quarto dos números de pixels), e assim por diante.

Com a resolução das câmeras atuais, uma reconstrução L0 é raramente usada, pois geram mapas de profundidade mais dispersos com um custo computacional elevado, o que acarreta em dificuldades para encontrar as correspondências densas das imagens. Geralmente utiliza-se o L2, pois o processo é mais rápido, gerando mapas de profundidades completos, já que utiliza imagens menores [27](#).

O MVS pode ser dividido em duas partes:

- Uma estrutura regional-crescente que tem uma fila de candidatos correspondentes, Q , ordenada pelas localizações dos pixels na câmera acrescido de seus valores para profundidade e normais;
- Um sistema de correspondências que leva um candidato correspondente como entrada e calcula profundidade, normal e uma confiança de correspondência usando vistas vizinhas fornecidas pela seleção de exibição local. Se a correspondência for bem sucedida, os dados são armazenados em mapas de profundidade, normais e de confiança e os pixels vizinhos na câmera são adicionados como novos candidatos a Q .



Figura 27 - Uma imagem de entrada (à esquerda) e sua correspondência em mapas de profundidade (à direita), onde a parte roxa significa que não foi encontrada nenhum mapa naquela região (FUHRMANN; LANGGUTH; GOESELE, 2014).

Reconstrução de superfícies – *Surface Reconstruction*

Utiliza-se a linha de comando *scene2pet*, que combina todos os mapas de profundidade em uma única e grande nuvem de pontos. Nesta fase, um valor de escala é atribuído a cada ponto, que indica o tamanho atual da região da superfície na qual o ponto foi mensurado. Esta informação adicional permite o uso de várias propriedades benéficas usando a abordagem de reconstrução de superfície usando FSSR (FUHRMANN; GOESELE, 2014). A seguir, as ferramentas FSSR calculam uma representação volumétrica de escala múltipla a partir dos pontos (na qual não precisa de nenhum ajuste de parâmetros explícitos) e uma malha final é extraída. Esta malha pode parecer desordenada devido à regiões não confiáveis e à componentes isolados, oriundos de medidas imprecisas. Logo, a malha é limpa, retirando pequenos componentes isolados e regiões não confiáveis da superfície.

4.2 VisualSfM

Introdução

VisualSfM (WU et al., 2011b) é um *software* baseado em fotogrametria que faz todo o processo de reconstrução 3D de um objeto e que pode ser usado por linha de comando ou então pela interface gráfica, que é ótima, por sinal. É altamente customizável, podemos utilizar o CUDA da NVIDIA, ou OpenGL, especificar a lista de pares para correspondência de imagens, usar detectores de *features* próprios, velocidade da detecção de *features*, da reconstrução densa, dentre outros parâmetros. Ou seja, é um *software* robusto, que pode ser usado em Linux, Windows ou até mesmo Mac.

Além disso, o VisualSfM é capaz de mostrar a matriz de correspondência de *fea-*

tures, número de *features*, rodar um *Bundle Adjustment* independente, usar um Level 0 no PVMS, alterar a memória de GPU usada na reconstrução, deletar uma reconstrução indesejável ou até mesmo alterar parâmetros.

Procedimento

Sua linha de reconstrução é parecida com o MVE 4.1, porém é mais intuitiva. Em sua interface, possui um Log de mensagens e erros que por ventura venham a acontecer e na parte de cima, alguns botões 28

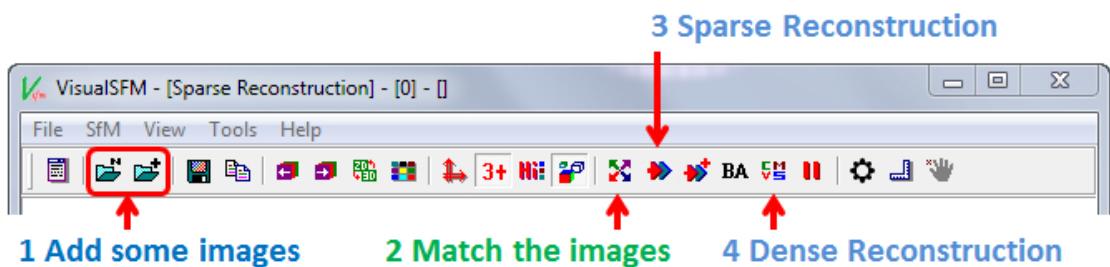


Figura 28 - Botões na parte superior da interface gráfica, este seria o procedimento padrão de funcionamento do *software*. (WU et al., 2011b)

Como demonstrado na imagem 28, o funcionamento seria da seguinte forma:

- **1 - Adicionar algumas imagens.** Este é o primeiro passo, para começar uma reconstrução, primeiro adiciona-se imagens ao *software*, pode ser uma única foto, um conjunto de fotos, incrementar o conjunto já existente ou então abrir um arquivo de extensão .nvm, que é interpretado como uma reconstrução esparsa previamente feita.
- **2 - Correspondência de imagens.** Agora, o *software* roda o algoritmo SIFT, realizando todas as correspondências entre os *features*, que já foi discutido anteriormente.
- **3 - Reconstrução esparsa.** Neste passo, o VisualSfM roda o algoritmo de reconstrução esparsa (PBA/MCBA) (WU et al., 2011a) em todos os *features* descobertos no passo passado.

Bundle Adjustment

O termo *Bundle* refere-se aos feixes de luz que refletem em cada *feature* 3D e vão para o centro de cada câmera da cena a ser reconstruída. Com isso, o *Bundle Adjustment* é o problema de refinhar uma reconstrução visual para produzir estimativas com a visualização de parâmetros (estimativa e/ou calibração de câmeras), juntamente com as estruturas 3D.

Solucionadores de problemas de *Bundle Adjustment* (**CHOUDHARY**,) resumem-se em minimizar o erro de reprojeção 29 entre as posições de imagem dos pontos de imagem observados e previstos, o que é expresso como a soma de quadrados de um grande número de funções não-lineares de valor real. Assim, a minimização é obtida usando algoritmos de mínimos quadrados não-lineares. Destes, Levenberg-Marquardt (**MORÉ**, 1978; **PRESS**, 1992), que emprega um método híbrido de iterações de Newton e *Gradient Descent* provou ser um dos mais bem sucedidos devido à sua facilidade de implementação e ao uso de uma estratégia de amortecimento eficaz que lhe confere a capacidade de convergir rapidamente de uma ampla gama de suposições iniciais, na qual, o desafio de se ter uma boa performance é basicamente, escolher uma boa suposição inicial. Ao linearizar iterativamente a função a ser minimizada na vizinhança da estimativa atual, o algoritmo de Levenberg-Marquardt envolve a solução de sistemas lineares denominados equações normais. Ao resolver os problemas de minimização que surgem na estrutura do *Bundle Adjustment*, as equações normais tem uma estrutura de bloco esparsa devido à falta de interação entre os parâmetros para diferentes pontos 3D e câmeras. Isso pode ser explorado para obter enormes benefícios computacionais ao empregar uma variante esparsa do algoritmo de Levenberg-Marquardt que aproveita explicitamente o padrão de zeros de equações normais, evitando armazenar e operar em elementos zero.

A descrição ?? é uma das abordagens mais comuns sobre o *Bundle Adjustment* e por isso, usaremos ela como exemplo.

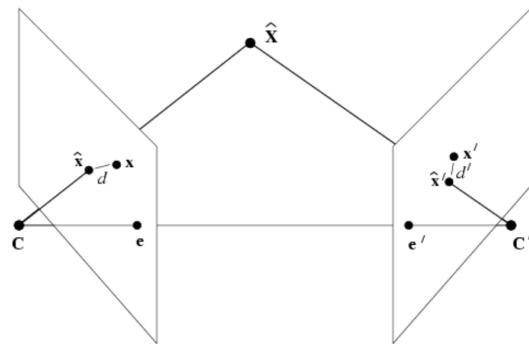


Figura 29 - Dado um ponto de um objeto 3D \hat{X} , sua reprojeção nas câmeras C e C' , são, respectivamente, x e x' . Esses pontos possuem um erro de reprojeção d e d' e ao utilizar o PBA/MCBA, os pontos x e x' serão reajustados como \hat{x} e \hat{x}' , respectivamente. (**STRICKER**, 2015)

Formulação inicial

Consideremos o seguinte problema de estimativa de um conjunto de parâmetros $x \in \mathbb{R}^M$ de um conjunto de observações $\bar{Z} \in \mathbb{R}^N$, com $M \ll N$. O objetivo é

calcular x na qual $Z(x)$ é o mais próximo de \bar{Z} possível, *i.e.*, para minimizar o erro de previsão residual $||\Delta Z|| = ||\bar{Z} - Z(x)||$

PBA/MCBA – *Multi-Core Bundle Adjustment*

Neste caso, o PBA/MCBA (FURUKAWA; PONCE, 2009; WU et al., 2011a) é um algoritmo que utiliza, de forma eficiente, os núcleos do computador, sendo até 10 vezes mais rápido, em CPU e 30 vezes, em GPU, em comparação ao utilizado na conferência ECCV de 2010. É o primeiro sistema publicado, baseado em GPU que escala com maiores problemas de Bundle Adjustments. Isto abriu a porta para resolver problemas ainda maiores. Ele funciona observando o passo inexato de resolução não-linear usando Levenberg Mardquardt, que pode ser implementado sem armazenar nenhuma matriz (Hessiana, complemento de Schur ou Jacobiana) na memória. Para sistemas de núcleo único isso se traduzia em memória de troca por tempo, mas em GPUs, isso leva a um surpreendente ganho, no espaço e no tempo. Outra surpresa é que a aritmética de precisão única, quando combinada com técnicas de normalização adequadas, dá resultados comparáveis aos obtidos por um solucionador de problemas usando aritmética de dupla precisão. Isso resulta em mais espaço e economia de tempo.

Este algoritmo recebe como entrada conjunto de localizações e correspondências de *features* de imagens, o objetivo do *Bundle Adjustment* é encontrar posições de 3 pontos e parâmetros de câmera que minimizem o erro de reprojeção. Esse problema de otimização geralmente é formulado como um problema de mínimos quadrados não-lineares, onde o erro é a norma L2 quadrada da diferença entre a localização da característica observada e a projeção do ponto 3D correspondente no plano da imagem da câmera.

Assumindo que x é um vetor de parâmetros e $f(x) = [f_1(x), \dots, f_k(x)]$ é o vetor de erros de projeção de uma reconstrução 3D. O problema de otimização pode ser formulado como um problema de mínimos quadrados não-linear:

$$x^* = \underset{x}{\operatorname{argmin}} \sum_{i=1}^k \|f_i(x)\|^2 \quad (14)$$

O algoritmo de Levenberg-Marquardt (LM) é o mais conhecido para resolução de problemas de mínimos quadrados não-lineares. O LM funciona resolvendo uma série de aproximações lineares regularizadas ao problema não-linear original. Seja $J(x)$ a Jacobiana de $f(x)$, então em cada iteração LM resolve um problema linear de

mínimos quadrados da forma:

$$\delta^* = \underset{\delta}{\operatorname{argmin}} \|J(x)\delta + f(x)\|^2 + \lambda \|D(x)\delta\|^2 \quad (15)$$

e, atualiza x , da forma:

1: caso ($\|f(x + \delta^*)\| < \|f(x)\|$), então

2: $x = x + \delta^*$

Aqui, $D(x)$ é uma matriz diagonal não-negativa, tipicamente a raíz quadrada da diagonal da matriz $J(x)^T J(x)$ e λ são parâmetros não-negativos que controlam a limite da regularização, que, por sua vez, é necessária para garantir um algoritmo convergente. O LM atualiza o valor de λ a cada passo, baseado no quanto a Jacobiana ($J(x)$) está próxima da função original ($f(x)$). Resolver 15 é equivalente à resolver as equações normais

$$(J^T J + \lambda D^T D)\delta = -J^T f \quad (16)$$

onde retiramos a dependência de x . A matriz $H_\lambda = J^T J + \lambda D^T D$ é conhecida como a matriz Hessiana aumentada.

No *Bundle Adjustment*, o parâmetro "vetor" é tipicamente organizado como $x = [x_c; x_p]$, onde x_c é o vetor de parâmetros da câmera e x_p é o vetor de parâmetros do ponto. Similarmente para D , δ e J , usaremos subscritos c e p para denotar parâmetros da câmera e do ponto, respectivamente. Seja $U = J_c^T J_c$, $V = J_p^T J_p$, $U_{\lambda} = U + \lambda D_c^T D_c$, $V_{\lambda} = V + \lambda D_p^T D_p$ e $W = J_c^T J_p$, então 16 pode ser re-escrita como um bloco de sistema linear estruturado

$$\begin{bmatrix} U_\lambda & W \\ W^T & V_\lambda \end{bmatrix} \begin{bmatrix} \delta_c \\ \delta_p \end{bmatrix} = - \begin{bmatrix} J_c^T f \\ J_p^T f \end{bmatrix}$$

Vale ressaltar que, para a maioria dos problemas de *Bundle Adjustment*, U_λ e V_λ são matrizes diagonais de blocos. Esta observação está no fundamento do truque do complemento de Schur usado para resolver esse sistema linear de forma eficiente, onde, ao aplicar a eliminação Gaussiana nos parâmetros do ponto, obtemos um sistema linear consistindo apenas nos parâmetros da câmera:

$$(U_\lambda - WV_\lambda^{-1}W^T)\delta_c = -J_c^T f + WV_\lambda^{-1}J_p^T f \quad (17)$$

Onde $S = U_\lambda - WV_\lambda^{-1}W^T$ é o complemento de Schur ou a matriz reduzida da câmera. Com a solução para 17, conseguimos obter os parâmetros do ponto com substituição regressiva:

$$\delta_p = -V_\lambda^{-1}(J_p^T f + W^T \delta_c) \quad (18)$$

Caso S for simétrica positiva-definida, a fatorização de Cholesky é indicado para a resolução de 17.

O algoritmo MCBA, une o paralelismo da GPU e técnicas de uso de multi-núcleos da GPU e a combinação de algoritmos de gradientes de conjugados pré-condicionados e algoritmos inexatos LM para resolução dessas equações com alguns pré-condicionadores simples e computacionalmente baratos.

- **4 - Reconstrução densa.** Finalmente, acaba a reconstrução rodando o algoritmo de reconstrução densa (**GAVA**,) CMVS/PMVS-2 embutido no próprio VisualSfM. CMVS/PMVS-2 (*Clustering Views for Multi-view Stereo / Patch-based for Multi-view Stereo version 2*)

Muitos algoritmos Multi-View Stereo (MVS) não escalam tão bem com um grande número de imagens de entrada ou em uma alta resolução, pois necessitam de muita memória e recursos computacionais. A palavra-chave do CMVS (**TEERAVECH, 2013; WU, 2013; LI et al., 2013a**) é escalabilidade, pois seu propósito é utilizar imagens provenientes de sites na internet, em diferentes resoluções, como o Flickr.com. Ele usa a saída do Structure from Motion – SfM (mais especificamente a saída do passo anterior, do PBA) e utiliza como entrada. Após isso, decompõe as imagens de entrada como um conjunto de *clusters* de imagens com tamanhos gerenciáveis. O MVS pode ser usado para processar cada *cluster* de forma independente e em paralelo, onde a união das reconstruções de todos os *clusters* não deve perder detalhes que poderiam ser obtidos através do conjunto de imagens.

A formulação dos *clusters* é projetada para satisfazer três restrições:

- (1) as imagens redundantes são excluídas dos *clusters* (compacidade)
- (2) cada *cluster* é pequeno o suficiente para uma reconstrução MVS (restrição de tamanho)
- (3) as reconstruções MVS destes *clusters* resultam em uma perda mínima de conteúdo e detalhes em comparação com o que pode ser obtido através do processamento do conjunto completo de imagens (cobertura).

A compacidade é importante para a eficiência computacional, mas também para melhorar precisão, pois as coleções de fotos da Internet geralmente contêm centenas ou milhares de fotos adquiridas de quase mesmo ponto de vista, ou seja, um conjunto composto inteiramente informações duplicadas.

Em outras palavras, a sobreposição de *clusters* é definida por:

- Minimizar $\sum_k |C_k|$ (compacidade)
- $\forall k |C_k| \leq \alpha$, onde α é determinado por recursos computacionais, principalmente por limitações de memória. (tamanho)
- $\forall i \frac{\# \text{ pontos cobertos em } I_i}{\# \text{ pontos em } I_i} \geq \delta$, onde δ é uma constante de proporção de pontos cobertos. (cobertura)

O CMVS pode ser resumido em quatro passos:

- Filtro SFM – agrupamento de pontos SFM
- Seleção de imagens – remove imagens redundantes
- Divisão de *cluster* – reforça a restrição de tamanho
- Adição de imagens – reforça a cobertura

Filtro SFM

A obtenção de medidas precisas de visibilidade de pontos é fundamental para o sucesso do procedimento de visualização baseado em *clusters*. Os recursos da imagem não detectados ou incomparáveis levam a erros nas estimativas de visibilidade do ponto V_j (geralmente na forma de imagens que estão faltando). Obtemos estimativas de visibilidade mais confiáveis ao agregar dados da visibilidade em uma vizinhança local, e mesclando os pontos nessa vizinhança. A posição do ponto mesclado é a média de seus vizinhos, enquanto a visibilidade se torna a união. Este passo também reduz significativamente o número de pontos SFM e melhora o tempo de execução das três etapas restantes. Especificamente, a partir de um conjunto de pontos SFM, um ponto é selecionado, combinado com seus vizinhos (mesclado) e, este ponto mesclado é emitido, após isso, o ponto original e seus vizinhos são removidos do conjunto de entrada. Esse procedimento é repetido até o conjunto de entrada estar vazio. O conjunto de pontos mesclados torna-se o novo conjunto de pontos, que, pode ser denotado por P_j^2 .

Seleção de imagens

Começando com o conjunto completo de imagens, cada imagem é testada e removida se a restrição de cobertura ainda for realizada após a remoção. O teste de remoção é realizado para todas as imagens enumeradas em ordem crescente de resolução de imagem (# de pixels), de modo que as imagens de baixa resolução sejam removidas primeiro. Observe que as imagens são descartadas permanentemente nesta etapa para acelerar as seguintes etapas principais de otimização.

Divisão de *cluster*

Em seguida, é aplicada a restrição de tamanho dividindo os *clusters*, ignorando a cobertura. Mais especificamente, um *cluster* de imagens é dividido em componentes menores caso viole a restrição de tamanho. A divisão de um *cluster* é realizada pelo algoritmo *Normalized-Cuts* [23] em um gráfico de visibilidade, onde os nós são imagens. O peso da borda entre um par de imagens (I_l, I_m) mede o quanto a I_l e I_m contribuem, juntos, para a reconstrução MVS em pontos SFM relevantes:

$e_{lm} = \sum_{P_j \in \Theta^{lm}} \frac{f(P_j, I_l, I_m)}{f(P_j, V_j)}$, onde Θ^{lm} denota um conjunto de pontos SFM visíveis em I_l e I_m . Intuitivamente, as imagens com alta contribuição no MVS têm pesos altos entre eles e são menos propensos a serem cortados. A divisão de um *cluster* se repete até que a restrição de tamanho seja satisfeita para todos os *clusters*.

Adição de imagens

A restrição de cobertura pode ter sido violada na etapa anterior, e agora são adicionadas imagens a cada *cluster* para cobrir mais pontos SFM e restabelecer a cobertura. Nesta etapa, primeiro é construída uma lista de ações possíveis, onde cada ação mede a eficácia de adicionar uma imagem a um *cluster* para aumentar a cobertura. Para cada ponto SFM que está descoberto, P_j , deixe $C_k = \text{argmax}_{Clf}(P_j, Cl)$ ser o *cluster* com a máxima precisão de reconstrução. Então, para P_j , é criada uma ação ($I \rightarrow C_k$), g que adiciona a imagem $I (\in V_j, \notin C_k)$ a C_k , onde g mede a eficácia. Só são consideradas ações que adicionam imagens ao C_k em vez de cada *cluster* que poderia cobrir P_j , para eficiência computacional. Uma vez que as ações com a mesma imagem e com o mesmo *cluster* são geradas a partir de vários pontos SFM, ocorre uma mescla dessas ações ao resumir a eficácia medida g . As ações na lista são classificadas em uma ordem decrescente de sua eficácia. Tendo construído uma

lista de ações, uma abordagem seria tomar a ação com a pontuação mais alta, então refazer a lista novamente, o que é computacionalmente muito caro.

Em vez disso, consideramos ações cujas pontuações são mais de 0,7 vezes a pontuação mais alta na lista, em seguida, repete-se a ação a partir do topo da lista. Como uma ação pode alterar a eficácia de outras ações semelhantes, depois de tomar uma ação, remove-se quaisquer conflito da lista, onde duas ações $(I \rightarrow C), g, (I' \rightarrow C'), g'$ estão em conflito se I' e I são vizinhos. A construção da lista e a adição da imagem são repetidas até que a restrição de cobertura seja satisfeita.

Após a adição da imagem, a restrição de tamanho pode ser violada e, neste caso, as duas últimas etapas são repetidas até que ambas as restrições sejam satisfeitas.

O passo seguinte, depois de obtido o *cluster* das imagens, é empregado algum algoritmo de reconstrução MVS, neste caso, o PMVS-2 (Patch-based Multiview Stereo Versão 2) ([TEERAVECH, 2013](#); [LI et al., 2013b](#); [FURUKAWA et al., 2010](#)).

PMVS-2

O PMVS-2 utiliza a técnica de DoG e cantos de Harris. O DoG é utilizado para detecção de bordas, subtraindo o resultado de dois Gaussianos com escalas diferentes [4](#). O operador de Harris emprega uma auto-correlação local para melhorar a consistência da borda, extraíndo a borda e os cantos dos *features* das imagens. A resposta de Harris é positiva em regiões com cantos, negativa em bordas e pequenas em regiões planas. Além disso, no PMVS-2, usando pontos de amostras das imagens como sementes, as linhas epipólares são usadas para decidir a região correspondente (dentro de uma área 2x2 pixels) em outra imagem, gerando *patches* (cada uma definida com seu centro, normal e visibilidade) para atender às restrições na visibilidade, e levando à uma correspondência baseada em *patches* entre imagens. A correspondência *Multi-view* no PMVS-2 é baseada em *patches* e depende da consistência fotográfica média de todos os pares visíveis. Um *patch* é reconstruído usando maximizando o valor médio da consistência da foto e, em seguida, aceitando somente se o número de imagens visíveis for maior ou igual a três.

A superfície do objeto é aproximada por um pequeno retângulo (o *patch*). O *patch*(p) é um retângulo modelado pela posição central $c(p)$, pelo vetor normal $n(p)$, pelos eixos x e y e pela imagem de referência $R(p)$, onde a imagem é a que melhor representa a visibilidade do *patch*. Seu tamanho é determinado por sua projeção na imagem de referência $R(p)$.

A imagem é dividida em células (*grid*), de $\beta \times \beta$ pixels (usualmente 2x2). O ideal é

reconstruir um patch por célula. Quanto menor a célula, maior será a densidade na nuvem de pontos final.

O PMVS-2 pode ser dividido em algumas etapas:

- Inicialização

- Detecção de *features*

- Correspondência guiada

- Expansão

- Filtragem

Detecção de *features*

O PMVS-2 padrão utiliza o DoG em conjunto com o algoritmo de cantos de Harris, onde é criada uma linha epipolar, e todos os pontos em comum nesta linha são considerados consistentes para a reconstrução. Após isso cria-se o *patch* onde o $c(p)$ é calculado pela triangulação dos *features* detectados das imagens. A normal $n(p)$ é o cálculo da relação do vetor $c(p)$, multiplicado pela centro óptico da imagem, pelo módulo do numerador. E $R(p)$ é a imagem de referência propriamente dita. São otimizadas as orientações e posições de todos os *patches*. Com a inicialização finalizada, temos como resultado a reconstrução esparsa da escultura. No caso do VisualSfM, como a reconstrução esparsa já é feita em passos anteriores (com o PBA [4.2](#)), na realidade o PMVS-2 só é empregado para a reconstrução densa, ou seja, a inicialização não é feita pelo PMVS-2 no VisualSfM.

Expansão

Cada ponto 3D na nuvem de pontos é usado como semente para um algoritmo de expansão (aumento da região). Um *patch* utilizado como semente é expandido da seguinte forma:

Um novo *patch* é projetado em uma célula vizinha. A posição é definida para a interseção do raio projetado para trás e no plano de seu patch pai, usando a mesma orientação (o vetor normal é propagado) e a mesma imagem de referência. Novamente, são otimizadas as orientações e posições, porém, do novo *patch*.

Filtragem

É aplicada uma consistência de visibilidade global, onde os *patches* que não são visíveis pelos centros ópticos das imagens, são descartados (estão dentro da superfície). Para isso, são utilizados dois filtros: filtro de qualidade e filtro de visibilidade ??.

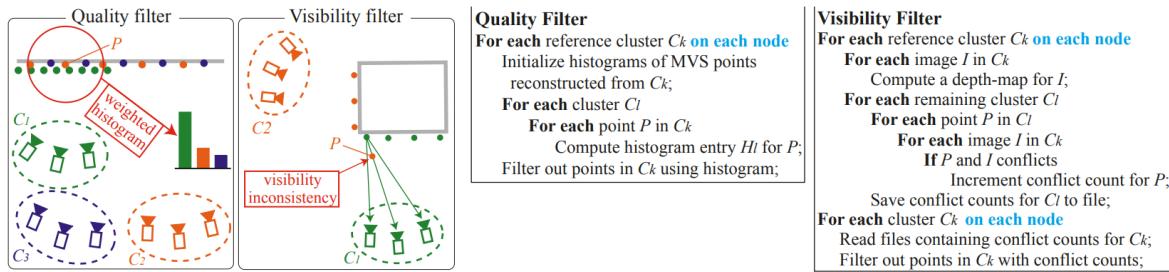


Figura 30 - Usabilidade dos filtros de qualidade e visibilidade, onde são aplicados fora do núcleo, assim como em paralelo. À esquerda, um ponto MVS P é testado usando os filtros. À direita, temos pseudo-códigos, onde os loops destacados em azul podem ser executados em paralelo. (FURUKAWA et al., 2010).

Filtro de Qualidade

A mesma região de superfície pode ser reconstruída em múltiplos clusters com qualidade de reconstrução variável: grupos próximos produzem pontos densos e precisos, enquanto cachos distantes produzem pontos escassos e ruidosos. Queremos filtrar o último, que é realizado pelo seguinte filtro de qualidade. Assumimos que P_j e V_j denotarem um ponto MVS e suas informações de visibilidade estimadas pelo algoritmo MVS, respectivamente. Supomos que P_j foi reconstruído a partir do *cluster* C_k . Primeiramente coletamos pontos MVS Q_m e sua informação de visibilidade V_m de todos os *clusters* que possuem normais compatíveis com P_j , isto é, a diferença de ângulo menores que 90° e seus locais projetados estejam dentro de n pixels de P_j em cada imagem em V_j , (no caso, experimentalmente, $n = 8$). A partir dos pontos MVS obtidos, calculamos um histograma (H_l), onde H_l é a soma da acurácia das precisões $f(Q_m, V_m)$ associadas a pontos MVS reconstruídos a partir de C_l . Uma vez que um *cluster* possua pontos acurados e densos, este deverá ter um valor significativamente maior do que os outros. P_j é filtrado se o valor do histograma H_k correspondente for inferior a metade do máximo: $H_k < 0,5\max_l H_l$. Repetimos este procedimento examinando cada *cluster* de referência, que pode ser executado em paralelo.

Filtro de Visibilidade

O filtro de visibilidade reforça a consistência das informações de visibilidade associadas aos pontos MVS durante toda a reconstrução. O filtro é, de fato, muito semelhante ao usado no PMVS [7, 9]. A diferença é que o PMVS reforça a consistência intra-cluster dentro de cada cluster, enquanto nosso filtro reforça a consistência de visibilidade inter-cluster em uma reconstrução inteira comparando as saídas PMVS de todos os clusters. Mais concretamente, para cada ponto MVS, contamos o número de vezes que ele conflita com reconstruções de outros clusters. O ponto é eliminado se a contagem de conflitos (**FURUKAWA et al., 2010; FURUKAWA; PONCE, 2010**) for superior a três.

5 EXPERIMENTOS

No presente trabalho, nos concentramos no objetivo proposto descrito na Seção 1.1.

5.1 Procedimento

Primeiramente, filmamos algumas esculturas utilizando a câmera de um *smartphone* convencional na resolução de 1920x1080 pixels. Esta filmagem foi realizada varrendo toda (ou maioria) da superfície da escultura em 360° com o intuito de ter toda a escultura reconstruída 31. Após isso, fizemos mais alguns vídeos, pegando alguns pontos que possuíam mais detalhes e que, com uma única varredura, não era capaz de reproduzir uma boa reconstrução.

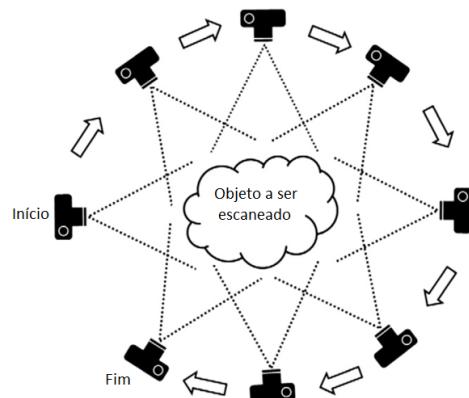


Figura 31 - Exemplo de como foi realizada a varredura da escultura

Com este material, foram feitos "cortes" em determinados *frames* do vídeo, com atenção para não cortar em *frames* muito juntos, pois aumentaria o número de correspondências ambíguas entre as imagens e com isso, o processamento da reconstrução demoraria mais. E não usar *frames* muito distantes, que ocorreria o inverso: com menos correspondências, ficariam buracos (partes sem a informação necessária) na reconstrução, como descrito na Seção 4.1.

Com isso em mente, foram reconstruídas duas esculturas: empregando o VisualSfM, usamos um único vídeo, totalizando 197 imagens. Com o MVE, utilizamos dois vídeos, que, ao cortá-los, totalizou cerca de 280 imagens.

Além de esculturas ao ar livre, fizemos alguns testes em ambiente fechado, dentro de uma casa, por exemplo. Foi utilizado um objeto feito de cabaça (casca de abóbora) na qual possui uma superfície propícia (Lambertiana) (BASRI; JACOBS, 2003) para uma reconstrução.

Com o procedimento descrito anteriormente, a partir dos vídeos feitos, obtemos um total de 200 imagens em um vídeo superficial e mais 24 imagens mais detalhadas do objeto, ambos numa resolução de 1080x1920 pixels. E, para um mesmo conjunto de imagens, rodamos tanto o VisualSfM quanto o MVE.

5.1.1 Resultados da reconstrução com o VisualSfM

Seguindo o passo-a-passo de reconstrução do software, obtivemos os seguintes resultados, para a escultura de 197 imagens do Jardim do Nêgo.

Tabela 4 - Tempos obtidos da reconstrução da escultura do Jardim do Nêgo usando o VisualSfM

Procedimento	Tempo (aprox.)
Carregamento de imagens	10 segundos
Calcular pares correspondentes de <i>features</i>	6.643 segundos
Gerar a reconstrução esparsa do modelo	220 segundos
Gerar a reconstrução densa do modelo	1.385 segundos

Com as seguintes reconstruções 32, 33. Percebemos que foi gerada uma nuvem de pontos bem consistente, a partir da reconstrução esparsa do algoritmo PBA. Por conta disso, nossa reconstrução 3D densa, empregando o MCBA/PMVS-2 obteve uma qualidade adequada para o conjunto de imagens usada.

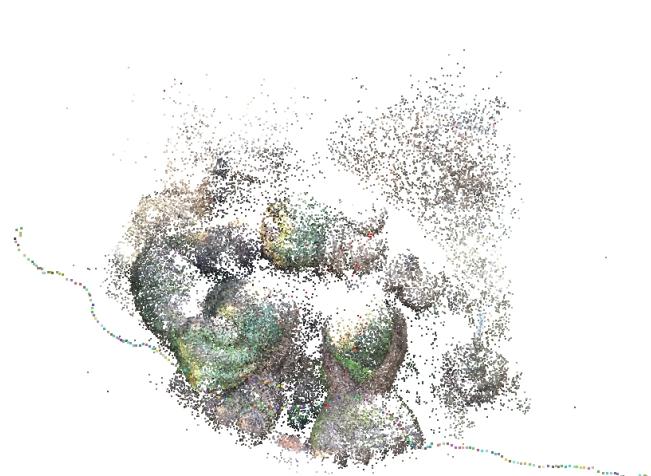


Figura 32 - Reconstrução esparsa da escultura do Jardim do Nêgo no VisualSfM com 197 imagens.

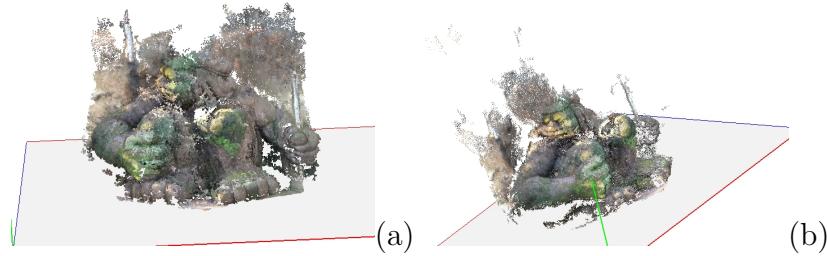


Figura 33 - Resultados da reconstrução densa da escultura do Jardim do Nêgo usando o VisualSfM, em dois ângulos diferentes (a) e (b).

Com o objeto em ambiente fechado, conseguimos os resultados a seguir.

Para o primeiro vídeo, convertido em 200 imagens:

Tabela 5 - Tempos obtidos da reconstrução do objeto usando o VisualSfM

Procedimento	Tempo (aprox.)
Carregamento de imagens	50 segundos
Calcular pares correspondentes de <i>features</i>	9.540 segundos
Gerar a reconstrução esparsa do modelo	135 segundos
Gerar a reconstrução densa do modelo	1.416 segundos

A Figura 34 mostra o resultado da reconstrução esparsa do algoritmo PBA. Não é tão nítida como na reconstrução densa, Figura 35, a quantidade de ruídos, provenientes de outros objetos presentes na cena (o VisualSfM só identifica objetos estáticos). Só é possível limpar a malha manualmente, pressionando a tecla F1 e selecionando a área desejada para ser deletada. Não é muito prático, pois podemos excluir alguns pontos importantes, o ideal seria fazer esta limpeza por meio de programas externos.

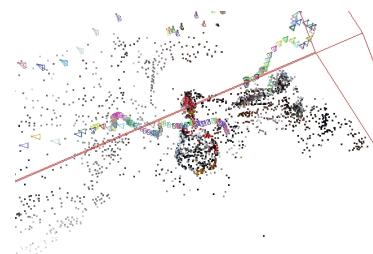


Figura 34 - Reconstrução esparsa do objeto no VisualSfM com 200 imagens.



Figura 35 - Reconstrução densa do objeto no VisualSfM com 200 imagens.

Fizemos uma outra reconstrução, utilizando os dois vídeos (gerando 224 imagens). Caso usássemos um conjunto maior, o programa parava de funcionar por falta de memória, mesmo após ajustar parâmetros (como o número de vizinhos, número de *cores* do processador, *level* do PMVS, entre outros) para melhorar esse problema. Portanto, o experimento seguiu da forma:

Tabela 6 - Tempos obtidos da reconstrução do objeto, com 224 imagens usando o VisualSfM

Procedimento	Tempo (aprox.)
Carregamento de imagens	60 segundos
Calcular pares correspondentes de <i>features</i>	10.451 segundos
Gerar a reconstrução esparsa do modelo	162 segundos
Gerar a reconstrução densa do modelo	1920 segundos

Percebemos que não foi tão proveitoso (qualitativamente) usar mais imagens neste caso, inclusive o algoritmo perdeu a referência do objeto e gerou um segundo modelo na reconstrução esparsa, Figura 36, e, consequentemente, na reconstrução densa, Figuras 37a, ?? e 37b. O que gerou uma certa incoerência na reconstrução.



Figura 36 - Reconstrução esparsa do objeto com 224 imagens no VisualSfM.

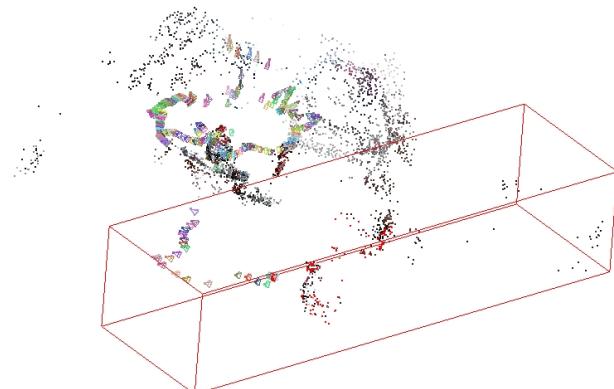


Figura 37 - Foram gerados dois modelos esparsos do objeto a partir do conjunto inicial de 224 imagens, provavelmente, proveniente da falta de parâmetros da câmera.

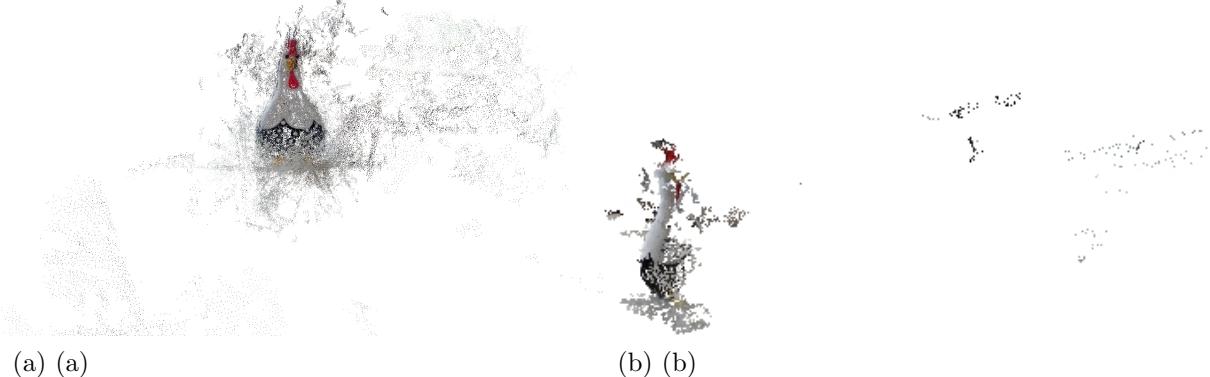


Figura 38 - Reconstruções densas do primeiro (a) e do segundo (b) modelo do objeto no VisualSfM com 224 imagens.

5.1.2 Resultados da reconstrução com o MVE

A utilização do software é bem intuitiva, seja por linha de comando ou pela interface gráfica (neste modo, fica mais fácil visualizar cada etapa da reconstrução). Amplamente configurável, podendo escolher a vizinhança, escala, manter o mapa de profundidade, ver os dados *EXIF* de cada imagem, dentre outras configurações.

Entretanto, para a aplicação proposta neste projeto, não é muito interessante, visto que ele utiliza a informação das câmeras, inseridas nas imagens (*EXIF*) e como as imagens empregadas na reconstrução são, tecnicamente, vídeos cortados em determinados *frames*, não é possível obter a informação das câmeras [39](#). Logo o software não tem tanta aplicabilidade neste caso, pois pode recair no problema dos parâmetros padrões adotados para as câmeras não serem bons o suficiente para estes conjuntos de dados. A menos que sejam tiradas fotos sequenciais de alguma escultura ou objeto que se deseja gerar a reconstrução densa, pois dessa forma, as informações necessárias das câmeras estarão armazenadas.

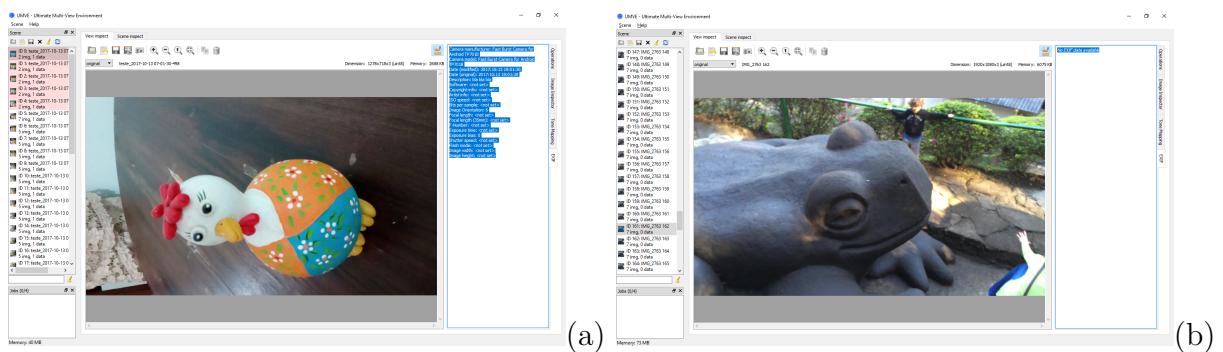


Figura 39 - A figura (a) é um exemplo onde a imagem possui dados na extensão *EXIF* (destacado em azul). Ao passo que a figura (b) é um frame de um vídeo, que não possui os dados das câmeras (destacado em azul).

Foi gerada uma reconstrução de um vídeo gravado de uma escultura no Jardim do Nêgo. O vídeo foi cortado em *frames* onde foram geradas 200 imagens base, com os parâmetros de câmera gerados pelo próprio software.

A partir disso, foi executado, todos os passos de uma reconstrução utilizando o MVE, de forma que, foram utilizadas as duas opções, tanto por linha de comando, quanto pela interface gráfica (UMVE).

Pela interface gráfica, o processo todo de reconstrução foi rápido (cerca de 30 minutos) [40](#), ao passo que por linha de comando, levou cerca de 11 horas e 30 minutos, portanto, vamos nos atentar somente à reconstrução por linha de comando, onde, resumindo, tivemos os resultados [7](#).

O UMVE não sinaliza quando o processo em execução termina, então, a explicação para essa discrepância no tempo é devido à execução de outro comando, sobrepondo o que já estava sendo executado, sem que o primeiro tivesse terminado.

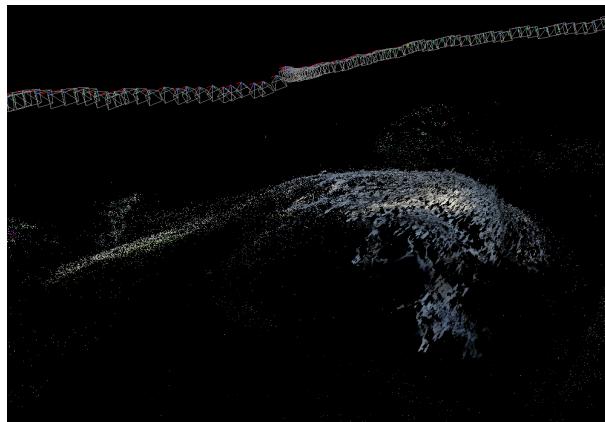


Figura 40 - Final da reconstrução via UMVE, percebe-se que alguns pontos não foram considerados, tendo como resultado uma "nuvem de pontos" mais densa, basicamente.

Tabela 7 - Tempos obtidos usando o MVE em um conjunto de dados do Jardim do Nêgo

Comando	Tempo (aprox.)
<i>sfmrecon</i>	78 segundos
<i>dmrecon</i>	14.503 segundos
<i>scene2pset</i>	600 segundos
<i>fssrecon</i>	25.293 segundos
<i>meshclean</i>	60 segundos

Na reconstrução por linha de comando também é possível visualizar em qual etapa da execução o algoritmo está (figura [41](#)), configurar alguns parâmetros e inclusive mostrar a porcentagem de progresso do comando em execução. Foram executados os comandos declarados nesta seção. O *sfmrecon* demorou cerca de 1 minuto e meio [42](#).



Figura 41 - Processos dentro do comando *sfmrecon*, onde (a) estão sendo detectadas as *features* do conjunto de imagens. Em (b) está computado o *pairwise matching* e em (c) está no processo de *Bundle Adjustment* (**CHOUDHARY**,), usando condições-padrão para as câmeras.

```
Selecionar Prompt de Comando
Rejected 201 tracks with large error.
Rejected 70 tracks behind cameras.
Rejected 674 tracks with unstable angle.
Deleted 0 of 23278 tracks (0.00%) above a threshold of 0.0159941.
Skipping full bundle adjustment (skipping 5 views).

Adding next view ID 65 (143 of 200)...
Collected 12 2D-3D correspondences.
Selected 10 2D-3D correspondences outliers (83%).
Reconstructed camera 65 with focal length 1
Running single camera bundle adjustment...
pBA: MSE 5.00345e-07 > 5.00159e-07 (S), 3 iter, 327ms.
Triangulated 1 new tracks, rejected 945 bad tracks.
Rejected 201 tracks with large error.
Rejected 70 tracks behind cameras.
Rejected 674 tracks with unstable angle.
Deleted 0 of 23279 tracks (0.00%) above a threshold of 0.0159941.
Skipping full bundle adjustment (skipping 5 views).
SFM reconstruction finished.

Running final bundle adjustment...
pBA: MSE 5.0055e-07 > 4.9486e-07 (S), 26 iter, 75509ms.
Camera 56, focal length: 0.935861 -> 0.935935, distortion: -0.0506553
Camera 57, focal length: 0.936948 -> 0.938748, distortion: -0.0554248
Camera 58, focal length: 0.955135 -> 0.953858, distortion: -0.0439308
Camera 59, focal length: 0.957488 -> 0.956769, distortion: -0.0595935
Camera 60, focal length: 0.963651 -> 0.964237, distortion: -0.0612002
Camera 61, focal length: 0.955873 -> 0.956757, distortion: -0.076264
Camera 62, focal length: 0.955131 -> 0.956728, distortion: -0.085152
Camera 63, focal length: 0.960946 -> 0.963876, distortion: -0.0631885
Camera 64, focal length: 0.970816 -> 0.975268, distortion: -0.0136308
```

Figura 42 - Término do comando *sfmrecon*, onde demorou cerca de 1 minuto e meio (75509 milisegundos).

O próximo comando, *dmrecon* demorou cerca de 4 horas, usando como configuração um nível L2, com 20 vizinhos 43. Usando um nível L0, o algoritmo rodou durante 6 horas aproximadamente e foi cancelado devido à demora na execução.

```

[...]
Count: 178779 filled: 69000 Queue: 21589
Count: 228433 filled: 76000 Queue: 3431
Count: 183540 filled: 70000 Queue: 20540
Filled 76658 pixels, i.e. 59.1 %.
MVS took 204 seconds.
Count: 187961 filled: 71000 Queue: 20256
Count: 191974 filled: 72000 Queue: 20095
Count: 196084 filled: 73000 Queue: 19739
Count: 202042 filled: 74000 Queue: 17974
Count: 206923 filled: 75000 Queue: 17279
Count: 210777 filled: 76000 Queue: 16925
Count: 216323 filled: 77000 Queue: 15475
Count: 221385 filled: 78000 Queue: 13979
Count: 226689 filled: 79000 Queue: 12274
Count: 234770 filled: 80000 Queue: 10341
Count: 240287 filled: 81000 Queue: 8352
Count: 248127 filled: 82000 Queue: 4630
Count: 254555 filled: 83000 Queue: 3094
Filled 83611 pixels, i.e. 64.5 %.
MVS took 216 seconds.
Reconstruction took 14502576ms.
Saving views back to disc...
Saving views to MVE files... done.

C:\Users\Desktop\Documents\UERJ\mve-20160517-win64>
C:\Users\Desktop\Documents\UERJ\mve-20160517-win64>

```

Figura 43 - Término do comando *dmrecon*, onde demorou cerca de 4 horas (14502576 milisegundos).

Usando o *scene2pset*, é necessário especificarmos em qual nível estamos reconstruindo e também uma saída válida. Por exemplo: ”*scene2pset.exe -Fnivel cena output*”. Onde o nível poderá ser um 0 (-F0), 1 (-F1) e assim por diante, a cena é o *input* e o *output* é um arquivo de extensão configurável, neste caso *.ply* 44. Este comando foi rápido, demorou cerca de 10 minutos, levando em conta todos os níveis.

```

[...]
Processing view "IMG_2763_198" (with colors)...
Processing view "IMG_2763_191" (with colors)...
Processing view "IMG_2763_192" (with colors)...
Processing view "IMG_2763_194" (with colors)...
Processing view "IMG_2763_193" (with colors)...
Processing view "IMG_2763_195" (with colors)...
Processing view "IMG_2763_196" (with colors)...
Processing view "IMG_2763_197" (with colors)...
Processing view "IMG_2763_198" (with colors)...
Processing view "IMG_2763_199" (with colors)...
Processing view "IMG_2763_200" (with colors)...
Writing final point set (13543640 points)...
Writing PLY file (13543640 verts, with colors, with normals, with confidences, with values, 0 faces, with colors)... done.

C:\Users\Desktop\Documents\UERJ\mve-20160517-win64>scene2pset.exe -F3 teste pset_L3.ply
MVE Scene to PointSet (built on May 17 2016, 12:36:22)
Using depthmap "depth-L3" and color image "undist-L3"
Initializing scene with 200 views...
Initialized 200 views (max ID is 199), took 104ms.
Writing final point set (0 points)...
Writing PLY file (0 verts, with colors, with normals, with confidences, with values, 0 faces, with colors)... done.

C:\Users\Desktop\Documents\UERJ\mve-20160517-win64>fssrecon pset_L0.ply pset_L1.ply pset_L2.ply pset_L3.ply final-output-mesh.ply
Floating Scale Surface Reconstruction (built on May 17 2016, 12:36:32)
Loading: pset_L0.ply...
Loading samples took 0ms.
Loading: pset_L1.ply...

```

Figura 44 - Execução dos comandos *scene2pset*, nos níveis -F0, -F1, -F2 e -F3.

Para juntar todos os níveis do *scene2pset*, foi usado o *fssrecon*, que gera uma única reconstrução. Este processo demorou bastante, cerca de 7 horas 45. Que teve como resultado a malha 46.

```

Selecionar Prompt de Comando
Loading: pset_L3.ply...
Loading samples took 0ms.
Limiting octree to 20 levels...
Octree contains 19019463 samples in 5267793 nodes on 16 levels.
    Level 7: 3 samples
    Level 8: 1330 samples
    Level 9: 34013 samples
    Level 10: 509845 samples
    Level 11: 3294553 samples
    Level 12: 8815390 samples
    Level 13: 6128926 samples
    Level 14: 235361 samples
    Level 15: 42 samples
Computing sampling of the implicit function...
Sampling the implicit function at 6796595 positions, fetch a beer...
Processing voxel 6796595 (100.00%, 421:19, ETA 307445734561825:51)...
Generated 6796595 voxels, took 25292543ms.
Extracting isosurface...
    Sanity-checking input data... took 430 ms.
    Computing Marching Cubes indices... took 8041 ms.
    Computing isovertices... took 14438 ms.
    Computing isopolygons... took 41304 ms.
    Computing triangulation... took 5218 ms.
    Done. Surface extraction took 69698ms.
Deleting zero confidence vertices... took 219ms.
Mesh output file: final-output-mesh.ply
Writing PLY file (1826729 verts, with colors, with confidences, with values, 3640878 faces)... done.
All done. Remember to clean the output mesh.

C:\Users\Desktop\Documents\UERJ\mve-20160517-win64>

```

Figura 45 - Progressão do comando *fssrecon*, onde possui o ETA – *Estimated Time of Arrival*.

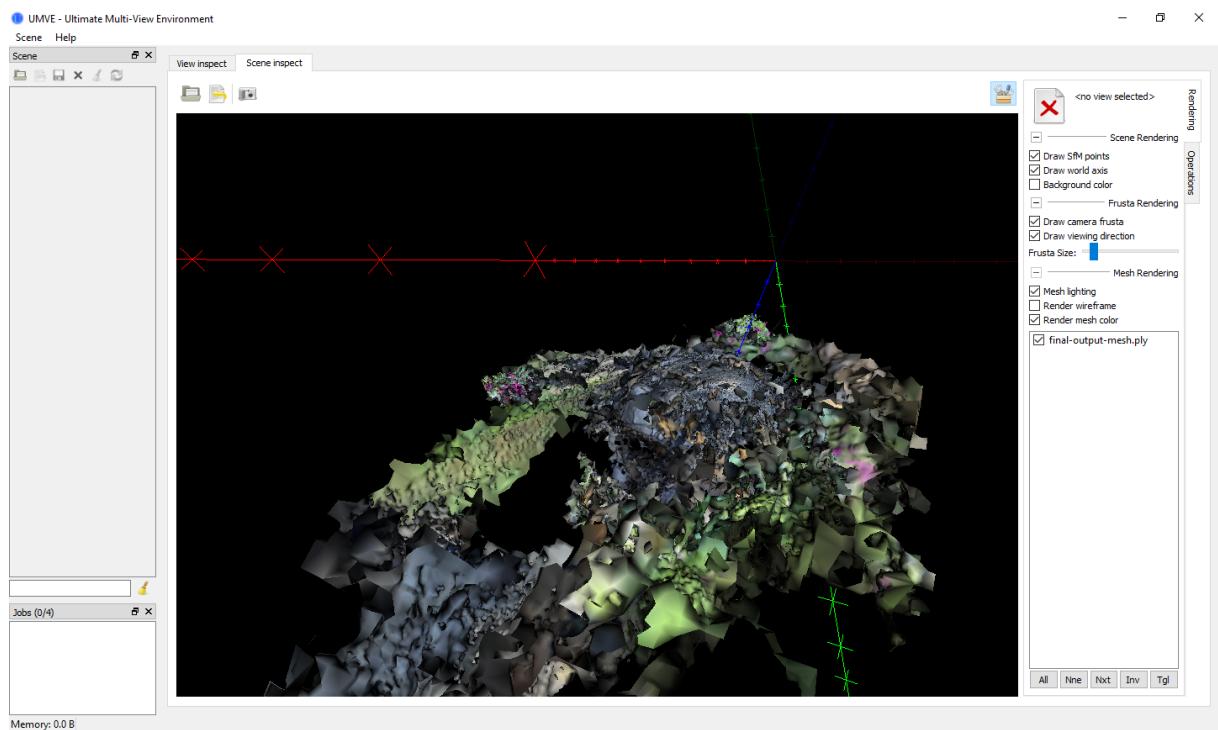


Figura 46 - Malha com ruídos proveniente do comando *fssrecon*.

Finalmente, basta limpar a malha atual com o comando *meshclean*, onde foi obtido o resultado [47](#).

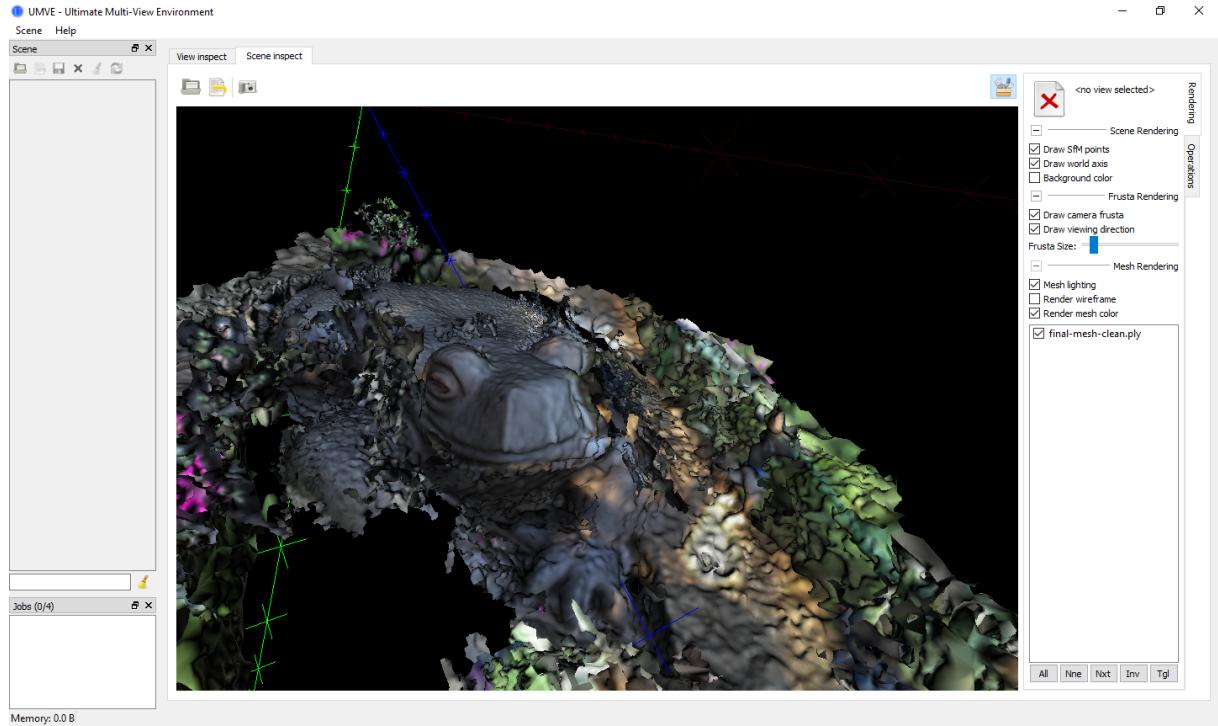


Figura 47 - Resultado final, após a remoção dos ruídos da malha.

Para comparação, usamos o mesmo objeto utilizado na reconstrução do VisualSfM (a galinha) e fizemos o passo a passo com o MVE: com a interface gráfica (UMVE), criamos uma nova cena e inserimos, primeiramente, as 200 fotos do objeto. Em seguida, utilizando as linhas de comando do MVE, fizemos o procedimento padrão de reconstrução do software. E, obtivemos os seguintes resultados [8](#):

Tabela 8 - Tempos obtidos usando o MVE em um conjunto de dados em ambiente interno com 200 imagens

Comando	Tempo (aprox.)
<i>sfmrecon</i>	371 segundos
<i>dmrecon</i>	3.716 segundos
<i>scene2pset</i>	300 segundos
<i>fssrecon</i>	1.695 segundos
<i>meshclean</i>	45 segundos

Figura 48 - Tempo gasto da etapa *sfmrecon* do MVE

Figura 49 - Tempo da etapa *dmrecon* do MVE

Figura 50 - Tempo da etapa *fssrecon* do MVE

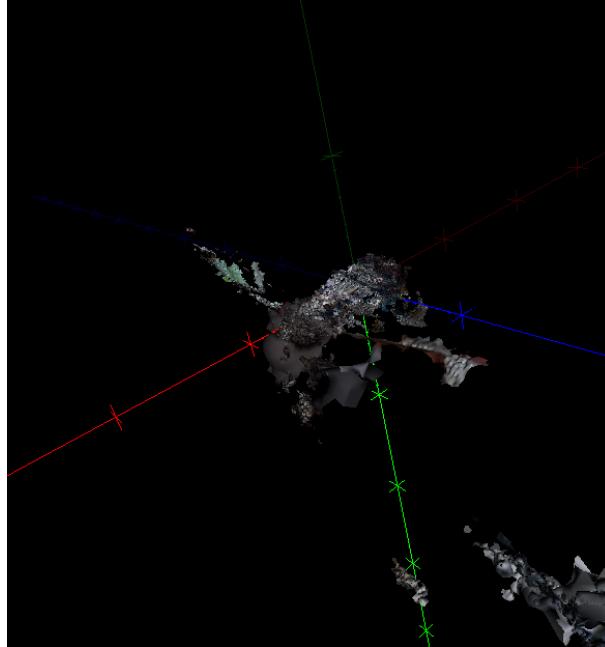


Figura 51 - Resultado da etapa *fssrecon* do MVE

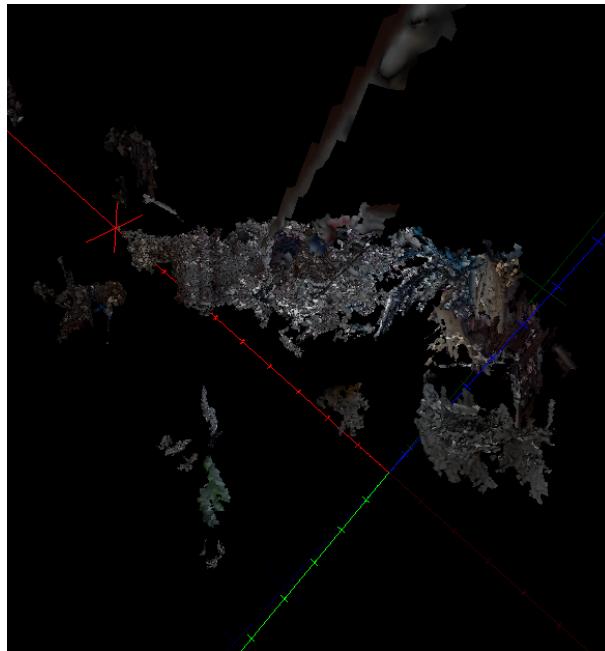


Figura 52 - Resultado da etapa *meshclean*, da etapa anterior 51

A etapa de *scene2pset* demorou cerca de 20 segundos (total). Porém percebemos que a reconstrução não foi satisfatória, o *software* se confundiu, e não conseguiu obter os parâmetros corretos das câmeras utilizadas. A partir disso, o erro se propagou e gerou essa reconstrução acima 51 e 52.

Rodamos também, com as 224 fotos, só foi possível executar o passo *sfmrecon* 53, pois o MVE não conseguiu rodar o comando *dmrecon* por algum motivo, e não gerou nenhum resultado para a continuação do algoritmo 54.

Figura 53 - Resultado da etapa *sfmrecon*, com todas as imagens

Figura 54 - Resultado da etapa *dmrecon*, com todas as imagens

6 CONCLUSÃO

Apresentamos técnicas de reconstruções utilizando fotogrametria, mais especificamente para esculturas à céu aberto, aprendendo sobre a calibração de equipamentos, software a serem utilizados e sobre como fazer uma boa varredura, cobrindo toda a escultura com uma câmera comum de celular.

Trabalhos futuros

Identificamos os seguintes caminhos para a evolução deste projeto:

- **Realizar uma varredura com o Kinect.** Embora seja custoso, tanto fisicamente quanto computacionalmente, seria interessante ter um parâmetro de comparação com as técnicas de fotogrametria Kinect, que se mostrou muito promissor em um ambiente fechado.
- **Validação adicional.** Ter resultados mais expressivos, em questão quantitativa e não só qualitativa, para realizar uma engenharia mais completa do sistema, comparando valores em diferentes técnicas empregadas.
- **Constatar na prática, o melhor método de varredura da escultura.** Verificamos que um dos melhores modos de se escanear uma escultura de grande porte seria escaneá-la várias vezes, a fim de que se pegue todos os detalhes, cobrindo toda a área a ser reconstruída. Mas será que este é realmente o melhor método?
- **Realizar uma reconstrução de curvas.** Será possível utilizar uma reconstrução baseada em curvas para auxiliar na reconstrução de nuvem de pontos e superfícies densas?
- **Concretizar o objetivo proposto neste trabalho.** Ir algumas vezes ao Jardim do Nêgo com o intuito de aumentar o acervo de filmes/imagens das esculturas de modo que seja possível ter uma reconstrução 3D satisfatória de todo o jardim, eternizando todo o patrimônio cultural.

REFERÊNCIAS

- ABLAN, D. *Digital Photography for 3D Imaging and Animation*. Wiley, 2007. ISBN 9780470165980. Disponível em: [⟨https://books.google.com.br/books?id=nLSVKEavyPcC⟩](https://books.google.com.br/books?id=nLSVKEavyPcC).
- AGARWAL, S. et al. Reconstructing rome. *Computer*, ieee, v. 43, n. 6, p. 40–47, 2010.
- AGARWAL, S. et al. Building rome in a day. *Communications of the ACM*, ACM, v. 54, n. 10, p. 105–112, 2011.
- BASRI, R.; JACOBS, D. W. Lambertian reflectance and linear subspaces. *IEEE transactions on pattern analysis and machine intelligence*, IEEE, v. 25, n. 2, p. 218–233, 2003.
- CHOUDHARY, S. Bundle adjustment : A tutorial.
- DOBBERT, T. *Matchmoving: The Invisible Art of Camera Tracking*. Wiley, 2012. (Books 24x7 IT PRO). ISBN 9781118529669. Disponível em: [⟨https://books.google.com.br/books?id=Jr4YsaTrIBgC⟩](https://books.google.com.br/books?id=Jr4YsaTrIBgC).
- FABBRI, R.; GIBLIN, P. J.; KIMIA, B. B. Camera pose estimation using first-order curve differential geometry. In: *Proceedings of the IEEE European Conference in Computer Vision*. [S.l.: s.n.], 2012.
- FABBRI, R.; KIMIA, B. B. 3D curve sketch: Flexible curve-based stereo reconstruction and calibration. In: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*. San Francisco, California, USA: IEEE Computer Society Press, 2010.
- FABBRI, R.; KIMIA, B. B. Multiview differential geometry of curves. *International Journal of Computer Vision*, Springer, v. 117, p. 1–23, 2016. Disponível em: [⟨http://dx.doi.org/10.1007/s11263-016-0912-7⟩](http://dx.doi.org/10.1007/s11263-016-0912-7).
- FUHRMANN, S.; GOESELE, M. Floating scale surface reconstruction. *ACM Transactions on Graphics (TOG)*, ACM, v. 33, n. 4, p. 46, 2014.
- FUHRMANN, S.; LANGGUTH, F.; GOESELE, M. Mve: A multi-view reconstruction environment. In: *Proceedings of the Eurographics Workshop on Graphics and Cultural Heritage*. Aire-la-Ville, Switzerland, Switzerland: Eurographics Association, 2014. (GCH '14), p. 11–18. ISBN 978-3-905674-63-7. Disponível em: [⟨http://dx.doi.org/10.2312/gch.20141299⟩](http://dx.doi.org/10.2312/gch.20141299).
- FURUKAWA, Y. et al. Towards internet-scale multi-view stereo. In: IEEE. *Computer Vision and Pattern Recognition (CVPR), 2010 IEEE Conference on*. [S.l.], 2010. p. 1434–1441.
- FURUKAWA, Y.; PONCE, J. *Dense patch models for motion capture from synchronized video streams*. [S.l.], 2007.

- FURUKAWA, Y.; PONCE, J. Accurate camera calibration from multi-view stereo and bundle adjustment. *International Journal of Computer Vision*, Springer, v. 84, n. 3, p. 257–268, 2009.
- FURUKAWA, Y.; PONCE, J. Accurate, dense, and robust multiview stereopsis. *IEEE transactions on pattern analysis and machine intelligence*, IEEE, v. 32, n. 8, p. 1362–1376, 2010.
- GAVA, C. Dense 3d reconstruction.
- GOESELE, M. et al. Multi-view stereo for community photo collections. In: *IEEE. Computer Vision, 2007. ICCV 2007. IEEE 11th International Conference on*. [S.l.], 2007. p. 1–8.
- GOKTURK, S. B.; YALCIN, H.; BAMJI, C. A time-of-flight depth sensor-system description, issues and solutions. In: *IEEE. Computer Vision and Pattern Recognition Workshop, 2004. CVPRW'04. Conference on*. [S.l.], 2004. p. 35–35.
- HAIGHT, F. A. *Handbook of the poisson distribution*. Wiley, 1967.
- IZADI, S. et al. Kinectfusion: Real-time 3d reconstruction and interaction using a moving depth camera. In: *Proceedings of the 24th Annual ACM Symposium on User Interface Software and Technology*. New York, NY, USA: ACM, 2011. (UIST '11), p. 559–568. ISBN 978-1-4503-0716-1. Disponível em: [⟨http://doi.acm.org/10.1145/2047196.2047270⟩](http://doi.acm.org/10.1145/2047196.2047270).
- LACHAT, E. et al. First experiences with kinect v2 sensor for close range 3d modelling. *The International Archives of Photogrammetry, Remote Sensing and Spatial Information Sciences*, Copernicus GmbH, v. 40, n. 5, p. 93, 2015.
- LEVOY, M. et al. The digital michelangelo project: 3d scanning of large statues. In: *ACM PRESS/ADDISON-WESLEY PUBLISHING CO. Proceedings of the 27th annual conference on Computer graphics and interactive techniques*. [S.l.], 2000. p. 131–144.
- LI, B. et al. Improving pmvs algorithm for 3d scene reconstruction from sparse stereo pairs. In: SPRINGER. *Pacific-Rim Conference on Multimedia*. [S.l.], 2013. p. 221–232.
- LI, B. et al. Improving pmvs algorithm for 3d scene reconstruction from sparse stereo pairs. In: _____. *Advances in Multimedia Information Processing – PCM 2013: 14th Pacific-Rim Conference on Multimedia, Nanjing, China, December 13–16, 2013. Proceedings*. Cham: Springer International Publishing, 2013. p. 221–232. ISBN 978-3-319-03731-8. Disponível em: [⟨https://doi.org/10.1007/978-3-319-03731-8_21⟩](https://doi.org/10.1007/978-3-319-03731-8_21).
- MIKOLAJCZYK, K. *Detection of local features invariant to affines transformations*. Tese (Doutorado) — Institut National Polytechnique de Grenoble-INPG, 2002.
- MORÉ, J. J. The levenberg-marquardt algorithm: implementation and theory. In: *Numerical analysis*. [S.l.]: Springer, 1978. p. 105–116.
- OPTO Engineering. 2017. Disponível em: [⟨http://www.opto-engineering.com/⟩](http://www.opto-engineering.com/).
- PRESS, W. H. *The art of scientific computing*. [S.l.]: Cambridge university press, 1992.
- RECONSTRUCTION Pipeline Howto version 0.1.

- SILBERMAN DEREK HOIEM, P. K. N.; FERGUS, R. Indoor segmentation and support inference from rgbd images. In: *ECCV*. [S.l.: s.n.], 2012.
- SMISEK, J.; JANCOSEK, M.; PAJDLA, T. 3d with kinect. In: *Consumer depth cameras for computer vision*. [S.l.]: Springer, 2013. p. 3–25.
- SNAVELY, N. et al. Bundler: Structure from motion (sfm) for unordered image collections. Available online: *phototour. cs. washington. edu/bundler/*(accessed on 12 July 2013), v. 1, 2010.
- STRICKER, D. Structure from motion ii. 2015.
- SWEENEY, C. *Theia Multiview Geometry Library: Tutorial & Reference*. 2016. (<http://theia-sfm.org>).
- TEERAVECH, K. An introduction to 3d reconstruction using visualsfm and pmvs2/cmvs. In: *Remote Sensing and Geographic Information Systems*. [S.l.: s.n.], 2013. ISBN 978-3-905674-63-7.
- USUMEZBAS, A.; FABBRI, R.; KIMIA, B. B. From multiview image curves to 3D drawings. In: *Proceedings of the European Conference on Computer Vision*. [S.l.]: Springer, 2016. (Lecture Notes in Computer Science).
- VALGMA, L. *3D reconstruction using Kinect v2 camera*. Tese (Doutorado) — Tartu Ülikool, 2016.
- WANG, G. et al. Research on features matching method for visual odometry based on depth image. In: INTERNATIONAL SOCIETY FOR OPTICS AND PHOTONICS. *Sixth International Conference on Electronics and Information Engineering*. [S.l.], 2015. v. 9794, p. 97941U.
- WITNESS, G. Best of brazil – readers’ tips. 2014. Disponível em: <https://www.theguardian.com/travel/2014/jun/23/best-of-brazil-readers-tips>.
- WU, C. Towards linear-time incremental structure from motion. In: *IEEE. 3DTV-Conference, 2013 International Conference on*. [S.l.], 2013. p. 127–134.
- WU, C. et al. Multicore bundle adjustment. In: *IEEE. Computer Vision and Pattern Recognition (CVPR), 2011 IEEE Conference on*. [S.l.], 2011. p. 3057–3064.
- WU, C. et al. Visualsfm: A visual structure from motion system. 2011.